

UNIVERSITÀ TELEMATICA INTERNAZIONALE
UNINETTUNO

FACOLTÀ DI INGEGNERIA

Corso di Laurea Magistrale in
Ingegneria Informatica

ELABORATO FINALE

in

Introduzione ai Big Data

**Svelando i segreti della Buy Box in Amazon:
un approccio containerizzato**

RELATORE

Prof. Emanuel Weitschek

CANDIDATO

Giulio Baglione

ANNO ACCADEMICO 2023/2024

Un ringraziamento speciale va alla mia famiglia, per il supporto costante e l'amore incondizionato durante questo percorso.

A mia figlia Bianca, per la sua curiosità contagiosa che mi ricorda ogni giorno l'importanza di non smettere mai di imparare.

E a mia moglie Simona, per il suo sorriso che illumina ogni giorno della mia vita e per essere la mia roccia nei momenti di difficoltà.

E un ringraziamento a me stesso, per non aver mai mollato, per aver creduto nelle mie capacità e per aver perseverato anche quando le sfide sembravano insormontabili.

Indice

1 Introduzione	1
1.1 Statistiche sul fatturato di Amazon	2
1.2 I vantaggi e le sfide di vendere su Amazon	4
1.3 Buy Box	5
1.4 Pricing dinamico	6
2 Il lavoro progettuale	7
2.1 Panoramica del sistema e tecnologie utilizzate	9
2.2 Introduzione a Docker	10
2.2.1 Vantaggi dell'utilizzo di Docker	11
2.2.2 Docker Compose	11
2.2.3 Immagini Docker	12
2.2.4 Volumi Docker	12
2.3 Composizione nell'architettura Docker di progetto	13
2.3.1 Servizio mongodb	13
2.3.2 Volume mongo-data	13
2.3.3 Servizio mongo-express	13
2.3.4 Servizio scraper	13
2.3.5 Servizio dashboard	14
2.4 Conclusioni sull'architettura	15
3 Campionamento dei dati tramite Web Scraping	16
3.1 Introduzione al Web Scraping	16
3.1.1 BeautifulSoup	17
3.1.2 Selenium	18
3.2 Campionamento dei prodotti su Amazon	19
3.3 Caratteristiche raccolte	23
3.3.1 Funzioni di estrazione dati	27
3.4 Scrittura dei campioni	28
4 Analisi dei dati con algoritmi di Machine Learning	30
4.1 Pre-processamento dei dati	32
4.1.1 Lettura dei dati da MongoDB	32
4.1.2 Trasformazione dei dati	32
4.1.3 Dati mancanti o nulli	34
4.1.4 Normalizzazione dei dati	35
4.2 Introduzione al Machine Learning	36
4.2.1 Apprendimento supervisionato	36
4.2.2 Scikit-Learn	37
4.2.3 Apprendimento d'insieme	38
4.3 Implementazione dei modelli di Machine Learning	39
4.3.1 Preparazione degli insiemi di training e test	39
4.3.2 Convalida del modello tramite Cross-Validation	40
4.3.3 Modelli di classificazione	43
4.3.4 Accuratezza dei modelli di classificazione	52
4.3.5 Scelta degli iperparametri	52

4.3.6 Estrazione dei pesi delle caratteristiche	54
5 Esplorazione delle analisi	56
5.1 Introduzione a Dash Plotly	57
5.2 Piattaforma Web interattiva	58
5.2.1 Sezione di input	59
5.2.2 Esecuzione analisi in Machine Learning	63
5.2.3 Sezione di output	64
5.3 Risultati notevoli	70
5.3.1 Periodo non promozionale (11/10/2024 - 18/10/2024)	72
5.3.2 Periodo del Black Friday (21/11/2024 - 02/12/2024)	81
5.3.3 Periodo delle Feste di Natale (15/12/2024 - 22/12/2024)	89
6 Conclusioni	97
Bibliografia	100
Sitografia	101
Appendice A - Codice sorgente del progetto	104
Appendice B - Esempi di file di campionamento	105
result_example.json	105
result_err_example.json	108

Sommario

Nel contesto di un mondo sempre più connesso e digitale, Amazon rappresenta una delle piattaforme di e-commerce più influenti a livello globale. Milioni di venditori, infatti, si rivolgono ad Amazon per raggiungere una vasta platea di consumatori, sfruttando le sue infrastrutture logistiche avanzate.

Ogni prodotto su Amazon può così essere venduto e spedito da uno o più soggetti, tra i quali la stessa Amazon. Tra tutti i venditori di un prodotto, la piattaforma di e-commerce di Amazon ne propone uno nella cosiddetta Buy Box, l'area sulla pagina del prodotto dove i clienti possono avviare il processo di acquisto aggiungendolo al carrello.

Tale proposta si presume sia guidata da un algoritmo complesso e non trasparente, il che rende una vera e propria sfida per i venditori adottare delle strategie atte a ottenere l'assegnazione della Buy Box. Per questi venditori, infatti, ottenere l'assegnazione della Buy Box significa poter beneficiare di una posizione privilegiata che incrementa sensibilmente la possibilità di effettuare una vendita, nonché aumentare la visibilità dei propri prodotti. Competere efficacemente su Amazon è determinante per il successo o il fallimento di un'attività commerciale, rendendo dunque essenziale la comprensione delle dinamiche che influenzano l'assegnazione della Buy Box.

In quest'ottica, il presente elaborato si propone di fornire uno strumento utile a estrarre le informazioni più rilevanti dalla piattaforma Amazon ed effettuare un'opportuna analisi al fine di identificare quali sono le caratteristiche dei venditori che influenzano maggiormente l'assegnazione della Buy Box. L'obiettivo principale, dunque, è sviluppare un sistema software automatizzato che estragga le informazioni da Amazon tramite tecniche di Web Scraping e analizzi tali dati tramite opportuni algoritmi di Machine Learning, i cui risultati saranno raccolti e visualizzati in una piattaforma Web per essere esplorati e interpretati.

Data la mutabilità dell'algoritmo di assegnazione della Buy Box di Amazon, con il sistema sviluppato si vuole proporre una soluzione che possa parametrizzare i dati di ingresso al calcolo analitico in Machine Learning, in modo da esplorare casistiche notevoli di interesse. Una tale funzionalità consente di rispondere agli innumerevoli quesiti che si possono porre nella fase di analisi dei dati, principalmente posti sulla base dei filtri da applicare ai dati in ingresso e ai parametri utili a personalizzare nonché ottimizzare le analisi stesse.

La ricerca procederà con un capitolo introduttivo in cui viene illustrato il contesto attorno al quale ruota il presente elaborato, ossia la piattaforma di e-commerce Amazon. Verrà effettuata

una panoramica sul contesto commerciale che ruota attorno ad Amazon e ai venditori che decidono di vendere i loro prodotti tramite la vetrina di questo colosso dell'e-commerce, con evidenza degli elementi fondamentali che caratterizzano la piattaforma, quali la Buy Box e il pricing dinamico.

Il capitolo successivo sarà dedicato a illustrare il lavoro progettuale ad alto livello, con evidenza degli obiettivi, delle tecnologie utilizzate e della relazione e comunicazione tra le parti che lo compongono. Ogni elemento del sistema verrà approfondito nei capitoli a seguire, con l'analisi delle scelte effettuate e gli opportuni dettagli implementativi.

In particolare, il capitolo successivo si focalizzerà sul campionamento dei dati da Amazon tramite tecniche di Web Scraping, realizzate mediante script in Python atti ad estrarre le informazioni più rilevanti dei venditori per alcuni prodotti di diverse categorie. Tra i dati raccolti compariranno informazioni quali il prezzo di vendita del prodotto, il numero di recensioni e il rating del venditore, i giorni di consegna e altre caratteristiche rilevanti. Tali dati saranno raccolti in un formato strutturato in JSON e memorizzati in un Database non-relazionale MongoDB.

Seguirà il capitolo in cui si analizzeranno i dati raccolti tramite gli algoritmi di Machine Learning, con un approfondimento sulle caratteristiche scelte per l'analisi, sui singoli algoritmi e sui dettagli implementativi che consentiranno di ottenere i risultati di tali analisi.

Successivamente, si illustrerà la piattaforma Web sviluppata per consentire la scelta dei parametri di filtro dei dati da analizzare e di input all'analisi in Machine Learning secondo gli algoritmi trattati nel capitolo appena precedente e la visualizzazione dei risultati dell'analisi stessa, in modo da esplorare diverse configurazioni che possono portare a risultati diversi e di particolare interesse.

Infatti, tramite tale piattaforma saranno esplorate alcune specifiche configurazioni che mostreranno, oltre a un'elevata accuratezza nell'analisi, dei risultati notevoli che potranno evidenziare quali sono le caratteristiche dei venditori che Amazon predilige per l'assegnazione della Buy Box.

In particolare, saranno presi in considerazione tre periodi di osservazione di particolare interesse, quali un periodo non promozionale, il periodo del Black Friday e il periodo delle Feste di Natale, e due particolari composizioni di input alle analisi nelle quali Amazon e i nuovi venditori sono inclusi nei dati, sia come vincitori che non della Buy Box, oppure sono filtrati ed esclusi.

Nelle esplorazioni effettuate si potrà notare che la caratteristica del prezzo totale di vendita del prodotto proposto dal venditore sia quella maggiormente influente per l'assegnazione della Buy

Box. A seguire si potranno individuare delle caratteristiche con un peso minore ma comunque influenti, quali l'adesione al programma FBA di Amazon e la percentuale di recensioni positive ricevute.

A conclusione del presente elaborato, saranno evidenziati i limiti e le possibili evoluzioni future del sistema sviluppato.

1 Introduzione

Nata nel 1994 come una piccola libreria online, Amazon è oggi un colosso dell'e-commerce che ha profondamente trasformato il modo in cui acquistiamo e consumiamo. Come sottolineato da Anderson [B1], Amazon rappresenta un caso paradigmatico di come l'innovazione tecnologica possa rivoluzionare interi settori industriali.

Inizialmente focalizzata sulla vendita di libri, Amazon ha rapidamente ampliato il suo catalogo, offrendo una vasta gamma di prodotti e servizi. La sua crescita esponenziale è stata resa possibile da una combinazione di diversi fattori.

In primo luogo un'ossessione per il cliente, come confermato anche dalla mission dichiarata da Amazon stessa [S1], la quale illustra la filosofia aziendale che si riflette in ogni aspetto del business, dalla facilità d'uso del sito web alla rapidità delle consegne. Proprio per l'ossessione verso il cliente, Amazon fa largo uso di algoritmi di apprendimento automatico per personalizzare l'esperienza d'acquisto per ogni cliente, aumentando così la fidelizzazione e le vendite [B2].

In secondo luogo l'innovazione continua, infatti Amazon investe ingenti risorse in ricerca e sviluppo, introducendo costantemente nuove tecnologie e servizi, come il programma Prime, Amazon Web Services (AWS) e i dispositivi Echo.

In terzo luogo una logistica efficiente, infatti la costruzione di una rete logistica globale ha permesso ad Amazon di offrire tempi di consegna sempre più rapidi e costi di spedizione competitivi.

Infine un marketplace di successo, la cui realizzazione ha consentito a milioni di venditori di terze parti di offrire i propri prodotti sulla piattaforma, ampliando enormemente l'assortimento disponibile e rafforzando la posizione di Amazon come destinazione principale per lo shopping online.

L'impatto di Amazon si estende ben oltre il settore dell'e-commerce. L'azienda ha profondamente modificato il comportamento dei consumatori, ha sfidato i tradizionali modelli di distribuzione e ha influenzato la concorrenza in numerosi settori. Inoltre, Amazon ha creato nuove opportunità per le piccole e medie imprese, offrendo loro una vetrina globale e strumenti innovativi per gestire il proprio business.

1.1 Statistiche sul fatturato di Amazon

Come si evince dal grafico seguente (fig. 1.1) [S2], il fatturato di Amazon è cresciuto in modo esponenziale negli ultimi cinque anni, superando i 500 miliardi di dollari nel 2022, con un'accelerazione particolarmente evidente a partire dal 2020, in concomitanza con la pandemia di COVID-19, che ha spinto i consumatori verso lo shopping online. Questa crescita è stata trainata principalmente dall'espansione del catalogo prodotti, dall'aumento del numero di venditori sul marketplace e dalla crescente diffusione dei servizi Prime.



Figura 1.1: Andamento del fatturato di Amazon negli ultimi 5 anni [S2]

Di seguito (fig. 1.2) viene evidenziato il dettaglio delle fonti del fatturato di Amazon [S3], con particolare rilevanza sulle vendite online, sui servizi offerti a venditori di terze parti e sui servizi digitali di Amazon Web Services:




Figura 1.2: Andamento del fatturato di Amazon negli ultimi 5 anni per fonte [S3]

L'analisi statistica dei dati di fatturato per paese (fig. 1.3) [S3] mostra come i principali proventi provengano dal Nord America:




Figura 1.3: Andamento del fatturato di Amazon negli ultimi 5 anni per paese [S3]

1.2 I vantaggi e le sfide di vendere su Amazon

Amazon offre un'opportunità unica per venditori di ogni dimensione. Con una base di clienti vastissima e un'infrastruttura logistica solida, Amazon si è affermata come una delle principali destinazioni per lo shopping online a livello globale. Questo marketplace, con la sua portata immensa e la sua reputazione consolidata, rappresenta un terreno fertile per la crescita di qualsiasi attività commerciale. Vendere su Amazon significa aprire le porte a un mondo di possibilità, raggiungendo un pubblico potenzialmente illimitato e incrementando significativamente le proprie vendite.

Amazon offre una vetrina virtuale estesa, dove è possibile vendere praticamente qualsiasi tipo di prodotto, dall'elettronica all'abbigliamento, dai libri ai prodotti artigianali. Questa varietà consente ai venditori di raggiungere una clientela diversificata, per età, interessi e potere d'acquisto, e di specializzarsi in nicchie di mercato specifiche.

Il marchio Amazon gode di una grande fiducia da parte dei consumatori, associato a qualità, affidabilità, vasta scelta e facilità d'uso. Tale percezione positiva si trasferisce anche ai prodotti venduti sulla piattaforma, facilitando le conversioni e aumentando la fidelizzazione dei clienti. Secondo una recente ricerca da parte della piattaforma Jungle Scout [S4], che si occupa di analizzare dati da Amazon per coadiuvare i venditori nelle loro scelte commerciali, Amazon è la destinazione di ricerca per il 56% dei consumatori che navigano nel Web, davanti ai motori di ricerca (42%), Walmart (29%), YouTube (13%), e Facebook (10%), a prova di quanto sia importante per i venditori aprire una propria vetrina su Amazon.

Inoltre, Amazon offre una serie di servizi utili per agevolare il proprio business, tra i quali è opportuno citare il programma Fulfillment by Amazon (FBA) [S5], grazie al quale il venditore può delegare alla logistica di Amazon lo stoccaggio, l'imballaggio e la spedizione dei prodotti in vendita. Secondo dei recenti studi statistici [S6] risulta che la maggior parte dei venditori (circa il 94%) usa il programma FBA, che sicuramente rimane la scelta preferita per i venditori indipendenti o che si affacciano per la prima volta a vendere prodotti su Amazon.

Come ulteriore punto a vantaggio dei venditori, Amazon offre ai venditori con account business [S7] degli strumenti di marketing per promuovere i prodotti e aumentare la visibilità, come pubblicità sponsorizzata e recensioni dei prodotti.

Infine, grazie agli opportuni strumenti di monitoraggio, i venditori possono analizzare i dati delle vendite e ottenere i dettagli riguardo le performance dei loro prodotti, consentendo di prendere

decisioni informate sulla strategia di vendita. Grazie a queste analisi, è possibile ottimizzare il catalogo prodotti, le campagne pubblicitarie e le strategie di prezzo.

Nonostante i numerosi vantaggi, vendere su Amazon presenta anche delle sfide. La competizione è intensa, con milioni di venditori che si contendono l'attenzione dei clienti. Mantenere prezzi competitivi, ottimizzare le inserzioni, gestire le recensioni dei clienti e stare al passo con le continue evoluzioni della piattaforma sono solo alcune delle sfide che i venditori devono affrontare.

Inoltre, la gestione della logistica, soprattutto per i venditori che si assumono la piena titolarità della spedizione con il programma Fulfillment by Merchant (FBM) [S8], alternativo all'utilizzo del programma FBA sopracitato, può rivelarsi complessa e richiedere una gestione attenta delle spedizioni e degli inventari.

Infine, le politiche di Amazon sono in continua evoluzione e i venditori devono essere sempre aggiornati per evitare sospensioni dell'account o penalizzazioni, le quali possono influenzare negativamente l'esperienza di vendita mediante la vetrina della piattaforma di e-commerce.

1.3 Buy Box

The screenshot displays the Amazon product page for the Trust Gaming GXT 415 Xirox headset. The product is shown with a large image and a smaller thumbnail. The title is 'Trust Gaming GXT 415 Xirox Cuffie Gaming Leggere con Driver da 50 mm per PC, Xbox, PS4, PS5, Switch, Mobile, Jack Audio 3.5 mm, Cavo 2m, Cuffie con Microfono Over-Ear - Nero'. The price is 16,99 €, with a 15% discount from the original price of 19,99 €. The product has a 4.3-star rating from 1,878 reviews. The 'Buy Box' is highlighted with a red rectangle, showing the 'Consegna' (Delivery) section with a 'Nuovo' (New) price of 16,99 €, the 'Resi GRATUITI' (Free Returns) policy, and the 'Acquista ora' (Buy now) button. The 'Spedizione' (Shipping) section is highlighted with a green rectangle, showing the seller is 'Amazon' and the delivery is 'GRATUITA' (Free). The 'Disponibilità immediata' (Immediate Availability) section is also visible, showing the quantity is 1 and the 'Aggiungi al carrello' (Add to cart) button.

Figura 1.4: Buy Box (evidenziato dal rettangolo in rosso) e dettaglio del venditore e dello spedizioniere (evidenziato dal rettangolo in verde)

La Buy Box di Amazon è una delle caratteristiche più ambite per i venditori sulla piattaforma. È lo spazio prominente nella pagina di un prodotto dove viene visualizzato il pulsante "Acquista ora" e le informazioni principali sull'offerta, come il prezzo, la disponibilità e chi sono il venditore e lo spedizioniere, come mostrato nella figura precedente (fig. 1.4).

Essere il venditore selezionato per la Buy Box significa avere in primo luogo una maggiore probabilità di aggiudicarsi la vendita del prodotto, in secondo luogo una maggiore visibilità e, di conseguenza, la possibilità di raggiungere più clienti.

Dunque, per i venditori è essenziale adottare delle strategie ben definite ed efficaci per vincere l'assegnazione della Buy Box, gestendo in maniera attenta il proprio negozio Amazon.

Si presume, infatti, che Amazon utilizzi un algoritmo complesso per determinare il vincitore della Buy Box, il quale prende in considerazione numerosi fattori caratteristici dei venditori e del prodotto in vendita. Tale algoritmo può mutare nel corso del tempo e prendere in considerazione fattori sempre più diversi o con un peso specifico differente rispetto a precedenti versioni, rendendo di fatto una vera e propria sfida per i venditori adottare delle strategie utili a configurare la propria vendita in modo da assicurarsi l'assegnazione della Buy Box da parte di Amazon.

1.4 Pricing dinamico

In questo contesto in continua evoluzione, è opportuno sottolineare come sia Amazon che venditori di terze parti utilizzino degli algoritmi di pricing atti a modificare i prezzi dei prodotti in base a diversi fattori, come la concorrenza, la domanda e il comportamento dei clienti.

Alla base di uno studio condotto da alcuni ricercatori della Northeastern University di Boston [B3] vi è l'analisi dell'utilizzo da parte dei venditori di algoritmi di pricing che consentono di massimizzare la competitività e la possibilità di vendere il proprio prodotto, proprio vincendo l'assegnazione della Buy Box.

Infatti, dallo studio suddetto sono emersi dei comportamenti distintivi tra i venditori algoritmici, ossia che usano algoritmi di pricing, e venditori non-algoritmici, che invece non li usano.

In primo luogo i prodotti venduti da venditori algoritmici subiscono un maggior numero di cambiamenti del vincitore della Buy Box (fig. 1.5).

In secondo luogo i venditori algoritmici hanno maggiori probabilità di vincere la Buy Box (fig. 1.6), tranne per il caso di prodotti di primo rango nella pagina delle nuove offerte.




Figura 1.5: Numero di cambiamenti del vincitore della Buy Box per distribuzione cumulativa dei prodotti¹




Figura 1.6: Rango dei prodotti per tasso di vincita della Buy Box²

Da quanto evidenziato, è possibile dedurre che il prezzo di vendita dei prodotti è sicuramente una caratteristica fondamentale per l'assegnazione della Buy Box.

¹ In riferimento alla fig. 25 a pag. 9 della sopracitata ricerca

² In riferimento alla fig. 26 a pag. 9 della sopracitata ricerca

2 Il lavoro progettuale

Al fine di identificare i fattori determinanti nell'assegnazione della Buy Box su Amazon, è stato sviluppato un sistema software altamente scalabile, affidabile e configurabile. Tale sistema è in grado di adattarsi a volumi di dati variabili, garantendo nel tempo risultati precisi e consistenti. La sua flessibilità consente di personalizzare le analisi a seconda delle esigenze specifiche, mentre la portabilità ne facilita l'implementazione in diversi ambienti. Tale sistema è il risultato finale di uno studio e un lavoro di sviluppo che attraversa diverse fasi.

In primo luogo si è analizzata la piattaforma di Amazon per alcuni prodotti campione scelti sulla base di diverse categorie, in modo da individuare quali sono le informazioni che è possibile recepire dalla piattaforma di e-commerce.

Tramite questa analisi preliminare è stato possibile sviluppare degli script in Python [S9] per estrarre, tramite opportune tecniche di Web Scraping [B4] con le librerie BeautifulSoup [S10] e Selenium [S11], dati dalle pagine Web di Amazon afferenti i prodotti in vendita e i loro venditori, distinti in vincitore e non vincitore della Buy Box. Tali dati includono informazioni come il prezzo di vendita del prodotto, il numero di recensioni e il rating del venditore, i giorni di consegna e altre caratteristiche rilevanti.

Le informazioni raccolte vengono memorizzate in un database NoSQL MongoDB [S12], il quale permette una gestione flessibile e scalabile dei dati. Per l'integrazione delle operazioni di lettura e scrittura in Python viene utilizzata la libreria PyMongo [S13], mentre per gestire in maniera visuale il Database è possibile utilizzare un'interfaccia Web Mongo Express [S14].

Successivamente, sono stati sviluppati degli script Python per normalizzare i dati storicizzati in un DataFrame [S15] e realizzare delle analisi su di esso tramite algoritmi di Machine Learning [B5], con la libreria Scikit-Learn [S16]. In questo modo sono state implementate delle analisi notevoli che mettono in pratica tecniche come la regressione, le reti neurali e gli alberi decisionali, al fine di identificare le caratteristiche che influenzano l'assegnazione della Buy Box.

Per configurare i dati di ingresso alle analisi in Machine Learning, eseguire tali analisi e visualizzarne i risultati graficamente, è stata realizzata un'applicazione Web in Python con la libreria Dash Plotly [S17]. Questa applicazione consente l'esplorazione di diverse configurazioni per le analisi dei dati in Machine Learning, mostrando i risultati di esse in tabelle e grafici notevoli per l'opportuna interpretazione da parte dell'utente.

In [Appendice A](#) è possibile consultare la struttura e i riferimenti del codice sorgente.

2.1 Panoramica del sistema e tecnologie utilizzate

Il sistema è basato su un'architettura containerizzata, dove ogni applicazione è isolata all'interno di un container Docker, garantendo flessibilità e portabilità.




Figura 2.1: Architettura containerizzata in Docker amazon-buy-box

La figura precedente (fig. 2.1) mostra la composizione dell'architettura, con evidenza di tutte le parti che la compongono e le relative tecnologie utilizzate.

Il contenitore denominato `amazon-buy-box-mongodb` contiene il Database NoSQL MongoDB, dove è possibile storicizzare i dati in un formato flessibile basato su documenti.

Grazie all'interfaccia Web dell'istanza Mongo Express in esecuzione nel contenitore denominato `amazon-buy-box-mongo-express`, è possibile gestire il database MongoDB in modo intuitivo e visuale, senza dover utilizzare la linea di comando.

Il contenitore denominato `amazon-buy-box-scrapers` contiene un'applicazione Python in esecuzione schedulata che estrae dati dalle pagine Web di Amazon tramite tecniche di Web Scraping, implementate utilizzando le librerie BeautifulSoup e Selenium. Il processo di scraping viene eseguito ogni ora su un sistema operativo Linux, grazie a un processo `cron` configurato all'interno del contenitore.

I prodotti da analizzare sono raccolti nel database MongoDB, dopo una prima alimentazione a partire da un file CSV ([prodotti.csv](#)), la quale viene eseguita nel caso in cui la collezione `products` sia vuota nel Database MongoDB.

Infine, i dati estratti vengono strutturati in un file JSON e salvati nel database MongoDB nella collezione `scraping` con l'ausilio della libreria PyMongo.

Il contenitore denominato `amazon-buy-box-dashboard` contiene un'applicazione Python in esecuzione che offre un'interfaccia Web, realizzata con la libreria Plotly Dash, tramite la quale si possono scegliere i parametri di input alle analisi eseguibili con algoritmi di Machine Learning, realizzati con la libreria Scikit-Learn. Il risultato delle analisi viene mostrato all'interno della medesima interfaccia in una sezione apposita con opportune tabelle e grafici.

Dopo una breve introduzione a Docker, nei paragrafi seguenti sono illustrati i dettagli riguardo la composizione delle applicazioni suddette, con le tecnologie necessarie per tale realizzazione.

2.2 Introduzione a Docker

Docker [S18] [B6] è una piattaforma che permette di creare e gestire degli ambienti isolati, detti container, in cui eseguire applicazioni; i container contengono tutto ciò di cui un'applicazione ha bisogno per funzionare, dal codice sorgente alle librerie, garantendo così elevate portabilità e riproducibilità.

2.2.1 Vantaggi dell'utilizzo di Docker

Docker rivoluziona il modo in cui sviluppiamo e distribuiamo le applicazioni, offrendo un ambiente di esecuzione isolato, portabile e scalabile.

Infatti, grazie a tali caratteristiche si prevengono conflitti tra le diverse dipendenze e si migliora la sicurezza dell'applicazione. Inoltre, si consente di eseguire un'applicazione su qualsiasi piattaforma che supporti Docker, senza la necessità di riconfigurare l'ambiente. Infine si consente di scalare individualmente i componenti di un'applicazione in base alle richieste, ottimizzando l'utilizzo delle risorse.

Grazie alla containerizzazione, ogni componente software viene avvolto in un contenitore autonomo, garantendo la riproducibilità degli ambienti e semplificando la gestione delle dipendenze, risolvendo il problema delle incompatibilità tra le diverse versioni delle librerie e dei tool.

Questa tecnologia accelera significativamente il ciclo di vita dello sviluppo, accelerando e automatizzando i processi di build, test e deployment, tramite l'opportuna integrazione nei flussi di Continuous Integration e Continuous Deployment, migliorando la qualità del software e riducendo il time-to-market.

Inoltre, la standardizzazione promossa da Docker favorisce la collaborazione tra team e la creazione di applicazioni più affidabili e manutenibili.

2.2.2 Docker Compose

Docker Compose [B6] [S19] è uno strumento complementare a Docker che facilita la definizione e la gestione di applicazioni multi-container. Grazie a un semplice file YAML [S20], è possibile descrivere tutti i servizi che compongono un'applicazione, le loro relazioni e le risorse necessarie. Con un singolo comando, Compose avvia e gestisce l'intero stack di applicazioni, semplificando notevolmente lo sviluppo, il testing e il deployment.

L'utilizzo congiunto di Docker e Compose offre un modo efficiente e flessibile per creare e distribuire applicazioni moderne, sia in ambienti locali che in cloud.

I vantaggi dell'utilizzo congiunto di Docker e Compose nell'ambito dello sviluppo software sono molteplici e contribuiscono significativamente a migliorare l'efficienza, la portabilità e la scalabilità delle applicazioni.

In conclusione, Docker e Compose rappresentano una tecnologia fondamentale per lo sviluppo di software moderno, consentendo di creare applicazioni più efficienti, affidabili e scalabili. L'adozione di queste tecnologie è fortemente raccomandata per qualsiasi organizzazione che desideri migliorare la propria capacità di sviluppare e distribuire software in modo rapido e agile.

2.2.3 Immagini Docker

Un'immagine Docker [B6] [S21] può essere definita come una fotografia immutabile di un sistema contenente tutte le dipendenze necessarie per eseguire un'applicazione, che viene utilizzata per creare container, dunque istanze in esecuzione dell'immagine stessa.

Il processo di creazione di un'immagine Docker avviene tramite uno specifico file di testo denominato `Dockerfile` [S22], il quale contiene una serie di istruzioni per assemblare l'immagine a partire da un'immagine base.

La seguente tabella (tab. 2.1) riporta le istruzioni più comunemente usate nella creazione di un'immagine Docker:

Comando	Descrizione
COPY	Copia file e directory dall'host locale nell'immagine
RUN	Esegue comandi all'interno dell'immagine
EXPOSE	Espone le porte del container all'esterno
CMD	Specifica il comando da eseguire quando il container viene avviato

Tabella 2.1: Istruzioni `Dockerfile` comuni

2.2.4 Volumi Docker

I volumi Docker [B6] [S23] rappresentano un meccanismo fondamentale per la gestione persistente dei dati all'interno di un ambiente containerizzato, infatti essi consentono di separare i dati dalle immagini Docker, garantendo una maggiore flessibilità, sicurezza e facilità di gestione.

Un volume Docker è sostanzialmente una directory speciale che viene creata al di fuori del filesystem dell'immagine: quando un volume viene montato all'interno di un container, le modifiche apportate ai dati all'interno di quel volume vengono scritte direttamente sul disco, garantendo la persistenza. Pertanto, l'utilizzo dei volumi è essenziale quando si fa uso di database containerizzati in Docker, in quanto garanti della persistenza, della sicurezza e della gestibilità dei dati.

2.3 Composizione nell'architettura Docker di progetto

Specificatamente all'architettura containerizzata precedentemente introdotta, si utilizza una composizione di container Docker mediante Docker Compose. Come si può notare nel file [compose.yaml](#), l'architettura è realizzata mediante la composizione di quattro servizi e un volume, che sono illustrati nei paragrafi seguenti.

2.3.1 Servizio mongodb

Il servizio `mongodb` utilizza l'immagine `mongo:latest` [S24] per istanziare un contenitore per il Database MongoDB, componendo l'immagine `amazon-buy-box-mongodb`. Per la configurazione del Database vengono definite delle opportune variabili d'ambiente per l'utente e la password di accesso ad esso, nonché il volume da utilizzare per la persistenza dei dati e le porte da esporre per l'opportuna comunicazione con gli altri contenitori.

2.3.2 Volume mongo-data

Il volume `mongo-data` identifica il volume utilizzato dal servizio `mongodb` per la persistenza dei dati. In questo caso il driver di tipo `local` indica che il volume verrà creato e gestito localmente sulla macchina `host`, ossia la macchina che gestisce la virtualizzazione Docker.

2.3.3 Servizio mongo-express

Il servizio `mongo-express` utilizza l'immagine `mongo-express:latest` [S25] per istanziare un contenitore per la piattaforma Web Mongo Express, per la quale vengono definite le variabili d'ambiente utili alla configurazione della connessione all'istanza del Database MongoDB e la porta esposta localmente per l'accesso alla suddetta piattaforma.

2.3.4 Servizio scraper

Il servizio `scraper` prevede la costruzione o `build` dell'immagine Docker a partire dal contesto nel quale è posizionato il codice sorgente, cioè l'insieme dei file di configurazione nella radice e degli script Python nel package `data_extraction`, e l'esecuzione delle istruzioni contenute nel file [Dockerfile.scraper](#).

In particolare, tale `Dockerfile` contiene le istruzioni elencate nella tabella seguente (tab. 2.2):

#	Dettaglio istruzione
1	Si utilizza l'immagine <code>python:3.12</code> [S26] per istanziare un contenitore che contiene un ambiente Unix semplificato con tutto il necessario per eseguire applicazioni scritte in Python con la versione 3.12
2	Si configura l'ambiente Python installando le librerie necessarie indicate nel file requirements.scraper.txt
3	Si configura il Web Browser Firefox [S27] nell'ambiente Unix per consentire agli script Python dell'immagine di eseguire le tecniche di Web Scraping
4	Si copia nell'ambiente il codice sorgente degli script Python contenuti nel package <code>data_extraction</code> e lo script di <code>crontab</code> per l'esecuzione schedulata degli stessi
5	Si esegue il comando <code>CMD ["cron", "-f"]</code> come processo principale del contenitore

Tabella 2.2: Elenco istruzioni Dockerfile.scraper

2.3.5 Servizio dashboard

Il servizio `dashboard` prevede la costruzione o `build` dell'immagine Docker a partire dal contesto nel quale è posizionato il codice sorgente, cioè l'insieme dei file di configurazione nella radice e degli script Python nel package `data_analysis`, e l'esecuzione delle istruzioni contenute nel file [Dockerfile.dashboard](#).

In particolare, tale `Dockerfile` contiene le istruzioni elencate nella tabella seguente (tab. 2.3):

#	Dettaglio istruzione
1	Si utilizza l'immagine <code>python:3.12</code> [S26], come per il servizio <code>scraper</code>
2	Si configura l'ambiente Python installando le librerie necessarie indicate nel file requirements.dashboard.txt
3	Si copia nell'ambiente il codice sorgente degli script Python contenuti nel package <code>data_analysis</code>
4	Si espone la porta 8082 del contenitore
5	Si esegue il comando <code>CMD ["python", "data_analysis/scripts/amazon_layout_dashboard.py"]</code> come processo principale del contenitore

Tabella 2.3: Elenco istruzioni Dockerfile.dashboard

2.4 Conclusioni sull'architettura

Quanto finora discusso evidenzia la composizione del sistema realizzato ad un alto livello di astrazione. Sono state messe in risalto l'architettura complessiva e le tecnologie che hanno reso possibile la sua realizzazione, nonché i dettagli relativi alle istruzioni di composizione delle singole applicazioni.

Nei capitoli seguenti si approfondiranno tali applicazioni, entrando nel dettaglio delle implementazioni e delle tecnologie utilizzate, seguendo passo passo le fasi di studio e di implementazione introdotte all'inizio di questo capitolo.

3 Campionamento dei dati tramite Web Scraping

La prima fase di fondamentale importanza è la raccolta dei campioni, che saranno utili alle analisi successive. A tal uopo si è sviluppato un meccanismo automatizzato per la raccolta dei dati da Amazon tramite opportune tecniche di Web Scraping.

In questo capitolo, dopo una breve introduzione al Web Scraping, saranno illustrati i dettagli relativi al processo di campionamento, in particolare quali sono i prodotti da analizzare e le caratteristiche di questi e dei loro venditori, le tecniche utilizzate per l'estrazione dei dati, con i relativi dettagli implementativi nell'ambito della realizzazione dell'immagine `amazon-buy-box-scraper`.


3.1 Introduzione al Web Scraping

La tecnica del Web Scraping o “Web Data Extraction” [B4] è utilizzata per estrarre dati da una pagina web o dalla risposta ottenuta dall'invocazione di un'API utilizzando dei programmi software.

I dati estratti dal Web possono essere utilizzati per molteplici scopi, come ad esempio comparare i prezzi esposti dai siti di e-commerce o effettuare ricerche statistiche più complesse, strutturando tali dati raccolti e salvandoli in database locali.

Grazie alla grande mole di dati disponibile online, si possono reperire campioni utili ad analisi statistiche che possono mettere in evidenza caratteristiche e comportamenti notevoli.

Nel caso di Amazon, la pagina Web che mostra un prodotto in vendita presenta una moltitudine di informazioni che possono essere estratte, come si può notare dalla figura seguente (fig. 3.1):



The screenshot displays the Amazon product page for the MACOM Just Kitchen 884 Professional Pizza Oven. The main image shows the oven with a pizza being cooked inside. Below the main image are several smaller images showing different views and features of the oven. The product title is "MACOM Just Kitchen 884 Professional Pizza Oven, Forno Pizza Professionale, Cuoce in 2 minuti, scalda fino a 400°, Piano cottura in pietra refrattaria da 32 cm rimovibile, 1700W". The price is 226.99 €, with a 13% discount from the original price of 259.99 €. The page also shows the delivery options, including Prime delivery and the availability of the product.

Scorri sopra l'immagine per ingrandirla

MACOM Just Kitchen 884 Professional Pizza Oven, Forno Pizza Professionale, Cuoce in 2 minuti, scalda fino a 400°, Piano cottura in pietra refrattaria da 32 cm rimovibile, 1700W

Visita lo Store di MACOM

4,3 ★★★★★ 172 voti

Scegli Amazon

400+ acquistati nel mese scorso

-13% 226.99 €

Prezzo consigliato: 259.99 €

Resi GRATUITI

I prezzi degli articoli in vendita su Amazon includono l'IVA. In base all'indirizzo di spedizione, l'IVA potrebbe variare durante il processo di acquisto. Per maggiori informazioni clicca qui.

Acquista subito e paga a rate con Cofidis al check-out Scopri di più

Marchio MACOM

Colore Stainless Steel

Dimensioni del prodotto 46P x 43L x 28,5H cm

Caratteristica speciale Piano cottura in pietra refrattaria

Tipo di controllo Controllo tramite pulsanti

Potenza in watt Materiale

Si, voglio la consegna GRATUITA

Iscriviti a Prime - GRATIS 30 giorni!

Scopri prime

226.99 €

Resi GRATUITI

Consegna GRATUITA giovedì, 14 novembre. Ordina entro 52 min. Maggiori informazioni

Consegna a Modena 41125: aggiorna luogo

Disponibilità immediata

Quantità: 1

Aggiungi al carrello

Acquista ora

Spedizione Amazon

Venditore Amazon

Resi Restituibile fino al 31 gennaio 2025

Supporto Assistenza prodotti inclusa

Figura 3.1: Pagina Web Amazon - prodotto Forno Pizza

Infatti, possiamo notare la presenza di alcune informazioni di particolare interesse, come ad esempio il prezzo del prodotto, il prezzo di spedizione, il venditore e lo spedizioniere.

Tramite opportune tecniche di Web Scraping è possibile simulare la navigazione delle pagine Web, come quella mostrata precedentemente, esplorare il codice HTML della pagina stessa e individuare gli elementi che contengono il patrimonio informativo da campionare e analizzare.

In Python esistono una moltitudine di librerie utili ad attuare tecniche di Web Scraping, grazie alle quali si possono realizzare dei software di estrazione molto potenti. Tuttavia, data la mutabilità frequente di determinate pagine Web, è necessario aggiornare frequentemente il codice realizzato per far fronte alle evoluzioni che possono occorrere o quantomeno dotarlo di opportuni meccanismi di fallback che consentano di esplorare varie opzionalità.

Nella realizzazione dello `scraper` sono state utilizzate le librerie in Python per il Web Scraping elencate nella seguente tabella (tab. 3.1):

Nome Libreria	Versione	Descrizione
BeautifulSoup	4.12.3	Consente di effettuare un parsing su codice HTML e XML estratto da una pagina Web
Selenium	4.21.0	Simula il comportamento di un utente sul browser e consente di accedere ai contenuti navigati

Tabella 3.1: Librerie in Python utilizzate per il Web Scraping

3.1.1 BeautifulSoup

BeautifulSoup [S9] è una libreria Python progettata per analizzare, navigare e modificare documenti in HTML e XML. Essa è pensata per semplificare il processo di estrazione di dati da pagine Web, con la possibilità di interagire con il contenuto del documento HTML/XML in analisi.

Grazie alle funzionalità offerte da tale libreria, è possibile compiere diverse azioni, le cui principali sono elencate nella seguente tabella (tab. 3.2):

Azione	Descrizione
Parsing di documenti	Trasformazione del codice sorgente di una pagina web, basato su una vasta gamma di formati di documenti, inclusi HTML, XML e altri formati basati su XML, in un albero di oggetti Python, rendendo facile l'accesso e la manipolazione dei singoli elementi

Navigazione nell'albero del documento	Navigazione semplice tra i diversi elementi dell'albero del documento che è stato elaborato, come tag, attributi e testo, consentendo di identificare e estrarre le informazioni desiderate in modo preciso
Selezione di elementi	Estrazione di dati specifici da una pagina web in modo efficiente tramite una varietà di metodi per selezionare gli elementi desiderati, basandosi su tag, attributi, testo o combinazioni di questi
Modifica del documento	Aggiunta, rimozione o modifica di elementi, permettendo di creare nuovi documenti HTML o XML a partire da quelli esistenti

Tabella 3.2: Azioni offerte dalla libreria BeautifulSoup

Tale libreria può essere utilizzata sinergicamente con altre per realizzare algoritmi di Web Scraping complessi; ad esempio, sfruttando le caratteristiche della libreria Selenium, i cui dettagli sono illustrati nel prossimo paragrafo, è possibile simulare una navigazione su una pagina Web ed estrarre le informazioni di interesse proprio tramite la libreria BeautifulSoup, con la quale si può elaborare il codice HTML recuperato dalla pagina, si possono individuare i tag specifici, tramite gli attributi `id` che li identificano univocamente, e si possono estrarre le informazioni in essi contenute.

3.1.2 Selenium

Selenium [S10] è un potente framework open-source, ampiamente utilizzato nel settore dell'Ingegneria del Software, per automatizzare le interazioni con browser web. Esso consente di simulare l'azione di un utente reale, permettendo di eseguire test funzionali, estrarre dati da siti web e automatizzare altre attività che richiedono l'interazione con un'interfaccia utente grafica.

Selenium supporta una vasta gamma di browser, tra cui Chrome, Firefox, Edge e Safari. Tale flessibilità consente di eseguire test su diverse piattaforme e di verificare la compatibilità delle applicazioni web con diversi motori di rendering.

Inoltre, esso supporta diversi linguaggi di programmazione, tra cui Java, Python, C# e JavaScript, offrendo una soluzione versatile per la creazione di script personalizzati e complessi che consentano di automatizzare attività che vanno oltre semplici interazioni con elementi web.

Per quanto riguarda l'interazione con elementi web, Selenium permette di individuare e manipolare con precisione qualsiasi elemento presente all'interno di una pagina web, grazie all'utilizzo di selettori CSS o XPath. Infatti, è possibile selezionare diverse tipologie di elementi web, quali pulsanti, campi di testo, link, tabelle e altro, e simulare azioni come cliccare, digitare, selezionare e trascinare elementi.

Ciò è reso possibile grazie a due componenti fondamentali, descritti nella seguente tabella (tab. 3.3):

Componente	Descrizione
WebDriver	Gestisce l'interazione con il browser supportando quelli più utilizzati (quali Chrome, Firefox, Edge); è la componente padre che contiene tutti i metodi principali di interazione con il browser
WebElement	Sottoinsieme di WebDriver che gestisce l'interazione con gli elementi di una pagina Web, cioè i singoli tag HTML

Tabella 3.3: Componenti fondamentali di Selenium

Selenium è divenuta presto una libreria molto popolare, grazie alla possibilità di automatizzare navigazioni web. A conseguenza di ciò, sono stati introdotti dei plugin online i quali, installati direttamente nei browser, consentono di registrare l'attività utente sul browser stesso e replicare le medesime azioni. Ciò è di notevole utilità nell'ambito dei test automatici di piattaforme Web.

Inoltre, offre la notevole funzionalità di interagire con piattaforme Web che utilizzano JavaScript, dando la possibilità di eseguire codice JavaScript personalizzato per le proprie esigenze. Tale funzionalità rende Selenium lo strumento più completo per effettuare Web Scraping.

3.2 Campionamento dei prodotti su Amazon

Al fine di realizzare un'analisi il più possibile completa e flessibile, è necessario scegliere opportunamente una varietà di prodotti venduti su Amazon, anche di categorie diverse. Dunque, si è scelta la lista di prodotti riportata nella tabella di seguito (tab. 3.4), poi raccolta in un file CSV denominato [prodotti.csv](#) che riporta per ogni prodotto un nome semplificato e l'URL della corrispettiva vetrina su Amazon.

Categoria	Prodotto
Elettronica > Cellulari e accessori	<i>Miracase Porta Cellulare Auto, [Livello Militare Aspirazione Affidabile] Supproto Telefono Auto Universale, Per il Cruscotto & Bocchette di Aerazione E Parabrezza Adatto a Tutti Smartphone</i>
Videogiochi	<i>Trust Gaming GXT 415 Zirox Cuffie Gaming Leggere con Driver da 50 mm per PC, Xbox, PS4, PS5, Switch, Mobile, Jack Audio 3.5 mm, Cavo 2m, Cuffie con Microfono Over-Ear - Nero</i>
Elettronica	<i>Tapo C200 Telecamera Wi-Fi Interno FHD, Videocamera</i>

> Foto e videocamere	<i>sorveglianza, Visione Notturna, 360° Visuale, Audio Bidirezionale, Rilevamento di movimento e notifiche, Allarme acustico e luminoso integrato</i>
Alimentari e cura della casa	<i>200 CAPSULE POP CAFFE' E-MIO 2 CREMOSO COMPATIBILI LAVAZZA A MODO MIO</i>
Salute e cura della persona > Vitamine, minerali e integratori	<i>Supradyn Magnesio e Potassio Integratore Multivitaminico con Vitamine B, Vitamina C e Sali Minerali per Stanchezza, Caldo e Sport, 24 Bustine Effervescenti Senza Zucchero, Gusto Arancia</i>
Informatica	<i>Kingston Canvas Select Plus SDCS2/64GB Scheda microSD Classe 10 con Adattatore SD Incluso, 64 GB</i>
Salute e cura della persona > Pulizia e cura della casa	<i>INSETTICIDA BAYER SOLFAC GEL LIQUIDO SCARAFAGGI 20G BLATTE VELENO INSETTI</i>
Salute e cura della persona > Pulizia e cura della casa	<i>Autan Active Vapo Bipacco, Insetto Repellente e Antizanzare, Lunga Durata, 2 Confezioni da 100 ml³</i>
Casa e cucina	<i>MACOM Just Kitchen 884 Professional Pizza Oven, Forno Pizza Professionale, Cuoce in 2 minuti, scalda fino a 400°, Piano cottura in pietra refrattaria da 32 cm rimovibile, 1700W</i>
Prima infanzia	<i>TIPPY PAD dispositivo anti abbandono, multicolore</i>
Auto e moto	<i>Osram ORIGINAL H7, lampadina alogena per fari, 64210, 12V, scatola pieghevole (1 lampadina) [Classe di efficienza energetica A]</i>
Fai da te	<i>REFLEXX R78 / M Guanti senza nitrili in polvere, medio, nero, confezione da 100</i>
Giochi e giocattoli	<i>RUBIK'S, SPIN MASTER, Il Cubo di Rubik's Classico 3X3, l'Originale, per bambini dagli 8+, Rompicapo Professionale a combinazione di colori, problem-solving</i>

Tabella 3.4: Lista dei prodotti scelti per le analisi

Inoltre, per il campionamento bisogna tener conto del periodo di osservazione in cui esso viene eseguito; infatti, raccogliere dati per lo stesso prodotto in periodi di tempo diversi consente di individuare le variazioni sul prodotto stesso e sui venditori che influenzano l'assegnazione della Buy Box.

Pertanto si è deciso di raccogliere campioni ad ogni ora del giorno per un periodo di tempo che va dal 9 Settembre 2024 al 31 Dicembre 2024, incrociandosi con alcune iniziative commerciali,

³ Inserito nella lista dei prodotti a partire dal 21/12/2024, in modo da integrare delle osservazioni con almeno tre venditori per la categoria "Salute e cura della persona > Pulizia e cura della casa", in quanto il precedente prodotto nel corso del tempo ha visto il decremento del numero di venditori disponibili.

come il periodo del Black Friday dal 21 Novembre 2024 al 2 Dicembre 2024, come annunciato da Amazon e riportato dai media [S28], e il periodo delle festività natalizie.

Per la realizzazione di tale schedulazione è stato impiegato uno script di `crontab` [S29] il quale ogni ora esegue lo script Python [amazon_data_extraction.py](#) adibito a punto di ingresso per l'avvio del processo di campionamento ed estrazione dati da Amazon.

Il processo di estrazione dei dati e di scraping degli stessi è illustrato nel seguente diagramma di flusso (fig. 3.2) che ne evidenzia le operazioni fondamentali.




Figura 3.2: Diagramma di flusso Campionamento dei prodotti da Amazon

La prima operazione è la lettura dal Database MongoDB della lista dei prodotti da analizzare, eventualmente alimentando per la prima volta la relativa collezione `products` nel caso in cui

proprio quest'ultima sia vuota, a partire dal file CSV recuperato dal filesystem. Successivamente, per ognuno dei prodotti, si esegue l'operazione di Web Scraping della pagina web del prodotto invocando opportunamente la funzione `scrape_product` dello script Python [amazon_scraper.py](#). Tale funzione recupera da Amazon la pagina HTML del prodotto tramite le librerie Selenium e BeautifulSoup per poi, tramite delle funzioni di utilità raccolte negli script [amazon_scraping_functions.py](#) e [amazon_utils.py](#), effettuare le opportune operazioni di individuazione delle informazioni essenziali alle analisi.

La raccolta di questi dati termina con la scrittura di un file JSON strutturato nel filesystem e il conseguente salvataggio del documento relativo nel Database MongoDB nella collezione `scraping`. Le operazioni di lettura e salvataggio sul Database MongoDB sono centralizzate in funzioni esposte dallo script [amazon_mongo.py](#), che vengono opportunamente chiamate dagli script sopracitati per le interazioni necessarie con il Database.

La seguente figura (fig. 3.3) riassume quanto illustrato, mettendo in evidenza le operazioni e le relazioni tra le componenti in gioco:




Figura 3.3: Processo di campionamento dei prodotti da Amazon

3.3 Caratteristiche raccolte

Lo studio preliminare della piattaforma di Amazon è di fondamentale importanza per individuare quali sono le caratteristiche utili da estrarre tramite le tecniche di Web Scraping.

Infatti, a partire da una pagina web comune di un prodotto in vendita, occorre analizzare in prima battuta ciò che il Web Browser mostra all'utente, navigando manualmente il codice sorgente HTML tramite gli opportuni strumenti per sviluppatori, messi a disposizione dal browser stesso.

La seguente figura (fig. 3.4) mostra come appare una pagina Web di un prodotto in vendita su Amazon e come, tramite gli strumenti per sviluppatori, si possano individuare i tag HTML relativi alla pagina navigata.




Figura 3.4: Pagina Scheda SD [S30] con dettaglio del codice HTML

Per l'analisi che concerne l'assegnazione della Buy Box, occorre analizzare la pagina del prodotto dove vengono esposti i diversi venditori che lo offrono; come si evince dalla pagina del

prodotto (fig. 3.4), occorre cliccare il link esposto sotto la voce “Altri venditori su Amazon” e navigare la spalla destra che si apre al momento del click (fig. 3.5).




Figura 3.5: Pagina Scheda SD [S30] con spalla Buy Box e altri venditori con dettaglio del codice HTML

In questa pagina si possono individuare una moltitudine di informazioni che riguardano sia il venditore vincitore della Buy Box che chi non l’ha vinta ma si attesta tra le prime opzioni suggerite. Dunque, il passo successivo è quello di individuare singolarmente le caratteristiche da raccogliere a partire dall’HTML estratto dalle pagine dei prodotti come quella sopra, mediante le tecniche di Web Scraping approfondite nei prossimi paragrafi, per le quali sono implementate delle funzioni notevoli in Python atte ad estrarre i singoli dati.

Il risultato dell’operazione di estrazione dati è un file in formato JSON, di cui se ne riporta un esempio in [Appendice B](#) con il file [result_example.json](#), il quale comprende, per tutti i prodotti scelti per l’analisi, i dati principali del prodotto e quelli specifici, fondamentali per l’analisi, dei venditori, distinti nelle categorie vincitore della Buy Box e non vincitore.

La tabella di seguito (tab. 3.5) riporta le caratteristiche che sono oggetto di raccolta e di analisi:

Caratteristica	Descrizione	Acq. o Ric.
Nome Prodotto	Nome del Prodotto	Acquisito
Nome Venditore	Nome del Venditore	Acquisito
Nome Spedizioniere	Nome dello Spedizioniere	Acquisito
Prezzo Prodotto	Prezzo effettivo del prodotto al netto della spedizione	Acquisito
Prezzo Spedizione	Prezzo di spedizione del prodotto	Acquisito
Prezzo Totale	Somma tra il prezzo del prodotto e il prezzo di spedizione	Ricavato
Giorni consegna	Determina la stima di quando il prodotto verrà consegnato al cliente	Acquisito
Numero di valutazioni Prodotto	Numero di recensioni dei clienti per il prodotto	Acquisito
Numero di valutazioni Venditore	Numero di recensioni dei clienti per il venditore	Acquisito
Media valutazioni Venditore	Media delle valutazioni dei clienti da 0 a 5 stelle per il venditore	Acquisito
Percentuale valutazioni positive Venditore	Rappresenta la percentuale di valutazioni positive negli ultimi 12 mesi per il venditore	Acquisito
Nuovo Venditore	Indica se il Venditore è nuovo su Amazon	Acquisito
FBA	Determina se il venditore aderisce o meno alla programma di logistica di Amazon	Ricavato
Amazon come venditore	Verifica se il venditore è Amazon	Ricavato
Differenza prezzo totale da Buy Box winner	Differenza del prezzo totale del prodotto da quello del vincitore della Buy Box	Ricavato
Differenza prezzo prodotto da Buy Box winner	Differenza del prezzo del solo prodotto da quello del vincitore della Buy Box	Ricavato
Differenza prezzo spedizione da Buy Box winner	Differenza del prezzo della sola spedizione da quello del vincitore della Buy Box	Ricavato
Buy Box Winner	Indica se il venditore ha vinto il buy box	Ricavato

Tabella 3.5: Caratteristiche raccolte per l'analisi dell'assegnazione della Buy Box

La seguente figura (fig. 3.6) riporta l'estratto della spalla delle opzioni di acquisto di un prodotto dalla quale si acquisiscono e si ricavano le informazioni di cui la precedente tabella, con il dettaglio della relazione tra i campi sopra e gli elementi individuabili nella pagina:

VINCITORE BUY BOX



Kingston Canvas Select Plus SDCS2/64GB Scheda micro...

★★★★★ 177.774 voti

Nuovo

-19% **8¹⁰€**

Prezzo consigliato: 9,99€ ⓘ

Consegna **GRATUITA 5 - 6 dicembre.** [Maggiori informazioni](#)

Prezzo spedizione

Nome prodotto

Numero Valutazioni prodotto

Prezzo prodotto

[Aggiungi al carrello](#)

Giorni consegna

Spedito da

Venditore

Media Valutazioni Venditore

Percentuali Valutazioni positive Venditore

FLASH SALE 2024

FLASH SALE 2024

★★★★★ (1929 valutazioni)

90% positive negli ultimi 12 mesi

Nome Spedizioniere

Nome Venditore

Numero Valutazioni Venditore

Mostra meno

124 opzioni

ordinati per totale (prezzo + spedizione): dal più basso al più alto

[Nuovo](#) [Filtra \(1\)](#) [Cancella tutto](#)

ALTRO VENDITORE 1

Nuovo

-19% **8¹⁰€**

Prezzo consigliato: 9,99€ ⓘ

Consegna **GRATUITA giovedì, 5 dicembre** sul tuo primo ordine

[Aggiungi al carrello](#)

Prezzo prodotto

Prezzo spedizione

Giorni consegna

Spedito da

Venditore

Media Valutazioni Venditore

Percentuali Valutazioni positive Venditore

Amazon

RUIXIN STORE ITALY

★★★★★ (33 valutazioni)

97% positive negli ultimi 12 mesi

Nome Spedizioniere

Nome Venditore

Numero Valutazioni Venditore

ALTRO VENDITORE 2

Nuovo

-19% **8¹⁰€**

Prezzo consigliato: 9,99€ ⓘ

Consegna **GRATUITA 5 - 6 dicembre.** [Maggiori informazioni](#)

[Aggiungi al carrello](#)

Spedito da

Venditore

FLASH SALE 2024

FLASH SALE 2024

★★★★★ (1929 valutazioni)

90% positive negli ultimi 12 mesi

Figura 3.6: Spalla delle opzioni di acquisto per il prodotto Scheda SD [S30] - Evidenze dei campi da acquisire

3.3.1 Funzioni di estrazione dati

Sia per il vincitore della Buy Box, che per gli altri venditori esposti, sono realizzate delle funzioni in Python che estraggono le caratteristiche illustrate precedentemente a partire dall'albero di oggetti elaborato con BeautifulSoup dall'HTML della pagina di Amazon del prodotto.

Tali funzioni, come già accennato, individuano nell'albero suddetto i dati specifici per i quali sono state realizzate, attraverso le funzioni offerte dalla libreria BeautifulSoup, come `find` e `findall`, e l'indicazione degli attributi HTML corrispondenti, come `id` (identificativo del tag) o `class` (classe di stile CSS), o l'eventuale XPath che individua univocamente l'elemento da estrarre.

La tabella di seguito (tab. 3.6) mostra il riferimento tra le caratteristiche da estrarre e le relative funzioni di estrazione raccolte nel file [amazon_scraping_functions.py](#).

Caratteristica	Funzione Python
Nome Venditore	<code>get_seller_name</code>
Nome Prodotto	<code>get_product_name</code>
Nome Spedizionario	<code>get_seller_fba</code>
Prezzo Prodotto	<code>get_price_element</code>
Prezzo Spedizione	<code>get_seller_shipping_price</code>
Giorni consegna	<code>get_seller_shipping_days</code>
Numero di valutazioni Prodotto	<code>get_product_num_ratings</code>
Numero di valutazioni Venditore	<code>get_seller_num_ratings</code>
Media valutazioni Venditore	<code>get_seller_avg_ratings</code>
Percentuale valutazioni positive Venditore	<code>get_seller_perc_positive_ratings</code>
Nuovo Venditore	<code>get_seller_flag_new</code>

Tabella 3.6: Caratteristiche da raccogliere per le analisi e funzioni di estrazione

All'elenco precedente occorre aggiungere le operazioni che calcolano alcuni dati notevoli a partire dalle caratteristiche raccolte, come evidenziato nella tabella di seguito (tab. 3.7):

Caratteristica	Operazione di calcolo
Prezzo Totale	Prezzo Prodotto + Prezzo Spedizione
FBA	True se Nome Spedizioniere è “Amazon”, False altrimenti
Amazon come venditore	True se Nome Venditore è Amazon (o relativi), False altrimenti
Differenza prezzo da Buy Box winner	Prezzo Totale(X) - Prezzo Totale(BB) con X altro venditore in esame e BB il vincitore della Buy Box
Differenza prezzo da Buy Box winner (solo prodotto)	Prezzo Prodotto(X) - Prezzo Prodotto(BB) con X altro venditore in esame e BB il vincitore della Buy Box
Differenza prezzo da Buy Box winner (solo spedizione)	Prezzo Spedizione(X) - Prezzo Spedizione(BB) con X altro venditore in esame e BB il vincitore della Buy Box
Buy Box Winner	True se è stato estratto dal Venditore nella sezione della Buy Box (index == 0)

Tabella 3.7: Caratteristiche ricavate per l’analisi e operazioni di calcolo

3.4 Scrittura dei campioni

I risultati del campionamento per prodotto e per data di osservazione vengono raccolti in maniera strutturata su un dizionario; una volta iterati tutti i prodotti, si ottiene infine una lista di dizionari, che viene salvata in un file JSON, come quello riportato in [Appendice B](#) con il nome [result_example.json](#). Gli elementi della lista, cioè i singoli dizionari, vengono poi persistiti in documenti sul Database MongoDB, centralizzato nel sistema in modo da condividere le informazioni con tutti gli altri attori.

La scrittura sul Database avviene per mezzo dello script Python [amazon_mongo.py](#), il quale utilizza la libreria PyMongo per interagire con il Database MongoDB e operare le opportune operazioni di lettura e scrittura.

Come si evince dalle seguenti figure, tramite la piattaforma Mongo Express inclusa nel sistema, è possibile consultare gli elementi persistiti nel Database, in particolare quelli presenti nella collezione `scraping` adibita a contenere i dati estratti da Amazon (fig. 3.7) e nella collezione `products` adibita a contenere i prodotti di cui estrarre i dati (fig. 3.8):

Mongo Express Database: amazon-buybox -> Collection: scraping

Viewing Collection: scraping

[New Document](#) [New Index](#)

Simple Advanced

Key Value String Find

Delete all 22248 documents retrieved

1 2 3 4 5 > >>

_id	name	url	datetime_extraction	data
  66de0d44917820b2f092a4b9	PORTA CELLULARE AUTO	https://www.amazon.it/dp/B0C273FR2T/ref=olp-opf-redir?ad=1&ie=UTF8&condition=NEW	2024-09-08 20:44:47	<pre>{ "product": @{2 items}, "buybox_seller": @{6 items}, "other_sellers": @{5 items} }</pre>
  66de0d44917820b2f092a4ba	CUFFIE GAMING	https://www.amazon.it/dp/B0C94KNS8D/ref=olp-opf-redir?ad=1&ie=UTF8&condition=NEW	2024-09-08 20:44:47	<pre>{ "product": @{2 items}, "buybox_seller": @{6 items}, "other_sellers": @{10 items} }</pre>

Figura 3.7: Mongo Express - Dettaglio della visualizzazione della collezione `scraping`

Mongo Express Database: amazon-buybox -> Collection: products

Viewing Collection: products

[New Document](#) [New Index](#)

Simple Advanced

Key Value String Find

Delete all 13 documents retrieved

1

_id	id	name	link
  67668a9c58267dc88300a462	1	PORTA CELLULARE AUTO	https://www.amazon.it/dp/B0C273FR2T/ref=olp-opf-redir?ad=1&ie=UTF8&condition=NEW
  67668a9c58267dc88300a463	2	CUFFIE GAMING	https://www.amazon.it/dp/B0C94KNS8D/ref=olp-opf-redir?ad=1&ie=UTF8&condition=NEW
  67668a9c58267dc88300a464	3	TELECAMERA	https://www.amazon.it/dp/B07XLML2YS/ref=olp-opf-redir?ad=1&ie=UTF8&condition=NEW
  67668a9c58267dc88300a465	4	CAPSULE CAFFE'	https://www.amazon.it/dp/B07JPJCY2/ref=olp-opf-redir?ad=1&ie=UTF8&condition=NEW
  67668a9c58267dc88300a466	5	INTEGRATORE ALIMENTARE	https://www.amazon.it/dp/B07Q7WZ5R2/ref=olp-opf-redir?ad=1&ie=UTF8&condition=NEW
  67668a9c58267dc88300a467	6	SCHEDA MICRO SD	https://www.amazon.it/dp/B07YGZQ4H8/ref=olp-opf-redir?ad=1&ie=UTF8&condition=NEW

Figura 3.8: Mongo Express - Dettaglio della visualizzazione della collezione `products`

4 Analisi dei dati con algoritmi di Machine Learning

Una volta acquisito l'insieme di campioni sufficiente da Amazon, si procede con un'elaborazione accurata dei dati che include: lettura, filtro, trasformazione e normalizzazione. Successivamente, si applicano algoritmi di Machine Learning per costruire modelli predittivi di classificazione per estrarre le caratteristiche più influenti nell'assegnazione della Buy Box da parte di Amazon.

La seguente figura (fig. 4.1) illustra il processo che orchestra le operazioni suddette:




Figura 4.1: Processo di lettura, normalizzazione dei dati e applicazione degli algoritmi di Machine Learning

Inizialmente si leggono i dati raccolti nel Database MongoDB tramite lo script [amazon_data_reader.py](#), il quale utilizza lo script di integrazione [amazon_mongo.py](#) per interfacciarsi con il DB. Successivamente, i dati di ingresso vengono puliti e normalizzati, tramite le funzioni sviluppate nello script [amazon_data_normalizer.py](#), trasformando l'insieme di dati in un DataFrame in Pandas ben strutturato. Infine, su questi dati vengono applicati gli algoritmi di Machine Learning tramite la funzione `exec_ml_analysis` dello script [amazon_ML_analysis.py](#), che incapsula le operazioni di analisi, come illustrato nel diagramma di flusso in figura 4.2.

In particolare, a partire da un classificatore definito nella libreria Scikit-Learn e da un'opportuna tecnica di Cross-Validation per la convalida del modello, si preparano i dati di training e test utili all'addestramento e alla verifica del modello di classificazione.

I risultati di tale processo sono l'insieme delle caratteristiche con la loro relativa importanza, espressa in percentuali⁴, e la misura dell'accuratezza dell'algoritmo di classificazione coinvolto nell'analisi. Nel caso in cui si sia utilizzata una tecnica di Cross-Validation di tipo K-Fold, come si vedrà nei paragrafi seguenti, i risultati suddetti saranno calcolati come le medie dei risultati parziali ottenuti su ogni strato di addestramento e test.

⁴ Più precisamente in valori compresi nell'intervallo $[0, 1]$.




Figura 4.2: Diagramma di flusso esecuzione algoritmo di Machine Learning

In questo capitolo, si approfondisce proprio il processo di analisi dei dati nel dettaglio, dalla preparazione dei dati di addestramento e test all'addestramento e convalida dei modelli di classificazione, includendo dei metodi di Cross-Validation per una stima più robusta delle prestazioni di tale modello.

Inoltre, viene fornita evidenza delle scelte tecniche adottate per stimare e scegliere gli iperparametri ottimali, calcolare le metriche di valutazione e, infine, l'insieme delle caratteristiche con i relativi pesi.

Tali attività sono fondamentali per la realizzazione dell'immagine `amazon-buy-box-dashboard`, dove alimentano il motore decisionale di backend.

4.1 Pre-processamento dei dati

I dati che sono stati recepiti da Amazon con il Web Scraping hanno già subito una prima trasformazione nel momento in cui essi sono stati estratti, infatti sono stati trasformati da dati grezzi contenuti nei tag HTML a dati strutturati, salvati in un file JSON e poi su un documento nel Database MongoDB.

Per analizzare i campioni raccolti, occorre verificare quali di essi possano essere ritenuti validi per l'analisi stessa. Dunque, il primo passo è quello di leggere ed esplorare i dati raccolti, filtrando quelli che presentano un contenuto informativo fallace.

Tra questi, infatti, balzano all'occhio quelli che, per motivi legati a fallimenti dello script di estrazione o a errori infrastrutturali, come ad esempio la temporanea indisponibilità della connessione di rete, presentano un insieme di informazioni nulle, come si evince dal file [result_err_example.json](#) consultabile in [Appendice B](#).

4.1.1 Lettura dei dati da MongoDB

La lettura dei campioni raccolti avviene tramite lo script in Python [amazon_mongo.py](#), adibito all'interazione con il database MongoDB per mezzo della libreria PyMongo; in questo caso offre delle funzioni di lettura dei documenti persistiti nel DB le quali includono la regola base di filtro delle sole osservazioni che contengono un insieme di dati non-nulli. Tale lettura avviene con due parametri di input, che corrispondono alle date di osservazione minima e massima cui focalizzarsi per l'estrazione dei dati, in modo tale da personalizzare la finestra temporale su cui compiere le successive analisi.

Il risultato della lettura da MongoDB è una lista di dizionari, dove ogni dizionario è la singola osservazione per prodotto e data di estrazione.

4.1.2 Trasformazione dei dati

Le funzioni di lettura da MongoDB sono incapsulate e richiamate tramite gli script in Python [amazon_data_reader.py](#) e [amazon_data_normalizer.py](#), i quali forniscono delle funzioni per trasformare la lista di dizionari recepita da MongoDB in un oggetto di tipo DataFrame elaborabile nelle analisi successive.

Nel processo di trasformazione in DataFrame vengono effettuate delle opportune mappature tra le proprietà dei singoli dizionari e le colonne definite del suddetto DataFrame, il quale si presenta come mostrato nella figura seguente (fig. 4.3):

	date	name	buybox	index	seller_name	price_no_shipping	total_price	price_diff_prod	price_diff	seller_index
0	2024-12-01 00:00:02	PORTA CELLULA...	1	1	BODE	11.35000	11.35000	0.00000	0.00000	0.00000
1	2024-12-01 00:00:02	PORTA CELLULA...	0	2	Amazon	17.28000	17.28000	5.93000	5.93000	0.00000
2	2024-12-01 00:00:02	PORTA CELLULA...	0	3	Gambistore	22.99000	22.99000	11.64000	11.64000	0.00000
3	2024-12-01 00:00:02	PORTA CELLULA...	0	4	Amazon UK	24.74000	24.74000	13.39000	13.39000	0.00000
4	2024-12-01 00:00:02	PORTA CELLULA...	0	5	EMRSPTA	29.99000	29.99000	18.64000	18.64000	0.00000
0	2024-12-01 00:00:02	CUFFIE GAMING	1	1	Amazon	15.99000	15.99000	0.00000	0.00000	0.00000
1	2024-12-01 00:00:02	CUFFIE GAMING	0	2	iCOM	23.03000	23.03000	7.04000	7.04000	0.00000
2	2024-12-01 00:00:02	CUFFIE GAMING	0	3	Zanetti Shop	16.91000	23.11000	0.92000	7.12000	6.20000
3	2024-12-01 00:00:02	CUFFIE GAMING	0	4	Bartolucci S.r.l.	23.69000	23.69000	7.70000	7.70000	0.00000
4	2024-12-01 00:00:02	CUFFIE GAMING	0	5	TechInn	23.99000	23.99000	8.00000	8.00000	0.00000
5	2024-12-01 00:00:02	CUFFIE GAMING	0	6	GRANDIN GR...	24.51000	24.51000	8.52000	8.52000	0.00000
6	2024-12-01 00:00:02	CUFFIE GAMING	0	7	DgWeb srl	25.05000	25.05000	9.06000	9.06000	0.00000
7	2024-12-01 00:00:02	CUFFIE GAMING	0	8	TECSTORE24	25.08000	25.08000	9.09000	9.09000	0.00000
8	2024-12-01 00:00:02	CUFFIE GAMING	0	9	Gory's Web S...	25.28000	25.28000	9.29000	9.29000	0.00000
9	2024-12-01 00:00:02	CUFFIE GAMING	0	10	Dagimarket	18.73000	26.05000	2.74000	10.06000	7.32000
10	2024-12-01 00:00:02	CUFFIE GAMING	0	11	officeservicesrl	27.17000	27.17000	11.18000	11.18000	0.00000
0	2024-12-01 00:00:02	TELECAMERA	1	1	Amazon	19.99000	19.99000	0.00000	0.00000	0.00000
1	2024-12-01 00:00:02	TELECAMERA	0	2	ipermercato-o...	32.22000	32.22000	12.23000	12.23000	0.00000
2	2024-12-01 00:00:02	TELECAMERA	0	3	GROOVE TO S...	37.00000	37.00000	17.01000	17.01000	0.00000
3	2024-12-01 00:00:02	TELECAMERA	0	4	ATRIACOM	30.07000	41.06000	10.08000	21.07000	10.99000
4	2024-12-01 00:00:02	TELECAMERA	0	5	Tecno Shop Srl	41.99000	41.99000	22.00000	22.00000	0.00000
5	2024-12-01 00:00:02	TELECAMERA	0	6	Shoppid Mark...	44.00000	44.00000	24.01000	24.01000	0.00000

Figura 4.3: DataFrame delle osservazioni lette dallo storico persistito in MongoDB

Nel dettaglio, la tabella di seguito (tab. 4.1) riporta la sintesi delle mappature tra le proprietà dei singoli dizionari e le colonne del DataFrame, definite opportunamente per contenere le informazioni utili e necessarie alle analisi successive. E' opportuno notare che nella colonna "Proprietà (JSON)" è riportata la dicitura `item` per indicare la singola osservazione, mentre `seller` indica il singolo venditore che può essere iterato a partire da `item["data"]["buybox_seller"]` per il vincitore della Buy Box, oppure da `item["data"]["other_sellers"][i]` per gli altri venditori non vincitori.

Caratteristica	Proprietà (JSON)	Colonna DataFrame
Data Osservazione	<code>item["datetime_extraction"]</code>	<code>date</code>
Nome Prodotto	<code>item["name"]</code>	<code>name</code>
Flag BuyBox (1 se vincente, 0 altrimenti)	<code>'1' se seller["index"] == 0</code> <code>'0' altrimenti</code>	<code>buybox</code>
Indice Venditore	<code>seller["index"]</code>	<code>index</code>
Nome Venditore	<code>seller["name"]</code>	<code>seller_name</code>
Prezzo Prodotto	<code>seller["sale"]</code> <code>["priceNoShipping"]</code>	<code>price_no_shipping</code>
Prezzo Totale	<code>seller["sale"]</code> <code>["totalPrice"]</code>	<code>total_price</code>
Differenza di prezzo prodotto con il	<code>seller["sale"]</code> <code>["diffPriceNoShipping"]</code>	<code>price_diff_prod</code>

vincitore della BuyBox		
Differenza di prezzo totale con il vincitore della BuyBox	seller["sale"] ["diffTotalPrice"]	price_diff
Prezzo Spedizione	seller["shipping"] ["price"]	shipping_price
Giorni Consegna	seller["shipping"] ["days"]	delivery_days
Differenza di prezzo spedizione con il vincitore della BuyBox	seller["shipping"] ["diffPrice"]	price_diff_ship
Numero di recensioni del Venditore	seller["ratings"] ["num"]	ratings_num
Media recensioni del Venditore (da 0 a 5 stelle)	seller["ratings"] ["avg"]	ratings_avg
Percentuale di recensioni positive del Venditore	seller["ratings"] ["perc_positive"]	ratings_perc_positive
FBA (1 se aderisce a FBA, 0 altrimenti)	seller["fba"]	fba
Amazon (1 se il Venditore è Amazon, 0 altrimenti)	"Amazon" in seller["name"]	amazon
Nuovo Venditore	seller["ratings"] ["new"]	new

Tabella 4.1: Mappatura delle caratteristiche dalle proprietà nel dizionario JSON salvato a DB alle colonne del DataFrame utile alle analisi in Machine Learning

4.1.3 Dati mancanti o nulli

Verificando il contenuto del DataFrame ottenuto, si può notare la presenza di osservazioni con dati nulli. Infatti, è opportuno considerare che sia un nuovo venditore che il venditore Amazon presentano i dati relativi alle recensioni nulli, in quanto o non ne hanno ricevute, nel caso di nuovo venditore, o non sono previste di default, nel caso di Amazon.

Pertanto, si è deciso di trattare questi valori nulli come zeri effettivi, tuttavia fornendo l'opzione di filtro di queste casistiche per la fase di analisi, in modo da poter esplorare anche le casistiche più pure.

4.1.4 Normalizzazione dei dati

La normalizzazione dei dati [B5.2] consiste nel trasformare i valori di tutte le caratteristiche in modo che essi adottino la medesima scala, in particolare dei nuovi valori che saranno compresi nell'intervallo $[0, 1]$. In questa condizione, gli algoritmi di classificazione in Machine Learning sono più efficienti e possono operare su dati che preservano la loro interpretabilità e contribuiscono in modo simile ai calcoli degli algoritmi successivi.

Il processo di normalizzazione prevede un diverso trattamento preliminare delle variabili categoriche e numeriche, con quest'ultime che vanno distinte in variabili indipendenti e dipendenti dall'osservazione, per poi prevedere l'applicazione di una funzione di normalizzazione minimo-massimo⁵ che “appiattisce” i dati nell'intervallo $[0, 1]$, con i valori 0 corrispondente al valore minimo e 1 al valore massimo.

Nel caso delle variabili categoriche, come ad esempio il nome del Venditore o la data di osservazione, esse vengono dapprima codificate in valori numerici, tramite il `LabelEncoder` offerto dalla libreria Scikit-Learn, per poi essere normalizzate nell'intervallo $[0, 1]$.

Nel caso delle variabili numeriche, come il prezzo del prodotto o il numero di recensioni, occorre procedere con una normalizzazione che preservi le relazioni e i rapporti di forza all'interno della singola osservazione, senza che vengano influenzate le altre. Per queste variabili dipendenti dall'osservazione è opportuno applicare la funzione di normalizzazione in maniera raggruppata rispetto all'osservazione, identificata dal nome del prodotto e dalla data di estrazione del campione. Le variabili che necessitano di questo tipo di normalizzazione sono le seguenti: `price_no_shipping`, `shipping_price`, `total_price`, `delivery_days`, `ratings_num`, `price_diff_prod`, `price_diff`, `price_diff_ship`.

Per quanto riguarda, invece, le rimanenti variabili numeriche che sono indipendenti dall'osservazione singola, come ad esempio la media delle valutazioni del Venditore, si opera una normalizzazione semplice riportando i dati nell'intervallo prestabilito.

⁵ Nella libreria Scikit-Learn esiste la funzione `MinMaxScaler` per la normalizzazione minimo-massimo, nel lavoro progettuale però si è preferito utilizzare una funzione personalizzata che esegue l'operazione analoga.

4.2 Introduzione al Machine Learning

Il Machine Learning [B5.3] è una branca dell'intelligenza artificiale che si occupa di sviluppare algoritmi in grado di apprendere dai dati, identificare pattern ed effettuare previsioni senza essere esplicitamente programmati per ogni singolo task. In altre parole, il Machine Learning dota i sistemi informatici della capacità di apprendere dai dati, migliorando così le proprie prestazioni nel tempo.

Attraverso i paradigmi di apprendimento supervisionato, non supervisionato e di rafforzamento, gli algoritmi sono in grado di estrarre pattern, fare previsioni e prendere decisioni sempre più accurate.




Figura 4.4: Paradigmi di apprendimento nel Machine Learning [B7]

Come mostrato nella figura precedente (fig. 4.4), i diversi paradigmi di apprendimento producono differenti modelli, ognuno dei quali ha delle sue peculiarità. In questo lavoro, ci si concentra sull'apprendimento supervisionato, in particolare sui modelli di classificazione, per prevedere l'assegnazione della Buy Box di Amazon, sfruttando l'ampio dataset di prodotti e venditori estratto come discusso nel capitolo precedente.

4.2.1 Apprendimento supervisionato

L'apprendimento supervisionato [B5.1] è una tecnica di Machine Learning in cui un algoritmo viene addestrato su un dataset etichettato, ovvero un insieme di dati per i quali è nota la

corrispondenza tra input e output desiderati, cosicché l'algoritmo impari a mappare nuovi input a output precedentemente sconosciuti.

L'obiettivo è costruire un modello in grado di generalizzare all'arrivo di nuovi dati, effettuando previsioni accurate su esempi mai visti in fase di addestramento. Tipici problemi di apprendimento supervisionato (fig. 4.5) sono la classificazione, dove si assegna un'etichetta a un dato (ad esempio, classificare una e-mail come spam o non spam), e la regressione, dove si prevede un valore numerico (ad esempio, prevedere il prezzo di un prodotto in vendita in base alle sue caratteristiche).




Figura 4.5: Apprendimento supervisionato: Classificazione e Regressione [B8]

4.2.2 Scikit-Learn

Scikit-Learn [S16] [B5.2] è una delle librerie Python più popolari e utilizzate per il Machine Learning, grazie alla sua interfaccia semplice e intuitiva, unita alla sua efficienza. Essa offre una vasta gamma di algoritmi di apprendimento supervisionato e non supervisionato, strumenti per la pre-elaborazione dei dati e tecniche di valutazione delle performance dei modelli.

Dato il `DataFrame` di input alle analisi, la libreria Scikit-Learn offre la funzione `train_test_split` per dividere lo stesso in due sottoinsiemi: un insieme di dati di addestramento, utile ad addestrare il modello di classificazione scelto stimandone i parametri, e uno di test, utile a valutare la capacità generalizzante del modello, ovvero la sua abilità di fare previsioni accurate su nuovi dati.

L'operazione di addestramento avviene per mezzo della funzione `fit` la quale stima i parametri del modello di classificazione a partire dai dati di addestramento opportunamente divisi in input e output attesi. Il modello addestrato risultante può applicare la funzione `predict` sull'insieme

degli input di test, restituendo in output dei valori predetti i quali, confrontati con l'insieme degli output di test, forniscono una valutazione della capacità generalizzante del modello.

La figura seguente (fig. 4.6) riassume il processo di addestramento di un modello di classificazione, inclusa la componente di predizione che fornisce in output, oltre ai dati predetti a partire dall'insieme di test, l'indicatore dell'accuratezza del modello, rappresentante una statistica di sintesi fondamentale nella valutazione dello stesso.




Figura 4.6: Processo di addestramento e predizione di un classificatore

4.2.3 Apprendimento d'insieme

L'apprendimento d'insieme o “ensemble learning” [B5.5] è una tecnica potente nell'ambito del Machine Learning che consiste nel combinare più modelli per ottenere migliori prestazioni predittive rispetto a un singolo modello. In pratica, l'idea è quella di "unire le forze" di diversi modelli, sfruttando le loro diverse prospettive per prendere decisioni più accurate e robuste.

Un esempio è l'algoritmo Random Forest che, come si vedrà nei paragrafi a seguire, applica diversi alberi decisionali, realizzati da sottoinsiemi di features e di campioni del dataset di input, per ottenere un singolo risultato predittivo più accurato dell'applicazione di un singolo albero decisionale.

Questo lavoro si può adattare facilmente per sposare in toto la filosofia dell'apprendimento d'insieme, infatti l'applicazione di diversi algoritmi di classificazione su uno stesso dataset di partenza, come si vedrà successivamente, può aiutare ad ottenere diversi punti di vista che può convergere verso un trend comune, mostrando, ad esempio, che alcune caratteristiche sono più influenti di altre.

Rispetto ad un apprendimento d'insieme puro che può prevedere l'implementazione di un classificatore a voto di maggioranza [B5.6], composto da diversi classificatori, in questo lavoro si eseguiranno le analisi o per singolo classificatore o confrontando le esecuzioni dei singoli classificatori, mostrando l'accuratezza media ottenuta e le medie dei pesi delle caratteristiche prese in esame.

4.3 Implementazione dei modelli di Machine Learning

I dati pre-processati e normalizzati sono pronti per essere analizzati con gli opportuni algoritmi di Machine Learning, il cui obiettivo è quello di individuare le caratteristiche, adesso raccolte nel DataFrame di input alle analisi, che influenzano maggiormente l'assegnazione della Buy Box da parte di Amazon.

Il problema, come accennato precedentemente, è di classificazione in due distinte categorie: i vincitori della Buy Box e i non vincitori. Le caratteristiche raccolte hanno dei pesi differenti nella classificazione dei campioni in tali categorie, e proprio l'insieme di questi pesi rappresenta l'incognita che si vuole svelare con questo lavoro.

Nei prossimi paragrafi si illustreranno le tecniche di preparazione degli insiemi di addestramento e di test, con particolare riferimento alle tecniche di convalida del modello di classificazione mediante Cross-Validation. Inoltre, saranno illustrati i differenti algoritmi di classificazione scelti per le analisi con le relative implementazioni in Scikit-Learn e la scelta degli iperparametri ottimali. Infine verrà illustrata la tecnica utile all'estrazione dei pesi delle caratteristiche, obiettivo dell'analisi.

4.3.1 Preparazione degli insiemi di training e test

La fase di preparazione dei dati è di fondamentale importanza per l'esecuzione di un'analisi in Machine Learning. Il primo passo consiste nella suddivisione del DataFrame in input in due parti distinte: un insieme di dati di addestramento o training, utili ad addestrare il modello sulle relazioni tra le caratteristiche di input e di output, e un insieme di dati di verifica o test, utili a valutare le prestazioni del modello su nuovi dati, stimando la sua capacità di generalizzazione a nuovi esempi.

Tale suddivisione può essere effettuata in modo casuale, ma è spesso preferibile utilizzare tecniche di campionamento stratificato, soprattutto quando si ha a che fare con dataset sbilanciati, per garantire che entrambe le parti abbiano una distribuzione simile delle classi.

4.3.2 Convalida del modello tramite Cross-Validation

La Cross-Validation [B5.4] è una tecnica fondamentale per valutare le prestazioni di un modello di Machine Learning e prevenire il fenomeno detto overfitting [B5.2], ovvero l'apprendimento del rumore presente nei dati di addestramento che influenza la generalizzazione a nuovi dati. Tale tecnica consiste nel dividere ripetutamente il dataset in input in diversi sottoinsiemi, utilizzando alternativamente ciascun sottoinsieme come insieme di test e gli altri come insieme di training. In questo modo, si ottengono stime più robuste delle prestazioni del modello rispetto a una singola divisione addestramento/test.

Esistono numerosi metodi di Cross-Validation, ognuno con le sue particolarità e specifiche che li rendono adatti a specifici insiemi di dati di input. Infatti, è possibile scegliere differenti metodi di Cross-Validation dipendentemente dalla dimensione del dataset di input, in base alle performance che si vogliono ottenere dall'addestramento del modello di classificazione.

Nei paragrafi di seguito saranno illustrati alcuni dei metodi di Cross-Validation più noti e adatti per questo lavoro progettuale.

4.3.2.1 Hold-out

Il metodo Hold-out [B5.4] [S59] prevede la suddivisione singola del dataset in input in due parti (fig. 4.7): un set di training e un set di test. La semplicità di implementazione lo rende un metodo che si presta bene per dataset di grandi dimensioni sia per le prestazioni computazionali che per l'utilità nelle prime esplorazioni, tuttavia può portare a stime variabili delle prestazioni del modello a seconda della particolare suddivisione.




Figura 4.7: Metodo di validazione Hold-out [S59]

In Scikit-Learn l'implementazione del metodo Hold-out è offerta mediante la funzione `train_test_split` specificando opportunamente la percentuale del dataset di input da dedicare come set di test.

4.3.2.2 K-Fold

Il metodo K-Fold [B5.4] [S59] prevede la suddivisione del dataset in input in k parti uguali detti fold. In tal modo il modello viene addestrato k volte, utilizzando ogni volta un fold diverso come set di test e gli altri $k-1$ come set di training (fig. 4.8). La performance media del modello sui k fold fornisce una stima più robusta rispetto al metodo Hold-out, tuttavia la computazione è più onerosa, soprattutto per valori di k elevati. Inoltre, se il dataset è troppo piccolo, la variabilità tra i fold può essere elevata, influenzando negativamente la stima delle prestazioni.



Figura 4.8: Metodo di validazione K-Fold [S59]

In Scikit-Learn l'implementazione del metodo K-Fold è offerta mediante la classe `KFold` [S60] specificando opportunamente il numero di fold tramite il parametro `n_splits`, per il quale è usuale scegliere un valore pari a 5 o 10 [S59].

4.3.2.3 Stratified K-Fold

Il metodo Stratified K-Fold [S59] è una variazione del metodo K-Fold (fig. 4.7) particolarmente efficace per gli insiemi di dati sbilanciati, infatti assicura che la distribuzione delle classi in ogni fold sia simile a quella del dataset originale.

In Scikit-Learn l'implementazione del metodo Stratified K-Fold è offerta mediante la classe `StratifiedKFold` [S61] specificando opportunamente il numero di fold tramite il parametro `n_splits` e se mescolare i campioni di ciascuna classe prima di dividerli in fold tramite il parametro booleano `shuffle`.

4.3.2.4 Repeated K-Fold

Il metodo Repeated K-Fold [S59] consiste nella ripetizione multipla del metodo K-Fold, con diverse suddivisioni casuali dei dati. Infatti, ad ogni ripetizione, i dati vengono mescolati casualmente prima di essere divisi in k fold, introducendo un maggiore grado di casualità nel processo (fig. 4.9). Il calcolo della media delle prestazioni su più ripetizioni fornisce una valutazione delle prestazioni di un modello di classificazione più stabile e affidabile, rendendo questo metodo uno dei migliori nell'ambito della Cross-Validation. Questa tecnica è particolarmente utile quando si lavora con dataset di piccole dimensioni o quando la suddivisione iniziale dei dati può influenzare significativamente le stime delle prestazioni. Tuttavia, bisogna considerare un costo computazionale considerevole data la complessità del metodo K-Fold e il numero delle ripetizioni.




Figura 4.9: Metodo di validazione Repeated K-Fold [S59]

In Scikit-Learn l'implementazione del metodo Repeated K-Fold è offerta mediante la classe `RepeatedKFold` [S62] specificando opportunamente il numero di fold tramite il parametro `n_splits` e il numero di volte cui ripetere il metodo K-Fold tramite il parametro `n_repeats`.

4.3.3 Modelli di classificazione

Nei seguenti paragrafi sono illustrati i differenti algoritmi di classificazione che sono stati scelti appositamente per compiere le analisi, con l'indicazione del corrispondente classificatore importato dalla libreria Scikit-Learn per l'implementazione in Python del relativo algoritmo.

4.3.3.1 Classification and Regression Tree (CART)

Classification And Regression Tree (CART) [B9.1] è un algoritmo di apprendimento supervisionato che può essere utilizzato sia per problemi di classificazione che di regressione. Nel caso della classificazione, l'obiettivo è assegnare un'etichetta di classe a una nuova osservazione sulla base delle caratteristiche osservate. CART costruisce un modello ad albero decisionale (fig. 4.10), dove ogni nodo interno rappresenta un test su un attributo, ogni ramo rappresenta il risultato del test e ogni foglia rappresenta una classe (nel caso della regressione un valore numerico).

Il principio di funzionamento di CART si basa sulla partizione ricorsiva dello spazio dei dati in regioni omogenee. Ad ogni nodo dell'albero, viene selezionata la migliore caratteristica e il suo valore di soglia in modo da massimizzare l'omogeneità delle classi all'interno dei nodi figli. Questo processo continua fino a quando non viene soddisfatto un criterio di arresto, come la profondità massima dell'albero o un numero minimo di osservazioni in ciascun nodo.




Figura 4.10: Classification and Regression Tree: Schema modello ad alberi decisionali

La libreria Scikit-Learn offre l'implementazione dell'algoritmo CART con la classe `DecisionTreeClassifier` [S31], la quale offre un'ampia configurabilità tramite vari parametri come `criterion`, utile a definire il criterio con cui valutare la riduzione dell'impurezza, tramite l'indice di Gini (`gini`), o l'entropia (`entropy`), e `max_depth`, il quale stabilisce la massima profondità dell'albero. Questi, insieme ad altri parametri impostabili, rendono possibile personalizzare il comportamento dell'albero decisionale e adattarlo alle caratteristiche specifiche dell'insieme di dati in input.

Inoltre, l'algoritmo CART si presta bene sia nella gestione di dati categorici che numerici, senza richiedere una preventiva trasformazione, fornendo dei risultati facilmente interpretabili grazie al disegno di alberi decisionali particolarmente esplicativi delle decisioni prese dal modello.

Tuttavia, i modelli di classificazione basati su CART sono particolarmente sensibili al rumore nei dati, ovvero a piccole variazioni nei dati di addestramento che possono portare a cambiamenti significativi nella struttura dell'albero. Infatti, gli alberi decisionali possono essere soggetti a overfitting. Questo problema può essere mitigato tramite tecniche di pruning o limitando la profondità dell'albero.

4.3.3.2 Random Forest

Random Forest [B9.2] è un potente algoritmo di apprendimento automatico che combina la forza di numerosi alberi decisionali, che formano, come suggerisce il nome, una foresta (fig. 4.11).

Ogni albero viene costruito su un sottoinsieme casuale dei dati e considera solo un sottoinsieme casuale delle caratteristiche ad ogni nodo. Questa randomizzazione aiuta a ridurre l'overfitting e aumenta la diversità tra gli alberi. La predizione finale è determinata dalla maggioranza dei voti tra tutti gli alberi della foresta.

Tale algoritmo è apprezzato per la sua accuratezza, versatilità e capacità di gestire grandi quantità di dati, rendendolo uno strumento fondamentale nella risoluzione di problemi di classificazione e regressione.




Figura 4.11: Random Forest: Schema semplificato di rappresentazione del modello [S32]

In Scikit-Learn viene offerta la classe `RandomForestClassifier` [S33], la quale permette di personalizzare diversi parametri, come il numero e la profondità massima degli alberi, il criterio di split (gini o entropy), e molti altri.

Rispetto all'algoritmo CART, dato che Random Forest è essenzialmente un insieme di alberi decisionali CART, esso risulta più efficiente nel gestire grandi dataset, anche se computazionalmente è più complesso, ed è relativamente insensibile alle singolarità o "outliers" e al rumore nei dati.

4.3.3.3 Support Vector Machines (SVM)

Le Support Vector Machines (SVM) [B9.3] sono algoritmi di apprendimento supervisionato molto potenti, utilizzati sia per problemi di classificazione che di regressione, il cui obiettivo principale è trovare l'iperpiano che separa al meglio i dati di due o più classi, massimizzando il margine tra di essi (fig. 4.12). Questo iperpiano è definito dai cosiddetti "vettori di supporto", i punti dati più vicini all'iperpiano stesso.




Figura 4.12: Support Vector Machines: grafico con gli iperpiani che distinguono gli elementi di due classi, con evidenza del margine di decisione e dei vettori di supporto [S34]

Le SVM sono particolarmente efficaci nel gestire dati ad alta dimensionalità e possono essere adattate per risolvere problemi non lineari attraverso l'utilizzo di funzioni kernel. Rispetto agli alberi decisionali, le SVM tendono a generalizzare meglio su nuovi dati e sono meno soggette a overfitting, ma possono essere più lente da addestrare su grandi moli di dati in ingresso, su cui pagano un costo computazionale alto.

`SVC` (Support Vector Classifier) è la classe in Scikit-Learn [S35] che implementa l'algoritmo delle Support Vector Machines per problemi di classificazione. Tale classe offre una vasta gamma di parametri che permettono di personalizzare e ottimizzare il modello in base ai dati e al problema specifico, tra i quali è opportuno citare i due parametri fondamentali: `kernel`, ossia il metodo utilizzato per la gestione dei dati (si può scegliere tra diversi approcci, come lineare, polinomiale, RBF, o altri), e il parametro di regolarizzazione `C`, che definisce il grado di complessità del modello in relazione alla sua capacità di generalizzazione (valori più alti di `C` corrispondono a modelli più complessi e con un margine più stretto).

4.3.3.4 Gradient Boosting

Il Gradient Boosting [B9.4] è una potente tecnica di apprendimento automatico che costruisce un modello predittivo aggiungendo sequenzialmente modelli deboli, tipicamente alberi decisionali, per correggere gli errori del modello precedente (fig. 4.13). L'algoritmo funziona minimizzando una funzione di perdita specificata attraverso un processo iterativo di aggiunta di nuovi modelli, risultando particolarmente efficace per problemi di regressione e classificazione, spesso superando le prestazioni di altri algoritmi come le Random Forest.




Figura 4.13: Gradient Boosting: grafico che sintetizza il processo di modellazione iterativa con minimizzazione dell'errore rilevato [S36]

Infatti, tale algoritmo presenta un'alta accuratezza, la capacità di gestire dati eterogenei, la flessibilità nella scelta della funzione di perdita e la capacità di interpretare l'importanza delle caratteristiche. Tuttavia risulta sensibile al fenomeno di overfitting se non correttamente regolarizzato, può essere computazionalmente costoso per grandi insiemi di dati di input e richiede una meticolosa ottimizzazione degli iperparametri.

A differenza degli alberi decisionali, che creano una singola struttura ad albero, il Gradient Boosting costruisce un “ensemble” di alberi, migliorando la generalizzazione. Rispetto al meccanismo di ensemble analogo delle Random Forest, il Gradient Boosting è più sequenziale e si concentra sulla correzione degli errori, mentre le prime creano alberi in parallelo.

`GradientBoostingClassifier` [S37] è la classe in Scikit-Learn che implementa l'algoritmo Gradient Boosting di classificazione, la quale offre una vasta gamma di iperparametri che consentono di controllare la complessità del modello, come la profondità massima degli alberi (`max_depth`), il tasso di apprendimento (`learning_rate`) e il numero di estimatori (`n_estimators`).

4.3.3.5 Logistic Regression

La Regressione Logistica [B9.5] è un algoritmo di apprendimento supervisionato utilizzato per problemi di classificazione binaria, ovvero quando la variabile dipendente può assumere solo due valori (es. sì/no, positivo/negativo). A differenza della Regressione Lineare, che prevede valori continui, la Regressione Logistica stima la probabilità che un'osservazione appartenga a una particolare classe, modellando la relazione tra una variabile dipendente binaria e una o più variabili indipendenti attraverso una funzione logistica, che mappa i valori dall'intervallo $[-\infty, +\infty]$ all'intervallo $[0, 1]$, ossia False/True o No/Yes (fig. 4.14).




Figura 4.14: Regressione Logistica - Esempificazione del funzionamento del modello [S38]

La Regressione Logistica, pur nella sua semplicità, offre numerosi vantaggi che la rendono un algoritmo di classificazione molto apprezzato. Infatti, la sua interpretabilità è uno dei suoi punti di forza: i coefficienti associati a ciascuna variabile indipendente indicano la direzione e l'intensità della loro relazione con la probabilità di appartenenza alla classe positiva.

Inoltre, tale algoritmo è computazionalmente efficiente e può gestire facilmente dataset di grandi dimensioni, anche se la sua principale limitazione risiede nell'assunzione di una relazione lineare tra le variabili esplicative e il logaritmo delle odds, ossia dei rapporti di probabilità che una determinata osservazione appartenga ad una classe piuttosto che a quella complementare. Ciò significa che potrebbe non essere in grado di catturare pattern non lineari complessi presenti nei dati.

Rispetto ad altri algoritmi, come gli alberi decisionali, la regressione logistica offre un modello globale e lineare, mentre gli alberi decisionali creano partizioni dello spazio delle caratteristiche, generando modelli più interpretabili a livello locale ma potenzialmente meno accurati su dati complessi. Le reti neurali, d'altro canto, sono in grado di apprendere relazioni non lineari molto

complesse, ma richiedono una maggiore quantità di dati e sono più soggette a overfitting, come si vedrà nel paragrafo successivo.

`LogisticRegression` [S39] è la classe in Scikit-Learn che implementa l'algoritmo di Regressione Logistica, la quale offre una serie di funzionalità e parametri che la rendono uno strumento versatile per la classificazione binaria e multinomiale.

In particolare è possibile personalizzare i seguenti parametri fondamentali: `solver`, per scegliere diversi algoritmi di ottimizzazione (`liblinear`, `lbfgs`, `newton-cg`, `sag`, `saga`) in modo da trovare i coefficienti del modello, `penalty`, per scegliere la norma (`l1`, `l2`) usata nella penalizzazione, `C`, inverso del parametro di regolarizzazione, e `max_iter`, per scegliere il numero massimo di iterazioni per la convergenza.

4.3.3.6 Neural Network: Multi-Layer Perceptron

Le reti neurali artificiali Multi-Layer Perceptron (MLP) [B5.7] [B10] sono modelli di apprendimento profondo o “deep learning” ispirati al funzionamento del cervello umano. Una MLP è costituita da più strati di neuroni artificiali (fig. 4.15), interconnessi tra loro, che lavorano insieme per apprendere pattern complessi nei dati, dove ogni neurone riceve input da neuroni dello strato precedente, li combina in modo ponderato e applica una funzione di attivazione non lineare per produrre un output.




Figura 4.15: Neural Network: MLP - Topologia del Multi-Layer Perceptron [S40]

Le MLP sono estremamente versatili e possono essere applicate a una vasta gamma di problemi, dalla classificazione alla regressione, passando per il riconoscimento di immagini e il linguaggio naturale. Inoltre, sono in grado di apprendere rappresentazioni complesse e non lineari dei dati, superando le limitazioni degli algoritmi lineari come la regressione logistica.

Tuttavia, esse richiedono una grande quantità di dati per essere addestrate in modo efficace e possono essere soggette a overfitting. In aggiunta, l'interpretazione dei modelli MLP è spesso difficile, rendendo complicato comprendere come l'algoritmo arrivi alle sue decisioni.

Rispetto ad algoritmi come la regressione logistica o gli alberi decisionali, le MLP sono in grado di apprendere modelli più complessi e non lineari, anche se sono più complesse da addestrare e richiedono una maggiore potenza computazionale.

`MLPClassifier` [S41] è la classe in Scikit-Learn che implementa l'algoritmo di classificazione Multi-Layer Perceptron (MLP), la quale richiede una scelta oculata dei parametri per ottenere le migliori prestazioni del modello.

Tra questi parametri è opportuno evidenziare i seguenti: `hidden_layer_sizes`, tupla che definisce l'architettura della rete neurale, specificando il numero di neuroni in ogni strato nascosto; `activation`, che determina la funzione di attivazione da utilizzare nei neuroni (`identity`, `logistic`, `tanh`, `relu`); `solver`, che specifica l'algoritmo di ottimizzazione (tra `sgd`, `adam` e `lbfgs`) utilizzato per addestrare la rete; `alpha`, che controlla la forza della regolarizzazione ¹², che aiuta a prevenire l'overfitting penalizzando i pesi grandi della rete; `learning_rate`, che determina la dimensione del passo effettuato durante l'ottimizzazione, infatti un learning rate troppo alto può portare a divergenza, mentre un learning rate troppo basso può rallentare l'addestramento.

4.3.3.7 K-Nearest Neighbors (KNN)

L'algoritmo K-Nearest Neighbors (KNN) [B9.6] è un metodo di apprendimento supervisionato non parametrico che classifica nuovi punti dati in base alla classe maggioritaria dei suoi k vicini più prossimi nello spazio delle features, assumendo, in sostanza, che punti dati simili si trovano in classi simili (fig. 4.16).




Figura 4.16: K-Nearest Neighbors (KNN) - Grafico con inserimento di un nuovo punto che viene classificato in un insieme dopo l'addestramento del modello [S42]

È un algoritmo semplice e intuitivo, ma può essere molto efficace in molte applicazioni: infatti, KNN è facile da implementare, non richiede alcuna assunzione sulla distribuzione dei dati e può essere utilizzato sia per classificazione che per regressione.

Tuttavia, la scelta del valore di k può influenzare significativamente le prestazioni e può essere computazionalmente costoso per grandi dataset.

Rispetto ad altri algoritmi come le reti neurali, KNN è, come accennato precedentemente, più semplice e più veloce da addestrare, ma può essere meno accurato su problemi complessi. Rispetto agli alberi decisionali, KNN non produce un modello interpretabile, ma può essere più robusto al rumore nei dati.

`KNeighborsClassifier` [S43] è la classe in Scikit-Learn che implementa l'algoritmo K-Nearest Neighbors (KNN), la quale offre una serie di parametri che permettono di personalizzare il comportamento dell'algoritmo e adattarlo a diverse situazioni, tra i quali: `n_neighbors`, ossia il numero di vicini più prossimi da considerare per la classificazione di un nuovo punto dati; `algorithm`, ossia l'algoritmo da utilizzare per la ricerca dei vicini (vi sono opzioni come il `brute-force` e il `tree-based`); `weights`, ossia la ponderazione dei vicini, infatti è possibile assegnare pesi diversi ai vicini in base alla loro distanza dal punto da classificare.

4.3.4 Accuratezza dei modelli di classificazione

Le prestazioni di un modello di classificazione si possono misurare attraverso diverse tecniche.

In questo lavoro progettuale la metodologia utilizzata è quella di verificare il grado di generalizzazione del modello di classificazione a nuovi dati, per mezzo della funzione `accuracy_score` [S64] offerta da Scikit-Learn, la quale, applicata sugli insiemi delle risposte di test e di predizione, fornisce una percentuale che corrisponde alla capacità del modello di generalizzare a nuovi dati.

Applicando questa funzione alle metodologie di Cross-Validation, è possibile verificare l'accuratezza del modello per ogni fold utilizzato per gli addestramenti parziali, in modo da ottenere una stima robusta dell'accuratezza del modello.

4.3.5 Scelta degli iperparametri

Come già accennato nei paragrafi precedenti, ogni algoritmo di classificazione richiede la scelta di opportuni iperparametri utili a personalizzare il comportamento dell'algoritmo, influenzando le prestazioni dello stesso.

Pertanto, risulta fondamentale la loro individuazione, al fine di ottenere i migliori risultati per ogni algoritmo per l'insieme di dati in esame.

A tal fine, si è reso necessario lo sviluppo di alcuni test in Python che, sulla base di tre differenti composizioni del dataset di ingresso⁶, esplori le diverse opzioni possibili degli iperparametri, determinando la migliore configurazione per ottenere la più alta accuratezza possibile, con una tecnica di Cross-Validation di tipo Hold-out.

Il seguente schema (fig. 4.17) riassume la metodologia con la quale si sono sviluppati i test e i risultati da ottenere per considerarlo superato.

⁶ Per il test sono stati raccolti tre differenti dataset: `small` (S) per i campioni raccolti in 7 giorni, `large` (L) per i campioni raccolti in 20 giorni, `extralarge` (XL) per i campioni raccolti in 38 giorni; il periodo di raccolta va dal 01/11/2024 al 08/12/2024.




Figura 4.17: Schema Unit Test per la valutazione degli iperparametri degli algoritmi di ML

In particolare, per esplorare la maggiorparte delle possibili opzioni degli iperparametri, si è realizzato lo script [test_amazon_ml_analysis_hyperparameters.py](#) il quale utilizza la classe `GridSearchCV` [S44] di Scikit-Learn per effettuare una ricerca degli iperparametri che contribuiscono ad ottenere la migliore accuratezza, combinandoli tra di loro e richiamando la funzione `fit` sul dataset in ingresso.

L'esito della ricerca evidenzia che vi sono diverse configurazioni possibili, per le quali si ottiene un'accuratezza molto elevata⁷, per ogni algoritmo in base alla grandezza del dataset di ingresso⁸. Infatti, come accennato nelle differenti descrizioni degli algoritmi di Machine Learning, tali algoritmi possono presentare comportamenti differenti sulla base della composizione del dataset di ingresso, sia in termini di efficienza che di risultati.

Pertanto, la realizzazione dei successivi script [test_amazon_ml_analysis_best_score.py](#) e [test_amazon_ml_analysis_best_score_massive.py](#) ha lo scopo di esplorare queste configurazioni in modo da verificare e valutare quali di esse si prestano bene a gestire le diverse situazioni, in termini di dataset di ingresso e opzioni all'analisi in Machine Learning.

⁷ L'accuratezza minima da raggiungere è fissata al 95%.

⁸ Infatti si ottiene una configurazione per ciascun dataset S, L o XL.

In particolare, il secondo script verifica la media dell'accuratezza ottenuta dalle analisi sui differenti dataset per ogni configurazione degli iperparametri notevoli verificati con il primo script. In questo modo, si sono trovate delle configurazioni degli iperparametri adatti ad ottenere ottimi risultati, in termini di accuratezza, indipendentemente dalla grandezza del dataset di ingresso.

Questi risultati sono raccolti nella seguente tabella riassuntiva (tab. 4.2):

Algoritmo ML	Mappa degli iperparametri scelti
CART	<code>{'criterion': 'entropy', 'max_depth': 20, 'max_leaf_nodes': None, 'min_samples_leaf': 4, 'min_samples_split': 10, 'splitter': 'random'}</code>
Random Forest	<code>{'max_depth': 10, 'max_features': 'sqrt', 'min_samples_leaf': 2, 'min_samples_split': 5, 'n_estimators': 500}</code>
Support Vector Machines	<code>{'C': 1, 'degree': 2, 'gamma': 'scale', 'kernel': 'rbf'}</code>
Gradient Boosting	<code>{'learning_rate': 0.05, 'max_depth': 7, 'min_samples_leaf': 2, 'min_samples_split': 2, 'n_estimators': 500}</code>
Logistic Regression	<code>{'C': 10, 'class_weight': {0: 1, 1: 1}, 'max_iter': 100, 'multi_class': 'ovr', 'penalty': 'l2', 'solver': 'lbfgs'}</code>
Neural Network: Multi-Layer Perceptron	<code>{'activation': 'relu', 'alpha': 0.0001, 'hidden_layer_sizes': (50, 50), 'learning_rate': 'adaptive', 'solver': 'adam'}</code>
K-Nearest Neighbors	<code>{'algorithm': 'brute', 'n_neighbors': 7, 'p': 1, 'weights': 'uniform'}</code>

Tabella 4.2: Iperparametri risultanti migliori per gli algoritmi di classificazione in Machine Learning

4.3.6 Estrazione dei pesi delle caratteristiche

Basandosi sul modello di classificazione addestrato è possibile estrarre i pesi delle caratteristiche coinvolte nell'analisi in Machine Learning. La tecnica che si adatta a tutti gli algoritmi coinvolti nell'analisi è la *permutation feature importance*, implementata tramite la funzione `permutation_importance` offerta da Scikit-Learn [S63].

Tale tecnica consiste nel perturbare casualmente i valori di una singola caratteristica nel dataset di test e osservare l'impatto che questa perturbazione ha sulla performance del modello.

Maggiore è la diminuzione della performance del modello dopo la permutazione, maggiore è l'importanza attribuita a quella caratteristica.

Il calcolo dell'importanza delle caratteristiche è influenzata dall'addestramento del modello di classificazione e, dunque, dalle prestazioni ottenute. Per ottenere una stima ottimale dei valori di importanza è possibile applicare la funzione `permutation_importance` congiuntamente all'applicazione dei metodi di Cross-Validation. Infatti, è possibile, ad esempio, calcolare le importanze delle caratteristiche ad ogni iterazione nell'applicazione del metodo `RepeatedKfold`, per infine calcolare la media di queste.

In tal modo si ottiene una stima più robusta dell'accuratezza e dell'importanza delle caratteristiche. In questo lavoro progettuale, il calcolo della media applicato ai risultati parziali per ogni strato di addestramento e test viene effettuato per tutte le tecniche di Cross-Validation basate su K-Fold.

5 Esplorazione delle analisi

Gli algoritmi di Machine Learning trattati nel precedente capitolo costituiscono la base su cui poggia il processo di esplorazione delle analisi. L'obiettivo è quello di realizzare un'interfaccia semplice e intuitiva che consenta di espletare le analisi dei dati con i diversi algoritmi di Machine Learning, manipolando la composizione dei dati in ingresso e i parametri utili al calcolo. I risultati dell'elaborazione devono poi essere visualizzati in tabelle e grafici notevoli, in modo da consentirne l'interpretazione da parte dell'utente finale.

In questo capitolo si illustra la composizione della piattaforma Web realizzata allo scopo di integrare analisi dei dati e la visualizzazione dei relativi risultati, evidenziando i relativi dettagli implementativi nell'ambito della realizzazione dell'immagine `amazon-buy-box-dashboard`.

Come illustrato nella figura seguente (fig. 5.1), la composizione dell'immagine `amazon-buy-box-dashboard` prevede due elementi fondamentali: il front-end con l'applicazione Web in Dash Plotly accessibile da parte dell'utente, su cui può selezionare i filtri e i parametri di input utili alle analisi in Machine Learning nonché visualizzare i risultati delle stesse, e il back-end con gli script Python relativi alle operazioni di lettura dal Database MongoDB, filtro, normalizzazione e analisi dei dati in Machine Learning.




Figura 5.1: Composizione immagine `amazon-buy-box-dashboard`

Dopo una breve introduzione sul framework Dash Plotly in Python, si illustreranno nel dettaglio le funzionalità offerte dalla piattaforma e gli elementi grafici utilizzati. Infine, si porrà l'attenzione su alcuni risultati di particolare interesse che evidenziano, in determinate condizioni, quali sono le caratteristiche più influenti nella scelta, da parte dell'algoritmo di Amazon, del venditore vincente della Buy Box.

5.1 Introduzione a Dash Plotly

Dash Plotly [S17] rappresenta una soluzione innovativa e versatile per la creazione di applicazioni web interattive focalizzate sull'analisi e la visualizzazione dei dati. Questo framework Python, costruito sulle solide fondamenta di Flask, Plotly.js e React.js, offre agli sviluppatori e ai data scientist un ambiente di sviluppo intuitivo e potente.

Grazie alle funzionalità offerte dal framework, si può fornire all'utente un'esperienza interattiva che permetta di esplorare i dati da diverse prospettive, tramite una vasta gamma di strumenti e componenti predefiniti, consentendo di creare dashboard personalizzati, grafici interattivi e applicazioni web complesse in modo rapido ed efficiente.

Una delle caratteristiche distintive di Dash è la sua sintassi Python intuitiva, che permette di definire layout, componenti e interazioni in modo naturale e leggibile. Questa semplicità d'uso, unita alla potenza di Plotly.js e Matplotlib [S45] per la creazione di visualizzazioni, rende Dash uno strumento accessibile sia ai data scientist che agli sviluppatori web, anche a quelli con un'esperienza limitata nella creazione di interfacce utente.

Infatti, Dash consente di realizzare layout sia componenti nativi in HTML [S46] che con elementi definiti dalle librerie offerte dal framework, le quali sono personalizzabili sia nello stile, anche moderno con l'integrazione di Bootstrap [S47], che nel comportamento, mediante le opportune funzioni di `callback` [S48].

Inoltre, Dash si integra perfettamente con altre librerie Python ampiamente utilizzate nel mondo della Data Science. Infatti, la componente di visualizzazione può integrarsi sia con la componente analitica di calcolo, identificata proprio dagli script Python adibiti all'esecuzione delle analisi con gli algoritmi in Machine Learning, sia con la componente di disegno di grafici notevoli che possono essere visualizzati e aggiornati nel layout, sia con l'utilizzo di strumenti nativi della libreria che di strumenti di librerie terze come Matplotlib.

5.2 Piattaforma Web interattiva

Il deploy dell'immagine `amazon-buy-box-dashboard` su ambiente Docker permette all'utente di accedere all'applicazione Web alla porta 8082 della macchina locale⁹.

Al primo accesso tramite browser la piattaforma si presenta come mostrato di seguito (fig. 5.2):

← → ↻ ⓘ localhost:8082 🔍 ☆ G ⋮

Interactive Amazon Buy Box Analysis

Input Data to Machine Learning Analysis

Observation Period: 11-10-2024 → 18-10-2024

Features to consider:

- price_diff_prod
- price_diff
- price_diff_ship
- delivery_days
- ratings_num
- ratings_avg
- ratings_perc_positive
- fba
- amazon
- new

Filter Amazon as BuyBox winner: ☒ Yes ☐ No

Filter Amazon as non-BuyBox winner: ☒ Yes ☐ No

Filter New Seller as BuyBox winner: ☒ Yes ☐ No

Filter New Seller as non-BuyBox winner: ☒ Yes ☐ No

Cross Validation Option:

- ☒ Hold-out (select test size)
- ☐ k-Fold (10 splits)
- ☐ Stratified k-Fold (10 splits)
- ☐ Repeated k-Fold (10 splits, 3 repeats)

Test size for Machine Learning algorithm: 0 0.1 0.2 0.3 0.4

Machine Learning Algorithm to use: ALL ALGORITHMS

Execute Machine Learning Analysis

Figura 5.2: Layout dell'applicazione Web “Interactive Amazon BuyBox Analysis” al primo ingresso in pagina

Come si può notare dalla figura precedente (fig. 5.2), viene proposta all'utente una sezione dedicata alla selezione dei dati di input alle analisi in Machine Learning, le quali possono essere eseguite al click sul bottone “Execute Machine Learning Analysis”; i risultati dell'analisi vengono mostrati nell'apposita sezione dei dati di output, posta in fondo alla pagina e che non risulta visibile al primo ingresso.

Nei paragrafi a seguire ci si focalizza su ognuna delle sezioni sopra citate, illustrando i singoli elementi e le tecniche implementative adottate per la loro realizzazione.

⁹ <http://localhost:8082>

5.2.1 Sezione di input

Input Data to Machine Learning Analysis

Observation Period: 11-10-2024 → 18-10-2024

Features to consider:

- ☒ price_diff_prod
- ☒ price_diff
- ☒ price_diff_ship
- ☒ delivery_days
- ☒ ratings_num
- ☒ ratings_avg
- ☒ ratings_perc_positive
- ☒ fba
- ☒ amazon
- ☒ new

Filter Amazon as BuyBox winner:

☐ Yes

☒ No

Filter Amazon as non-BuyBox winner:

☐ Yes

☒ No

Filter New Seller as BuyBox winner:

☐ Yes

☒ No

Filter New Seller as non-BuyBox winner:

☐ Yes

☒ No

Cross Validation Option:

- ☒ Hold-out (select test size)
- ☐ k-Fold (10 splits)
- ☐ Stratified k-Fold (10 splits)
- ☐ Repeated k-Fold (10 splits, 3 repeats)

Test size for Machine Learning algorithm:

0 0.1 0.2 0.3 0.4

Machine Learning Algorithm to use:

ALL ALGORITHMS

Figura 5.3: Interactive Amazon Buy Box Analysis - Sezione di input

La sezione di input (fig. 5.3) offre all'utente la possibilità di personalizzare una serie di parametri ben definiti per il calcolo in Machine Learning. Tale possibilità nasce dal fatto che le analisi possono variare significativamente i loro risultati sulla base della composizione del DataFrame di input, che può essere manipolata con gli opportuni filtri sui dati, dell'insieme delle caratteristiche di cui valutare i pesi, degli algoritmi da utilizzare e dei parametri ad essi, come il metodo di Cross-Validation da applicare per l'addestramento del modello di classificazione.

Infatti, in base alla combinazione dei suddetti input, i risultati relativi alle analisi possono evidenziare delle sostanziali differenze tra di loro, dimostrando la complessità e la variabilità dell'algoritmo usato da Amazon per l'assegnazione della Buy Box.

5.2.1.1 Periodo di osservazione

Il periodo di osservazione è indicato da una data di inizio e da una data di fine periodo entro le quali vengono filtrati i campioni estratti da Amazon. Il componente è realizzato mediante la classe `DatePickerRange` di Dash Plotly [S49], che consente di selezionare un periodo di tempo compreso tra due date di inizio e fine, mostrando un calendario da dove selezionare le date in un popup.

Al primo ingresso in pagina il componente è pre-valorizzato con un periodo di sette giorni che termina con l'ultima data di estrazione dei campioni da Amazon.

L'applicazione del filtro per periodo di osservazione è effettuata nella fase di lettura dei dati dal Database MongoDB, una volta scatenato il processo di analisi dei dati in Machine Learning al click del bottone “Execute Machine Learning Analysis”.

5.2.1.2 Caratteristiche da considerare

L'insieme delle caratteristiche da considerare per le analisi in Machine Learning è componibile mediante la classe `Dropdown` di Dash Plotly [S50] grazie alla quale è possibile selezionare, da un insieme predefinito, le caratteristiche di cui calcolare i relativi pesi nella classificazione.

5.2.1.3 Filtri sui venditori e osservazioni notevoli

Come accennato precedentemente, è opportuno considerare nell'analisi la presenza o assenza di alcuni venditori e osservazioni notevoli, che risultano determinanti nell'esecuzione delle analisi in Machine Learning, con l'ottenimento di risultati parecchio differenti tra loro.

In particolare, si individuano due categorie di venditori di particolare interesse: Amazon e il nuovo venditore di terze parti. Queste due categorie si differenziano rispetto agli altri venditori poiché non presentano valorizzati i dati delle recensioni, infatti in entrambi i casi Amazon non li espone in pagina in quanto o non disponibili, per il caso Amazon come venditore, o non ancora immessi dagli utenti, per il caso del nuovo venditore.

Pertanto, si è scelto di proporre all'utente quattro filtri per gestire altrettante casistiche in modo da comporre dinamicamente il DataFrame di input al calcolo in Machine Learning. Tali filtri sono realizzati con la classe `RadioItems` di Dash Plotly [S51] e realizzano i filtri indicati nella seguente tabella:

Descrizione Filtro	Quali dati filtra se è selezionata l'opzione 'Yes'	Funzione Python
Amazon come vincitore della Buy Box	Si filtrano via tutte le osservazioni che presentano il venditore Amazon come vincitore della Buy Box	<code>filter_amazon_bb_seller</code>
Amazon come altro venditore non vincitore della Buy Box	Si filtrano via tutte le righe (non le osservazioni) dei venditori non vincitori della Buy Box che sono il venditore Amazon	<code>filter_amazon_nbb_seller</code>
Nuovo venditore come vincitore della Buy Box	Si filtrano via tutte le osservazioni che presentano il nuovo venditore come vincitore della Buy Box	<code>filter_new_bb_sellers</code>

Nuovo venditore come altro venditore non vincitore della Buy Box	Si filtrano via tutte le righe (non le osservazioni) dei venditori non vincitori della Buy Box che sono nuovi venditori	<code>filter_new_nbb_sellers</code>
--	---	-------------------------------------

Tabella 5.1: Filtri su venditori e osservazioni notevoli

L'implementazione dei filtri suddetti è realizzata nello script [amazon_data_filters.py](#) con le funzioni indicate nell'ultima colonna della tabella qui sopra.

5.2.1.4 Filtri sulla numerosità di venditori nelle osservazioni

Ad integrazione dei filtri indicati precedentemente, vi sono altri due filtri che consentono all'utente di selezionare e personalizzare le osservazioni in base alla numerosità di venditori estratti con il campionamento.

In particolare, sono stati messi a disposizione due filtri numerici realizzati con la classe `Slider` di Dash Plotly [S52]: il primo consente di selezionare il numero minimo di venditori che rendono un'osservazione valida e, quindi, da includere nel DataFrame di input; il secondo consente di selezionare il numero minimo di venditori non vincitori della Buy Box da considerare per la singola osservazione.

Le opzioni offerte variano in un numero di venditori compresi in un intervallo $[3, 10]$, con le scelte pre-valorizzate che ricadono in 8 a entrambe.

L'implementazione dei filtri suddetti è realizzata nello script [amazon_data_filters.py](#) con le rispettive funzioni `filter_by_seller_count` e `filter_by_nbb_seller_count`.

5.2.1.5 Metodi di Cross-Validation

La scelta circa il metodo di Cross-Validation da applicare per l'addestramento del modello di classificazione consente all'utente di esplorare diverse configurazioni per il calcolo in Machine Learning. Infatti, tramite la scelta tra gli opportuni `RadioItems` di Dash Plotly [S51] è possibile selezionare il metodo di Cross-Validation più adatto alle proprie esigenze, secondo le opzioni riportate nella seguente tabella (tab. 5.2):

Metodo di Cross-Validation	Descrizione
Hold-out	Metodo Hold-out , applicato con la percentuale dell'insieme di test selezionata con l'opzione visibile solo nel caso in cui questo metodo sia selezionato

K-Fold	Metodo K-Fold , con un numero di fold pari a 10.
Stratified K-Fold	Metodo Stratified K-Fold , con un numero di fold pari a 10.
Repeated K-Fold	Metodo Repeated K-Fold , con un numero di fold pari a 10 e un numero di run pari a 3.

Tabella 5.2: Metodi di Cross-Validation selezionabili

5.2.1.6 Grandezza del set di test per il Machine Learning

Grazie alla classe `Slider` trattata per i precedenti filtri, è stata realizzata l’opzione di selezione della grandezza del set di test da prendere in considerazione come parametro per l’apprendimento con l’analisi in Machine Learning nel caso in cui sia stata selezionata l’opzione “Hold-out” come metodo di Cross-Validation. Il componente grafico non è visibile se l’opzione di Cross-Validation è differente rispetto alla suddetta.

In base al valore scelto si può determinare in che percentuale utilizzare i campioni per l’addestramento e per i test, influenzando l’addestramento dei modelli di classificazione con gli algoritmi di Machine Learning, determinando dei risultati differenti tra le varie opzioni.

Le opzioni offerte variano in un intervallo $[0, 0.4]$ con un passo di 0.1, mentre la scelta predefinita è 0.2.

5.2.1.7 Scelta dell’algoritmo di classificazione

L’utente può scegliere l’algoritmo di classificazione da utilizzare per l’analisi in Machine Learning mediante l’opportuno menù a tendina realizzato con la classe `Dropdown` di Dash Plotly [S50]. In particolare, le opzioni proposte sono gli algoritmi trattati nel precedente Capitolo, con l’aggiunta in prima posizione di un’opzione “ALL ALGORITHMS”, che risulta anche pre-valorizzata al primo ingresso, grazie alla quale è possibile lanciare il calcolo in Machine Learning con tutti gli algoritmi di classificazione.

Tale opzione è utile per confrontare i risultati di diversi modelli addestrati con diversi algoritmi, con evidenza dell’accuratezza media e dei pesi medi, come si vedrà nel paragrafo dedicato alla sezione di output.

5.2.2 Esecuzione analisi in Machine Learning

L'esecuzione delle analisi in Machine Learning, con gli input indicati dall'utente, viene lanciata a seguito del click sul bottone "Execute Machine Learning Analysis" (fig. 5.4), realizzato con la classe `Button` di Dash Plotly [S53].


A screenshot of a button with the text "Execute Machine Learning Analysis" inside a rectangular border.

Figura 5.4: Interactive Amazon BuyBox Analysis - Bottone "Execute Machine Learning Analysis"

L'operazione di `Submit` al click del bottone scatena l'esecuzione di una funzione di `callback` secondo le specifiche di Dash Plotly [S48], grazie alla quale è possibile recepire i dati di input precedentemente selezionati in pagina e aggiornare determinati componenti grafici di output, a seguito della modifica di uno o più componenti di input.

Come si può notare nel codice sorgente dello script [amazon_layout_dashboard.py](#), la funzione `update_output` di `callback` definisce tramite opportune annotazioni proprie del framework Dash Plotly tutte le componenti coinvolte nell'esecuzione della funzione. Si possono distinguere gli `Input`, ossia quali elementi scatenano l'esecuzione della funzione di `callback` a seguito di una loro modifica, gli `Output`, ossia gli elementi che vengono restituiti dalla funzione di `callback` e che sono destinati ad aggiornare i rispettivi elementi grafici presenti in pagina, e infine gli `State`, ossia gli elementi da consultare utili all'esecuzione della funzione di `callback`.

In questo caso specifico: l'unico `Input` è l'attributo `n_clicks` del bottone con identificativo `'submit-button-state'`, alla cui modifica viene lanciata la funzione di `callback`, ossia al click sul bottone che ne incrementa il valore; gli `Output` sono i diversi attributi dei componenti che vengono mostrati nella sezione di output, quali tabelle e grafici; gli `State` sono i valori assunti dai componenti grafici presenti nella sezione di input, utili ad essere gli input al calcolo in Machine Learning.

La funzione di `callback` suddetta, come evidenziato nel diagramma di flusso a figura 5.5, orchestra le operazioni per il calcolo in Machine Learning e il disegno dei componenti visuali di output. Di fatto, vengono effettuate le invocazioni alle funzioni implementate negli script [amazon_data*.py](#), [amazon_ML*.py](#) e [amazon_layout_utils.py](#), dedicati rispettivamente a: la gestione dei dati di input, con operazioni come importazione, filtro e normalizzazione; il calcolo in Machine Learning, con le operazioni di addestramento dei modelli per uno o più algoritmi e

restituzione dell'accuratezza e dei pesi delle caratteristiche in esame; il disegno dei componenti grafici quali tabelle e grafici notevoli per esporre i dati di output.




Figura 5.5: Diagramma di flusso esecuzione callback al click sul bottone “Execute Machine Learning Analysis”

I dati di output del calcolo vengono poi strutturati per consentire la realizzazione degli opportuni componenti grafici presenti nella sezione di output che, come si può notare nel paragrafo seguente, è composto da tabelle e grafici notevoli.

5.2.3 Sezione di output

La sezione di output, denominata “Output Data & Graphs”, raccoglie i risultati delle analisi sui dati effettuate, eseguite con l’operatività utente illustrata nel paragrafo precedente.

Tale raccolta si compone di tabelle e grafici notevoli che illustrano le proprietà dell'insieme di dati analizzati, le statistiche dei vincitori della Buy Box, l'accuratezza raggiunta dall'analisi in Machine Learning e i dati, sia in formato tabellare che grafico su istogramma, dei pesi delle caratteristiche relative alle osservazioni, evidenziando quali di esse sono le più influenti per l'assegnazione della Buy Box da parte di Amazon.

La figura seguente (fig. 5.6) mostra come appare la sezione di output una volta eseguita l'analisi in Machine Learning cliccando il bottone trattato al paragrafo precedente, con l'indicazione di applicare tutti gli algoritmi di classificazione con l'opzione "ALL ALGORITHMS":

Output Data & Graphs


Normalized Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	24377	0.47	0.33	0	0.17	0.5	0.75	1
price_diff	24377	0.47	0.34	0	0.14	0.5	0.75	1
price_diff_ship	24377	0.11	0.28	0	0	0	0	1
delivery_days	24377	0.42	0.34	0	0	0.4	0.67	1
ratings_num	24377	0.48	0.33	0	0.17	0.5	0.75	1
ratings_avg	24377	0.68	0.3	0	0.67	0.83	0.83	1
ratings_perc_positive	24377	0.59	0.33	0	0.38	0.65	0.88	1
fba	24377	0.25	0.43	0	0	0	0	1
amazon	24377	0.11	0.31	0	0	0	0	1

Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	24377	5.79	7.44	-6.81	0.1	3.55	7.51	32.21
price_diff	24377	6.59	7.42	-6.81	0.59	4.83	8.08	32.21
price_diff_ship	24377	0.8	2.13	0	0	0	0	10.99
delivery_days	24377	7.33	4.19	2	4	6	10	35
ratings_num	21232	4193.86	10694.12	2	198	853	2679	83905
ratings_avg	21232	4.31	0.59	1	4	4.5	4.5	5
ratings_perc_positive	21232	83.67	15.02	0	76	86	95	100

Buy Box Winners



Accuracy Score



Features Importance Table

feature	CLASSIFICATION AND REGRESSION TREE	GRADIENT BOOSTING	K-NEAREST NEIGHBORS	LOGISTIC REGRESSION	MULTI-LAYER PERCEPTRON	RANDOM FOREST	SUPPORT VECTOR MACHINES
amazon	6.42	1.56	0	16.62	16.54	0.48	0.04
delivery_days	15.56	21.37	30.12	13.2	16.29	25.63	15.6
fba	21.09	21.92	11.23	11.91	18.33	8.43	31.33
price_diff	36.47	40.76	14.36	40.56	19.19	50.17	35.05
price_diff_prod	11.4	3.26	31.83	8.47	12.99	5.7	6.48
price_diff_ship	0	0	0.61	2.6	2.05	0.09	2.37
ratings_avg	0.58	0.11	0.07	0	2.71	0.6	4.87
ratings_num	4.32	4.24	9.66	6.18	9.32	4.27	3.37
ratings_perc_positive	4.16	6.8	2.12	0.47	2.58	4.62	0.91

Features Importance Graph





Figura 5.6: Interactive Amazon Buy Box Analysis - Sezione di output per l'opzione "ALL ALGORITHMS"

Di seguito, invece, è mostrata (fig. 5.7) la sezione di output nel caso in cui sia selezionato un singolo algoritmo di classificazione, come ad esempio l'algoritmo CART:

Output Data & Graphs



Buy Box Winners

Amazon seller

FBM third party seller

FBA third party seller

Accuracy Score

Features Importance Table

feature	importance
price_diff	36.56
amazon	20.31
delivery_days	14.56
price_diff_prod	13.13
ratings_num	6.17
fba	3.52
ratings_avg	3.28
ratings_perc_positive	2.45
price_diff_ship	0

Features Importance Graph

Figura 5.7: Interactive Amazon Buy Box Analysis - Sezione di output per l’opzione a singolo algoritmo (es. “CLASSIFICATION AND REGRESSION TREE”)

5.2.3.1 Descrizioni delle caratteristiche nel Dataset di input

Le prime due tabelle forniscono una panoramica delle statistiche relative alle caratteristiche scelte per l'analisi all'interno del Dataset di input. In particolare, come suggeriscono i nomi che le precedono, tali tabelle mostrano il risultato dell'operazione di `describe` [S54] effettuata su due differenti versioni del DataFrame di input focalizzate sulle caratteristiche scelte dall'utente: una con i dati normalizzati nell'intervallo $[0, 1]$ e una versione con i dati reali, cioè pre-normalizzazione.

Tale visualizzazione mostra la distribuzione dei dati per ciascuna caratteristica, grazie alla quale si possono individuare simmetrie o asimmetrie nei dati, con l'evidenza del numero totale, della media, della deviazione standard, dei vari percentili e dei valori minimo e massimo.

Per la realizzazione delle tabelle si è utilizzato il componente `DataTable` di Dash Plotly [S55], passando in input i dizionari dei record da mostrare costruiti a partire dai DataFrame pre e post normalizzazione.

5.2.3.2 Vincitori della Buy Box

Una statistica fondamentale nell'esplorazione dei dati è quella che riguarda quali tipologie di venditori risultano vincitori dell'assegnazione della Buy Box. A tal proposito, si visualizzano le percentuali di presenza tra i vincitori della Buy Box di tre specifiche tipologie di venditori, quali Amazon e i venditori di terze parti che aderiscono o meno¹⁰ al programma FBA, su un apposito diagramma a torta realizzato per mezzo della classe `Pie` di Dash Plotly [S56].

Grazie a tale visualizzazione è possibile comprendere la composizione dei vincitori della Buy Box, ottenendo una statistica influente nell'interpretazione dei dati da parte dell'utente.

5.2.3.3 Accuratezza

La metrica dell'accuratezza dell'analisi in Machine Learning fornisce all'utente l'informazione di quanto il modello sia ben addestrato ad effettuare predizioni su nuovi dati sulla base di quanto effettivamente imparato sui dati di addestramento. Grazie a tale metrica, si può capire se l'analisi effettuata con gli input selezionati fornisce dei risultati accurati e di buona qualità¹¹.

Nel caso in cui sia scelto un singolo algoritmo di classificazione, l'accuratezza visualizzata è quella relativa al calcolo relativo a quell'algoritmo, mentre nel caso in cui si sia scelta l'opzione

¹⁰ In questo caso aderiscono al programma FBM.

¹¹ Per questo tipo di lavoro di analisi, si considera di buona qualità un'accuratezza superiore al 95%.

“ALL ALGORITHMS”, per l’applicazione di tutti gli algoritmi di classificazione, la metrica dell’accuratezza è una media delle accuratèzze ottenute dalle singole applicazioni degli algoritmi.

Inoltre, il calcolo dell’accuratezza è influenzato dal metodo di Cross-Validation selezionato per l’addestramento del modello: infatti, per le opzioni basate su K-Fold la misura dell’accuratezza è calcolata come la media dei risultati parziali dell’addestramento del modello sui singoli fold¹².

La realizzazione del componente visuale è stata effettuata mediante la classe `Gauge` di Dash Plotly [S57], con l’indicazione dell’accuratezza in percentuale e una gradazione a colori su quattro livelli: rosso nell’intervallo $[0, 65]$, arancione nell’intervallo $[65, 80]$, giallo nell’intervallo $[80, 95]$ e verde nell’intervallo $[95, 100]$, con quest’ultimo che indica il livello ottimale di bontà dell’accuratezza dell’analisi.

5.2.3.4 Importanza delle caratteristiche

L’importanza delle caratteristiche ha una duplice rappresentazione: una tabellare e una su istogramma. Nella rappresentazione tabellare vengono riportate le caratteristiche in esame con le relative percentuali di importanza per ogni algoritmo di classificazione coinvolto nell’analisi. Nell’istogramma, conseguentemente e coerentemente, vengono riportati i valori presenti in tabella in modo da fornire una visione immediata e semplice dei dati relativi all’importanza delle caratteristiche.

Nel caso in cui sia selezionata l’opzione “ALL ALGORITHMS”, l’istogramma mostra tutte le percentuali di importanza delle caratteristiche in esame per ogni algoritmo, con evidenza della media calcolata per ogni caratteristica. Tale visione rende ancor più immediata e intuitiva l’interpretazione del grafico, mostrando, in maniera ordinata e decrescente, le caratteristiche più importanti e, quindi, influenti nell’assegnazione della Buy Box da parte di Amazon.

Anche in questo caso, come per quello dell’accuratezza, se la scelta del metodo di Cross-Validation ricade su un metodo basato su K-Fold, la misura dell’importanza delle caratteristiche è calcolata sulla base della media dei risultati parziali ottenuti dall’addestramento del modello sui singoli fold.

Per la realizzazione dell’istogramma si è utilizzato il componente `Histogram` di Dash Plotly [S58] passando in input il DataFrame riportante le caratteristiche con le relative importanze per

¹² E’ possibile recuperare dai log applicativi relativi all’analisi in Machine Learning le misure dell’accuratezza minima, massima e media calcolate dai risultati parziali per ogni fold e per ogni modello.

ogni algoritmo di classificazione e quali colonne dello stesso considerare nella rappresentazione sugli assi delle ascisse e delle ordinate.

5.3 Risultati notevoli

Il lavoro di campionamento dei dati da Amazon e l'analisi di essi in Machine Learning tramite l'applicazione Web sviluppata può fornire dei risultati notevoli a seconda di diversi fattori. Infatti, sulla base dei campioni raccolti nel periodo di campionamento¹³ e sugli input selezionati nella piattaforma Web, si possono ottenere risultati diversi che mostrano dei comportamenti di particolare interesse da parte dell'algoritmo di Amazon nell'assegnazione della Buy Box.

In questo paragrafo sono raccolte una serie di osservazioni particolari per le quali, in particolari periodi di osservazione e con specifiche configurazioni di input all'applicazione Web, si evidenziano dei risultati interessanti.

In particolare: per la composizione dell'insieme di dati di input si utilizzano due differenti configurazioni, mentre per l'esecuzione dell'analisi in Machine Learning si utilizza l'opzione "ALL ALGORITHMS" e il metodo "Repeated K-Fold" di Cross-Validation, in modo da avere un quadro generale che comprenda i risultati di tutti i modelli di classificazione, addestrati con il metodo più robusto di Cross-Validation, con evidenza dei pesi medi delle caratteristiche in esame.

La prima configurazione di input, come da figura seguente (fig. 5.8), consente di comporre il DataFrame da analizzare in modo che comprenda tutte le osservazioni rilevate nel periodo prescelto, a patto che presentino un minimo di quattro venditori, dei quali tra i non vincitori della Buy Box ne saranno inclusi i primi otto.

¹³ Definito dal periodo di tempo che va dal 9 Settembre 2024 al 31 Dicembre 2024 (rif. capitolo 3)

Input Data to Machine Learning Analysis

Observation Period: 11-10-2024 → 18-10-2024

Features to consider:

☒ price_diff_prod ☒ price_diff ☒ price_diff_ship ☒ delivery_days
☒ ratings_num ☒ ratings_avg ☒ ratings_perc_positive ☒ fba
☒ amazon ☒ new

Filter Amazon as BuyBox winner:
☐ Yes ☒ No

Filter Amazon as non-BuyBox winner:
☐ Yes ☒ No

Filter New Seller as BuyBox winner:
☐ Yes ☒ No

Filter New Seller as non-BuyBox winner:
☐ Yes ☒ No

Cross Validation Option:
☐ Hold-out (select test size)
☐ k-Fold (10 splits)
☐ Stratified k-Fold (10 splits)
☒ Repeated k-Fold (10 splits, 3 repeats)

Machine Learning Algorithm to use:
ALL ALGORITHMS

Minimum Number of sellers: 3 4 5 6 7 8 9 10

Number of non-buybox winner sellers to consider: 3 4 5 6 7 8 9 10

Figura 5.8: Prima configurazione di input: con Amazon e nuovi venditori

La seconda configurazione di input, come da figura seguente (fig. 5.9), consente di comporre il DataFrame da analizzare in modo che comprenda le osservazioni rilevate nel periodo prescelto eccetto quelle per le quali Amazon o un nuovo venditore risulti vincitore della Buy Box, con il vincolo che presentino un minimo di quattro venditori, dei quali tra i non vincitori della Buy Box ne saranno inclusi i primi dieci, escludendo tra questi sia Amazon che i nuovi venditori.

Input Data to Machine Learning Analysis

Observation Period: 11-10-2024 → 18-10-2024

Features to consider:

☒ price_diff_prod ☒ price_diff ☒ price_diff_ship ☒ delivery_days
☒ ratings_num ☒ ratings_avg ☒ ratings_perc_positive ☒ fba
☐ amazon ☐ new

Filter Amazon as BuyBox winner:
☒ Yes ☐ No

Filter Amazon as non-BuyBox winner:
☒ Yes ☐ No

Filter New Seller as BuyBox winner:
☒ Yes ☐ No

Filter New Seller as non-BuyBox winner:
☒ Yes ☐ No

Cross Validation Option:
☐ Hold-out (select test size)
☐ k-Fold (10 splits)
☐ Stratified k-Fold (10 splits)
☒ Repeated k-Fold (10 splits, 3 repeats)

Machine Learning Algorithm to use:
ALL ALGORITHMS

Minimum Number of sellers: 3 4 5 6 7 8 9 10

Number of non-buybox winner sellers to consider: 3 4 5 6 7 8 9 10

Figura 5.9: Seconda configurazione di input: senza Amazon e senza nuovi venditori

Tali scelte sono motivate dal fatto che i singoli record che afferiscono ad Amazon o ai nuovi venditori possono alterare, con la loro presenza, le statistiche in merito alle recensioni ricevute, in quanto i relativi dati sono nulli e normalizzati a zero.

Inoltre, specificatamente al caso di Amazon come venditore, si dimostra, come è possibile notare nei paragrafi seguenti, che esso è presente come vincitore della Buy Box per più della metà dei campioni raccolti per singolo periodo di osservazione. Pertanto, isolare le osservazioni dove un

altro venditore, diverso da Amazon, risulta vincitore dell'assegnazione della Buy Box consente di evidenziare, specificatamente a queste casistiche, quali caratteristiche influenzano maggiormente la scelta di tale assegnazione.

Proprio riguardo le caratteristiche che sono oggetto delle analisi in Machine Learning, è necessario sottolineare che esse sono scelte differientemente in base alla configurazione di input precedentemente illustrata, secondo la tabella riassuntiva di seguito (tab. 5.3):

Configurazione di input	Caratteristiche incluse nell'analisi
Prima Configurazione (con Amazon e nuovi venditori)	price_diff_prod, price_diff, price_diff_ship, ratings_num, ratings_avg, ratings_perc_positive, delivery_days, fba, amazon, new
Seconda Configurazione (senza Amazon e senza nuovi venditori)	price_diff_prod, price_diff, price_diff_ship, ratings_num, ratings_avg, ratings_perc_positive, delivery_days, fba

Tabella 5.3: Caratteristiche oggetto di analisi in Machine Learning per ogni configurazione di input

Dunque, le due configurazioni presentano un insieme di caratteristiche in comune, quali i dati relativi alle differenze di prezzo¹⁴, alle recensioni¹⁵, ai giorni di consegna e all'affiliazione al programma FBA di Amazon. L'unica differenza risiede nel considerare le caratteristiche `amazon` e `new`, le quali giustamente non vengono considerate nella seconda configurazione in quanto superflue, essendo stati filtrati ed esclusi i dati relativi ad Amazon come venditore e ai nuovi venditori.

Infine, a chiudere la panoramica sulle selezioni degli input, la scelta relativa al metodo di Cross-Validation da applicare all'addestramento dei modelli di Machine Learning è quella di utilizzare il metodo "Repeated K-Fold", tra le opzioni il più robusto anche se computazionalmente oneroso.

Nelle successive sezioni sono illustrate le simulazioni di calcolo con la piattaforma Web con evidenza dei risultati dell'analisi in Machine Learning, prendendo in considerazione alcuni periodi di osservazione notevoli di interesse.

¹⁴ Totale, di prodotto, di spedizione.

¹⁵ Numero, media e percentuali di positive.

5.3.1 Periodo non promozionale (11/10/2024 - 18/10/2024)

Il primo periodo analizzato è quello che non ha previsto iniziative promozionali degne di nota, così da prendere in considerazione dei campioni che rientrano nella usuale vetrina di Amazon, senza subire sollecitazioni dovute alla concorrenza aggressiva da parte dei venditori.

La seguente figura (fig. 5.10) mostra come appare la sezione di input nell'applicazione Web sviluppata, in riferimento alla prima configurazione di input discussa precedentemente, ossia includendo Amazon e i nuovi venditori:

Input Data to Machine Learning Analysis

Observation Period: 11-10-2024 → 18-10-2024

Features to consider:

- price_diff_prod
- price_diff
- price_diff_ship
- delivery_days
- ratings_num
- ratings_avg
- ratings_perc_positive
- fba
- amazon
- new

Filter Amazon as BuyBox winner: ☐ Yes ☒ No

Filter Amazon as non-BuyBox winner: ☐ Yes ☒ No

Filter New Seller as BuyBox winner: ☐ Yes ☒ No

Filter New Seller as non-BuyBox winner: ☐ Yes ☒ No

Minimum Number of sellers: 3 4 5 6 7 8 9 10

Number of non-buybox winner sellers to consider: 3 4 5 6 7 8 9 10

Cross Validation Option:

- ☐ Hold-out (select test size)
- ☐ k-Fold (10 splits)
- ☐ Stratified k-Fold (10 splits)
- ☒ Repeated k-Fold (10 splits, 3 repeats)

Machine Learning Algorithm to use: ALL ALGORITHMS

Figura 5.10: Periodo non promozionale - Sezione di input con prima configurazione (con Amazon e nuovi venditori)

Dall'insieme delle statistiche e dei grafici prodotti nella sezione di output a seguito dell'analisi in Machine Learning per l'input selezionato, mostrati nella figura (fig. 5.11) e nelle tabelle (tab. 5.4, 5.5, 5.6) a pagina seguente, è possibile constatare che le caratteristiche in media più influenti nell'assegnazione della Buy Box sono state `price_diff`, `price_diff_prod` e `amazon`, anche se il distacco rispetto alle altre caratteristiche in esame non è stato così netto.

In effetti, i vari modelli di classificazione hanno portato delle valutazioni abbastanza differenti tra loro e con un'accuratezza media molto elevata e pari al 98%: ad esempio l'algoritmo CART ha attribuito dei pesi maggiori alle caratteristiche `amazon` e `price_diff`, mentre l'algoritmo a reti neurali Multi-Layer Perceptron ha attribuito dei pesi maggiori alle caratteristiche `ratings_avg` e `price_diff`, o ancora il modello Support Vector Machines ha attribuito dei pesi maggiori alle caratteristiche `fba` e `ratings_avg`.

Come evidenzia la media ottenuta, comunque, la caratteristica più influente per l'assegnazione della Buy Box è quella legata al prezzo del prodotto, sia incluso che escluso il costo di spedizione.

Il distacco limitato tra le varie caratteristiche può avere un'interpretazione per la quale in un periodo non promozionale l'algoritmo di assegnazione della Buy Box di Amazon ha una complessità tale da considerare più caratteristiche nella valutazione per decretare il venditore vincitore, con un peso maggiore se il venditore è Amazon e offre un prezzo minore rispetto agli altri venditori concorrenti.

Output Data & Graphs


Normalized Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	15184	0.49	0.33	0	0.25	0.5	0.75	1
price_diff	15184	0.49	0.33	0	0.25	0.5	0.75	1
price_diff_ship	15184	0.09	0.26	0	0	0	0	1
delivery_days	15184	0.39	0.36	0	0	0.33	0.67	1
ratings_num	15184	0.48	0.33	0	0.2	0.5	0.75	1
ratings_avg	15184	0.68	0.31	0	0.67	0.83	0.83	1
ratings_perc_positive	15184	0.59	0.34	0	0.36	0.66	0.89	1
fba	15184	0.3	0.46	0	0	0	1	1
amazon	15184	0.11	0.31	0	0	0	0	1
new	15184	0.02	0.14	0	0	0	0	1

Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	15184	9.45	17.15	-4.95	0.26	3.04	8.29	86.01
price_diff	15184	10.19	17.11	-3.17	1.45	3.58	8.47	86.01
price_diff_ship	15184	0.73	2.09	0	0	0	0	10.99
delivery_days	15184	6.21	3.98	1	3	5	7	26
ratings_num	15184	4592.39	13134.17	0	64	530	2666	82577
ratings_avg	15184	3.77	1.55	0	4	4.5	4.5	5
ratings_perc_positive	15184	73.44	31.49	0	71	84	94	100

Buy Box Winners



Accuracy Score



Features Importance Table

feature	CLASSIFICATION AND REGRESSION TREE	GRADIENT BOOSTING	K-NEAREST NEIGHBORS	LOGISTIC REGRESSION	MULTI-LAYER PERCEPTRON	RANDOM FOREST	SUPPORT VECTOR MACHINES
amazon	26.87	21.34	0.34	24.34	9.02	21.34	6.39
delivery_days	6.76	6.26	18.34	3.49	6	7.12	6.87
fba	4.81	0.85	23.23	8.38	9.71	0.6	31.37
new	0.01	0.1	0.34	0.19	0.15	0.7	0
price_diff	22.48	28.15	10.8	3.39	21.63	22.34	12.98
price_diff_prod	19.84	15.81	32.57	9.19	10.05	21.6	10.06
price_diff_ship	0.17	0.08	0.47	0.87	1.07	0.5	0.11
ratings_avg	3.96	3.08	0.32	29.99	27.1	0.74	16.19
ratings_num	7.47	11.61	12.49	0.35	3.6	9.23	4.25
ratings_perc_positive	7.62	12.71	1.08	19.82	11.67	15.82	11.78

Features Importance Graph




Figura 5.11: Periodo non promozionale - Sezione di output per la prima configurazione (con Amazon e nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	15184	0.49	0.33	0	0.25	0.5	0.75	1
price_diff	15184	0.49	0.33	0	0.25	0.5	0.75	1
price_diff_ship	15184	0.09	0.26	0	0	0	0	1
delivery_days	15184	0.39	0.36	0	0	0.33	0.67	1
ratings_num	15184	0.48	0.33	0	0.2	0.5	0.75	1
ratings_avg	15184	0.68	0.31	0	0.67	0.83	0.83	1
ratings_perc_positive	15184	0.59	0.34	0	0.36	0.66	0.89	1
fba	15184	0.3	0.46	0	0	0	1	1
amazon	15184	0.11	0.31	0	0	0	0	1
new	15184	0.02	0.14	0	0	0	0	1

Tabella 5.4: Periodo non promozionale - Tabella Describe dei dati normalizzati per la prima configurazione
(con Amazon e nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	15184	9.45	17.15	-4.95	0.26	3.04	8.29	86.01
price_diff	15184	10.19	17.11	-3.17	1.45	3.58	8.47	86.01
price_diff_ship	15184	0.73	2.09	0	0	0	0	10.99
delivery_days	15184	6.21	3.98	1	3	5	7	26
ratings_num	15184	4592.39	13134.17	0	64	530	2666	82577
ratings_avg	15184	3.77	1.55	0	4	4.5	4.5	5
ratings_perc_positive	15184	73.44	31.49	0	71	84	94	100

Tabella 5.5: Periodo non promozionale - Tabella Describe dei dati non-normalizzati per la prima configurazione
(con Amazon e nuovi venditori)

Features	Classification And Regression Tree	Gradient Boosting	K-Nearest Neighbors	Logistic Regression	Multi-Layer Perceptron	Random Forest	Support Vector Machines
amazon	26.87	21.34	0.34	24.34	9.02	21.34	6.39
delivery_days	6.76	6.26	18.34	3.49	6	7.12	6.87
fba	4.81	0.85	23.23	8.38	9.71	0.6	31.37
new	0.01	0.1	8.34	0.19	0.15	0.7	0
price_diff	22.48	28.15	10.8	3.39	21.63	22.34	12.98
price_diff_prod	19.84	15.81	32.57	9.19	10.05	21.6	10.06
price_diff_ship	0.17	0.08	0.47	0.87	1.07	0.5	8.11
ratings_avg	3.96	3.08	8.32	29.99	27.1	0.74	16.19
ratings_num	7.47	11.61	12.49	0.35	3.6	9.23	4.25
ratings_perc_positive	7.62	12.71	1.08	19.82	11.67	15.82	11.78

Tabella 5.6: Periodo non promozionale - Tabella Descrive dei dati non-normalizzati per la prima configurazione (con Amazon e nuovi venditori)

Di seguito è riportata la tabella (tab. 5.7) che riporta le percentuali dell'accuratezza minima, media e massima relative all'addestramento dei diversi modelli di classificazione con l'applicazione del metodo Repeated K-Fold di Cross-Validation, estratte dai log applicativi registrati nella fase di analisi in Machine Learning:

Modello di classificazione	Accuratezza		
	min	mean	max
CLASSIFICATION AND REGRESSION TREE	97.43	98.33	98.88
RANDOM FOREST	97.76	98.39	98.94
SUPPORT VECTOR MACHINES	96.91	97.62	98.22
GRADIENT BOOSTING	97.96	98.43	98.88
LOGISTIC REGRESSION	94.99	96.29	97.10
MULTI-LAYER PERCEPTRON	97.30	98.21	98.88
K-NEAREST NEIGHBORS	97.89	98.48	99.14

Tabella 5.7: Periodo non promozionale - Tabella riepilogativa dell'Accuratezza per la prima configurazione (con Amazon e nuovi venditori)

Rimuovendo Amazon e i nuovi venditori con la seconda configurazione di input si ha la seguente sezione di input (fig. 5.12):

Input Data to Machine Learning Analysis

Observation Period: 11-10-2024 → 18-10-2024

Features to consider:

- price_diff_prod
- price_diff
- price_diff_ship
- delivery_days
- ratings_num
- ratings_avg
- ratings_perc_positive
- fba

Filter Amazon as BuyBox winner: ☒ Yes ☐ No

Filter Amazon as non-BuyBox winner: ☒ Yes ☐ No

Filter New Seller as BuyBox winner: ☒ Yes ☐ No

Filter New Seller as non-BuyBox winner: ☒ Yes ☐ No

Cross Validation Option:

- ☐ Hold-out (select test size)
- ☐ k-Fold (10 splits)
- ☐ Stratified k-Fold (10 splits)
- ☒ Repeated k-Fold (10 splits, 3 repeats)

Machine Learning Algorithm to use: ALL ALGORITHMS

Figura 5.12: Periodo non promozionale - Sezione di input con seconda configurazione (senza Amazon e senza nuovi venditori)

Dall'insieme delle statistiche e dei grafici prodotti nella sezione di output a seguito dell'analisi in Machine Learning per l'input selezionato, mostrata nella figura (fig. 5.13) e nelle tabelle (tab. 5.8, 5.9, 5.10) a pagina seguente, è possibile constatare che le caratteristiche in media più influenti nell'assegnazione della Buy Box sono state `price_diff` e `fba`.

Questa analisi, la cui accuratezza media si attesta al 95.2%, fornisce delle informazioni di notevole interesse.

In primo luogo conferma che nel periodo non promozionale è la differenza di prezzo totale la caratteristica più influente nell'assegnazione della Buy Box, coerentemente con quanto precedentemente analizzato includendo Amazon e i nuovi venditori.

In secondo luogo, a fronte del minoritario 31.5% di venditori di terze parti che si affidano al programma FBA e che sono vincitori della Buy Box, la caratteristica `fba` risulta molto influente nell'assegnazione della stessa.

Se si considera l'insieme delle caratteristiche influenti includendo le successive in ordine di classifica media `ratings_num`, `ratings_perc_positive` e `delivery_days`, è possibile fornire un'interpretazione delle analisi per la quale nel periodo sopracitato i venditori di terze parti per aumentare la probabilità di vincere l'assegnazione della Buy Box hanno offerto i loro prodotti ad un prezzo totale, inclusa la spedizione, più basso rispetto ai concorrenti affiliandosi altresì al programma FBA, oppure provvedendo alla spedizione per proprio conto potendo contare su buone e numerose recensioni e tempi di consegna rapidi.

Output Data & Graphs


Normalized Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	4931	0.52	0.36	0	0.17	0.5	0.83	1
price_diff	4931	0.51	0.36	0	0.17	0.5	0.83	1
price_diff_ship	4931	0.05	0.2	0	0	0	0	1
delivery_days	4931	0.41	0.43	0	0	0.33	1	1
ratings_num	4931	0.5	0.33	0	0.2	0.5	0.8	1
ratings_avg	4931	0.75	0.25	0	0.6	0.8	1	1
ratings_perc_positive	4931	0.68	0.31	0	0.46	0.79	0.96	1
fba	4931	0.33	0.47	0	0	0	1	1

Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	4931	3.71	4.81	-4.49	0	2.36	5.43	22.4
price_diff	4931	4.15	5.3	-2.09	0.1	2.6	5.43	22.4
price_diff_ship	4931	0.44	1.67	0	0	0	0	7.5
delivery_days	4931	4.46	1.88	1	3	4	6	18
ratings_num	4931	5566.86	15640.43	2	160	525	1817	82577
ratings_avg	4931	4.34	0.8	1	4	4.5	5	5
ratings_perc_positive	4931	84.64	20.17	0	77	92	99	100

Buy Box Winners



Accuracy Score



Features Importance Table

feature	CLASSIFICATION AND REGRESSION TREE	GRADIENT BOOSTING	K-NEAREST NEIGHBORS	LOGISTIC REGRESSION	MULTI-LAYER PERCEPTRON	RANDOM FOREST	SUPPORT VECTOR MACHINES
delivery_days	8.15	5.03	24.48	8.49	11.25	9.02	7.61
fba	7.11	0.91	48.26	28.12	24.85	1.4	32.7
price_diff	38.09	49.42	7.58	28.02	33.28	51.6	27
price_diff_prod	12.88	7.35	3.43	3.59	7.86	4.68	5.98
price_diff_ship	0.57	0.7	0.68	0.37	0.91	2.25	0.57
ratings_avg	12.89	6.47	0.48	4.76	3.92	3.89	8.08
ratings_num	11.18	14.92	12.84	9.43	6.14	16.04	7.21
ratings_perc_positive	9.13	15.2	2.25	17.23	11.79	11.13	10.87

Features Importance Graph




Figura 5.13: Periodo non promozionale - Sezione di output per la seconda configurazione (senza Amazon e senza nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	4931	0.52	0.36	0	0.17	0.5	0.83	1
price_diff	4931	0.51	0.36	0	0.17	0.5	0.83	1
price_diff_ship	4931	0.05	0.2	0	0	0	0	1
delivery_days	4931	0.41	0.43	0	0	0.33	1	1
ratings_num	4931	0.5	0.33	0	0.2	0.5	0.8	1
ratings_avg	4931	0.75	0.25	0	0.6	0.8	1	1
ratings_perc_positive	4931	0.68	0.31	0	0.46	0.79	0.96	1
fba	4931	0.33	0.47	0	0	0	1	1
amazon	4931	0.52	0.36	0	0.17	0.5	0.83	1
new	4931	0.51	0.36	0	0.17	0.5	0.83	1

Tabella 5.8: Periodo non promozionale - Tabella Describe dei dati normalizzati per la seconda configurazione (senza Amazon e senza nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	4931	3.71	4.81	-4.49	0	2.36	5.43	22.4
price_diff	4931	4.15	5.3	-2.09	0.1	2.6	5.43	22.4
price_diff_ship	4931	0.44	1.67	0	0	0	0	7.5
delivery_days	4931	4.46	1.88	1	3	4	6	18
ratings_num	4931	5566.86	15640.43	2	160	525	1817	82577
ratings_avg	4931	4.34	0.8	1	4	4.5	5	5
ratings_perc_positive	4931	84.64	20.17	0	77	92	99	100

Tabella 5.9: Periodo non promozionale - Tabella Describe dei dati non-normalizzati per la seconda configurazione (senza Amazon e senza nuovi venditori)

Features	Classification And Regression Tree	Gradient Boosting	K-Nearest Neighbors	Logistic Regression	Multi-Layer Perceptron	Random Forest	Support Vector Machines
delivery_days	8.15	5.03	24.48	8.49	11.25	9.02	7.61
fba	7.11	0.91	48.26	28.12	24.85	1.4	32.7
price_diff	38.09	49.42	7.58	28.02	33.28	51.6	27
price_diff_prod	12.88	7.35	3.43	3.59	7.86	4.68	5.98
price_diff_ship	0.57	0.7	0.68	0.37	0.91	2.25	0.57
ratings_avg	12.89	6.47	0.48	4.76	3.92	3.89	8.08
ratings_num	11.18	14.92	12.84	9.43	6.14	16.04	7.21
ratings_perc_positive	9.13	15.2	2.25	17.23	11.79	11.13	10.87

Tabella 5.10: Periodo non promozionale - Tabella Descrive dei dati non-normalizzati per la seconda configurazione (senza Amazon e senza nuovi venditori)

Di seguito è riportata la tabella (tab. 5.11) che riporta le percentuali dell'accuratezza minima, media e massima relative all'addestramento dei diversi modelli di classificazione con l'applicazione del metodo Repeated K-Fold di Cross-Validation, estratte dai log applicativi registrati nella fase di analisi in Machine Learning:

Modello di classificazione	Accuratezza		
	min	mean	max
CLASSIFICATION AND REGRESSION TREE	93.51	95.34	96.75
RANDOM FOREST	93.91	95.32	96.75
SUPPORT VECTOR MACHINES	93.71	95.59	96.96
GRADIENT BOOSTING	93.91	95.42	96.96
LOGISTIC REGRESSION	92.29	94.07	95.54
MULTI-LAYER PERCEPTRON	94.52	95.92	97.97
K-NEAREST NEIGHBORS	92.49	94.5	96.35

Tabella 5.11: Periodo non promozionale - Tabella riepilogativa dell'Accuratezza per la seconda configurazione (senza Amazon e senza nuovi venditori)

5.3.2 Periodo del Black Friday (21/11/2024 - 02/12/2024)

Il Black Friday è un evento commerciale annuale che si svolge solitamente il venerdì successivo al Giorno del Ringraziamento negli Stati Uniti, e che negli ultimi anni si è diffuso a livello globale, Italia compresa. Per l'edizione del 2024 la data esatta è il 29 Novembre 2024, tuttavia, come ormai consuetudine, molte aziende tendono ad anticipare le offerte, allungando così il periodo promozionale che spesso si estende per tutta la settimana o addirittura per tutto il mese di Novembre¹⁶. Per quanto riguarda Amazon, il periodo promozionale è stato esteso nel periodo che va dal 21 Novembre 2024 al 02 Dicembre 2024, pertanto si sono operate le opportune analisi in Machine Learning con i campioni rilevati in questo periodo.

La seguente figura (fig. 5.14) mostra come appare la sezione di input nell'applicazione Web sviluppata, in riferimento alla prima configurazione di input discussa precedentemente, ossia includendo Amazon e i nuovi venditori:

Input Data to Machine Learning Analysis

Observation Period: 21-11-2024 → 02-12-2024

Features to consider:

- ☒ price_diff_prod
- ☒ price_diff
- ☒ price_diff_ship
- ☒ delivery_days
- ☒ ratings_num
- ☒ ratings_avg
- ☒ ratings_perc_positive
- ☒ fba
- ☒ amazon
- ☒ new

Filter Amazon as BuyBox winner:

☐ Yes

☒ No

Filter Amazon as non-BuyBox winner:

☐ Yes

☒ No

Filter New Seller as BuyBox winner:

☐ Yes

☒ No

Filter New Seller as non-BuyBox winner:

☐ Yes

☒ No

Minimum Number of sellers: 3 4 5 6 7 8 9 10

Number of non-buybox winner sellers to consider: 3 4 5 6 7 8 9 10

Cross Validation Option:

☐ Hold-out (select test size)

☐ k-Fold (10 splits)

☐ Stratified k-Fold (10 splits)

☒ Repeated k-Fold (10 splits, 3 repeats)

Machine Learning Algorithm to use:

ALL ALGORITHMS

Figura 5.14: Periodo del Black Friday - Sezione di input con prima configurazione (con Amazon e nuovi venditori)

Dall'insieme delle statistiche e dei grafici prodotti nella sezione di output (fig. 5.15) (tab. 5.12, 5.13, 5.14) a seguito dell'analisi in Machine Learning, è possibile constatare che le caratteristiche in media più influenti nell'assegnazione della Buy Box nel periodo del Black Friday 2024 sono state `price_diff`, `delivery_days` e `fba`, con un'accuratezza media del 97.8%. Ciò si può tradurre nell'affermazione che, durante il periodo suddetto, è stato molto probabile vincere l'assegnazione della Buy Box per quei venditori che hanno venduto i loro prodotti al prezzo più basso, con la più veloce consegna e affiliandosi al programma FBA di Amazon. Da notare che la caratteristica `amazon` non risulta tra quelle con il maggior peso, anche se Amazon come venditore risulta vincitore della Buy Box per il 63.8% delle osservazioni.

¹⁶ Questo fenomeno è noto come “Black Week” o “Cyber Week”.

Output Data & Graphs


Normalized Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	24377	0.47	0.33	0	0.17	0.5	0.75	1
price_diff	24377	0.47	0.34	0	0.14	0.5	0.75	1
price_diff_ship	24377	0.11	0.28	0	0	0	0	1
delivery_days	24377	0.42	0.34	0	0	0.4	0.67	1
ratings_num	24377	0.48	0.33	0	0.17	0.5	0.75	1
ratings_avg	24377	0.68	0.3	0	0.67	0.83	0.83	1
ratings_perc_positive	24377	0.59	0.33	0	0.38	0.65	0.88	1
fba	24377	0.25	0.43	0	0	0	0	1
amazon	24377	0.11	0.31	0	0	0	0	1
new	24377	0.02	0.14	0	0	0	0	1

Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	24377	5.79	7.44	-6.81	0.1	3.55	7.51	32.21
price_diff	24377	6.59	7.42	-6.81	0.59	4.83	8.08	32.21
price_diff_ship	24377	0.8	2.13	0	0	0	0	10.99
delivery_days	24377	7.33	4.19	2	4	6	10	35
ratings_num	24377	3652.79	10078.96	0	64	646	2463	83905
ratings_avg	24377	3.76	1.55	0	4	4.5	4.5	5
ratings_perc_positive	24377	72.88	31.36	0	70	83	94	100

Buy Box Winners



Accuracy Score



Features Importance Table

feature	CLASSIFICATION AND REGRESSION TREE	GRADIENT BOOSTING	K-NEAREST NEIGHBORS	LOGISTIC REGRESSION	MULTI-LAYER PERCEPTRON	RANDOM FOREST	SUPPORT VECTOR MACHINES
amazon	13.46	1.59	0.09	23.97	6.68	0.55	0.14
delivery_days	17.39	20.44	30.32	12.81	17.41	26.64	18.88
fba	10.25	22.92	12.87	8.81	17.51	9.31	27.86
new	0	0.05	0.09	0.49	0.08	0.12	0.72
price_diff	31.61	39.9	14.14	37.19	21.11	50.23	34.29
price_diff_prod	15.23	4.14	30	7.41	14.71	4.45	6.66
price_diff_ship	0.66	0.05	0.46	2.7	2.37	0.13	2.54
ratings_avg	2.08	0.78	0.04	0.18	6.38	0.61	4.64
ratings_num	4.69	3.83	9.85	6.19	8.5	3.9	3.32
ratings_perc_positive	4.62	6.29	2.13	0.25	5.25	4.05	0.97

Features Importance Graph




Figura 5.15: Periodo del Black Friday - Sezione di output per la prima configurazione (con Amazon e nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	24377	0.47	0.33	0	0.17	0.5	0.75	1
price_diff	24377	0.47	0.34	0	0.14	0.5	0.75	1
price_diff_ship	24377	0.11	0.28	0	0	0	0	1
delivery_days	24377	0.42	0.34	0	0	0.4	0.67	1
ratings_num	24377	0.48	0.33	0	0.17	0.5	0.75	1
ratings_avg	24377	0.68	0.3	0	0.67	0.83	0.83	1
ratings_perc_positive	24377	0.59	0.33	0	0.38	0.65	0.88	1
fba	24377	0.25	0.43	0	0	0	0	1
amazon	24377	0.11	0.31	0	0	0	0	1
new	24377	0.02	0.14	0	0	0	0	1

Tabella 5.12: Periodo del Black Friday - Tabella Descrive dei dati normalizzati per la prima configurazione (con Amazon e nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	24377	5.79	7.44	-6.81	0.1	3.55	7.51	32.21
price_diff	24377	6.59	7.42	-6.81	0.59	4.83	8.08	32.21
price_diff_ship	24377	0.8	2.13	0	0	0	0	10.99
delivery_days	24377	7.33	4.19	2	4	6	10	35
ratings_num	24377	3652.79	10078.96	0	64	646	2463	83905
ratings_avg	24377	3.76	1.55	0	4	4.5	4.5	5
ratings_perc_positive	24377	72.88	31.36	0	70	83	94	100

Tabella 5.13: Periodo del Black Friday - Tabella Descrive dei dati non-normalizzati per la prima configurazione (con Amazon e nuovi venditori)

Features	Classificati on And Regression Tree	Gradient Boosting	K-Nearest Neighbors	Logistic Regression	Multi- Layer Perceptron	Random Forest	Support Vector Machines
amazon	13.46	1.59	0.09	23.97	6.68	0.55	0.14
delivery_ days	17.39	20.44	30.32	12.81	17.41	26.64	18.88
fba	10.25	22.92	12.87	8.81	17.51	9.31	27.86
new	0	0.05	0.09	0.49	0.08	0.12	0.72
price_diff	31.61	39.9	14.14	37.19	21.11	50.23	34.29
price_diff_ prod	15.23	4.14	30	7.41	14.71	4.45	6.66
price_diff_ ship	0.66	0.05	0.46	2.7	2.37	0.13	2.54
ratings_avg	2.08	0.78	0.04	0.18	6.38	0.61	4.64
ratings_num	4.69	3.83	9.85	6.19	8.5	3.9	3.32
ratings_perc _positive	4.62	6.29	2.13	0.25	5.25	4.05	0.97

Tabella 5.14: Periodo del Black Friday - Tabella Descrive dei dati non-normalizzati per la prima configurazione (con Amazon e nuovi venditori)

Di seguito è riportata la tabella (tab. 5.15) che riporta le percentuali dell'accuratezza minima, media e massima relative all'addestramento dei diversi modelli di classificazione con l'applicazione del metodo Repeated K-Fold di Cross-Validation, estratte dai log applicativi registrati nella fase di analisi in Machine Learning:

Modello di classificazione	Accuratezza		
	min	mean	max
CLASSIFICATION AND REGRESSION TREE	97.78	98.23	98.65
RANDOM FOREST	97.58	98.26	98.93
SUPPORT VECTOR MACHINES	96.43	97.14	97.74
GRADIENT BOOSTING	97.83	98.30	98.73
LOGISTIC REGRESSION	96.35	96.97	97.50
MULTI-LAYER PERCEPTRON	97.25	97.95	98.69
K-NEAREST NEIGHBORS	97.42	97.92	98.40

Tabella 5.15: Periodo del Black Friday - Tabella riepilogativa dell'Accuratezza per la prima configurazione (con Amazon e nuovi venditori)

Rimuovendo Amazon e i nuovi venditori con la seconda configurazione di input si ha la seguente sezione di input (fig. 5.16):

Input Data to Machine Learning Analysis

Observation Period: 21-11-2024 → 02-12-2024

Features to consider:

- price_diff_prod
- price_diff
- price_diff_ship
- delivery_days
- ratings_num
- ratings_avg
- ratings_perc_positive
- fba

Filter Amazon as BuyBox winner: ☒ Yes ☐ No

Filter Amazon as non-BuyBox winner: ☒ Yes ☐ No

Filter New Seller as BuyBox winner: ☒ Yes ☐ No

Filter New Seller as non-BuyBox winner: ☒ Yes ☐ No

Minimum Number of sellers: 3 4 5 6 7 8 9 10

Number of non-buybox winner sellers to consider: 3 4 5 6 7 8 9 10

Cross Validation Option:

- ☐ Hold-out (select test size)
- ☐ k-Fold (10 splits)
- ☐ Stratified k-Fold (10 splits)
- ☒ Repeated k-Fold (10 splits, 3 repeats)

Machine Learning Algorithm to use: ALL ALGORITHMS

Figura 5.16: Periodo del Black Friday - Sezione di input con seconda configurazione
(senza Amazon e senza nuovi venditori)

In questo caso la sezione di output (fig. 5.17) (tab. 5.16, 5.17, 5.18) mostra delle statistiche che ricalcano quanto precedentemente illustrato con la prima configurazione, anche se con una misura dell'accuratezza media inferiore, che si attesta sul 94.3%.

Le caratteristiche più influenti nell'assegnazione della Buy Box sono `price_diff`, `delivery_days` e `fba`, seguite dalle caratteristiche riguardanti le recensioni, quali `ratings_num`, `ratings_perc_positive` e `rating_avg`.


Anche in questo caso l'interpretazione è che è stato molto probabile vincere l'assegnazione della Buy Box per quei venditori che hanno venduto i loro prodotti al prezzo più basso, con la più veloce consegna e affiliandosi al programma FBA di Amazon.

Da queste prime analisi risulta evidente come il prezzo del prodotto giochi un ruolo di primaria importanza nell'assegnazione della Buy Box, mentre vi sono delle caratteristiche secondarie che in base al periodo possono rivelarsi altrettanto importanti, come i giorni di consegna nel periodo del Black Friday preso in esame.

Output Data & Graphs

Normalized Features Dataset Describe Table									Features Dataset Describe Table								
feature	count	mean	std	min	25%	50%	75%	max	feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	8048	0.43	0.36	0	0	0.4	0.75	1	price_diff_prod	8048	3.55	5.75	-4.64	0	0.65	5.01	22.07
price_diff	8048	0.42	0.36	0	0	0.4	0.75	1	price_diff	8048	3.97	6.19	-4.64	0	0.69	6.17	22.07
price_diff_ship	8048	0.05	0.19	0	0	0	0	1	price_diff_ship	8048	0.42	1.65	0	0	0	0	7.5
delivery_days	8048	0.37	0.36	0	0	0.33	0.67	1	delivery_days	8048	6.59	4.08	2	4	5	8	35
ratings_num	8048	0.49	0.33	0	0.2	0.5	0.8	1	ratings_num	8048	6605.1	15617.07	3	172	744	5522	83905
ratings_avg	8048	0.75	0.25	0	0.6	0.8	1	1	ratings_avg	8048	4.32	0.8	1	4	4.5	5	5
ratings_perc_positive	8048	0.69	0.28	0	0.5	0.76	0.93	1	ratings_perc_positive	8048	83.92	19.56	0	76	90	97	100
fba	8048	0.24	0.43	0	0	0	0	1									

Buy Box Winners



Accuracy Score



Features Importance Table

feature	CLASSIFICATION AND REGRESSION TREE	GRADIENT BOOSTING	K-NEAREST NEIGHBORS	LOGISTIC REGRESSION	MULTI-LAYER PERCEPTRON	RANDOM FOREST	SUPPORT VECTOR MACHINES
delivery_days	19.38	23.36	26.28	7.17	19.63	33.6	27.95
fba	11.36	8.78	31.39	5.7	10.67	12.71	23.1
price_diff	27.3	39.4	6.79	27.22	31.21	27.68	25.06
price_diff_prod	13.2	3.72	5.24	1.81	12.65	7.84	2.92
price_diff_ship	0.01	0.09	3.13	0.18	1.23	0.01	0.28
ratings_avg	9.82	0.87	2.95	25.94	8.24	1.31	5.17
ratings_num	10.44	11.85	24.12	9.5	13.62	8.7	12.8
ratings_perc_positive	8.49	11.93	0.1	22.47	2.74	8.16	2.72

Features Importance Graph




Figura 5.17: Periodo del Black Friday - Sezione di output per la seconda configurazione (senza Amazon e senza nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	8048	0.43	0.36	0	0	0.4	0.75	1
price_diff	8048	0.42	0.36	0	0	0.4	0.75	1
price_diff_ship	8048	0.05	0.19	0	0	0	0	1
delivery_days	8048	0.37	0.36	0	0	0.33	0.67	1
ratings_num	8048	0.49	0.33	0	0.2	0.5	0.8	1
ratings_avg	8048	0.75	0.25	0	0.6	0.8	1	1
ratings_perc_positive	8048	0.69	0.28	0	0.5	0.76	0.93	1
fba	8048	0.24	0.43	0	0	0	0	1

Tabella 5.16: Periodo del Black Friday - Tabella Describe dei dati normalizzati per la seconda configurazione (senza Amazon e senza nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	8048	3.55	5.75	-4.64	0	0.65	5.01	22.07
price_diff	8048	3.97	6.19	-4.64	0	0.69	6.17	22.07
price_diff_ship	8048	0.42	1.65	0	0	0	0	7.5
delivery_days	8048	6.59	4.08	2	4	5	8	35
ratings_num	8048	6605.1	15617.07	3	172	744	5522	83905
ratings_avg	8048	4.32	0.8	1	4	4.5	5	5
ratings_perc_positive	8048	83.92	19.56	0	76	90	97	100

Tabella 5.17: Periodo del Black Friday - Tabella Describe dei dati non-normalizzati per la seconda configurazione (senza Amazon e senza nuovi venditori)

Features	Classification And Regression Tree	Gradient Boosting	K-Nearest Neighbors	Logistic Regression	Multi-Layer Perceptron	Random Forest	Support Vector Machines
delivery_days	19.38	23.36	26.28	7.17	19.63	33.6	27.95
fba	11.36	8.78	31.39	5.7	10.67	12.71	23.1
price_diff	27.3	39.4	6.79	27.22	31.21	27.68	25.06
price_diff_prod	13.2	3.72	5.24	1.81	12.65	7.84	2.92
price_diff_ship	0.01	0.09	3.13	0.18	1.23	0.01	0.28
ratings_avg	9.82	0.87	2.95	25.94	8.24	1.31	5.17
ratings_num	10.44	11.85	24.12	9.5	13.62	8.7	12.8
ratings_perc_positive	8.49	11.93	0.1	22.47	2.74	8.16	2.72

Tabella 5.18: Periodo del Black Friday - Tabella Descrive dei dati non-normalizzati per la seconda configurazione (senza Amazon e senza nuovi venditori)

Di seguito è riportata la tabella (tab. 5.19) che riporta le percentuali dell'accuratezza minima, media e massima relative all'addestramento dei diversi modelli di classificazione con l'applicazione del metodo Repeated K-Fold di Cross-Validation, estratte dai log applicativi registrati nella fase di analisi in Machine Learning:

Modello di classificazione	Accuratezza		
	min	mean	max
CLASSIFICATION AND REGRESSION TREE	94.04	95.45	96.65
RANDOM FOREST	93.54	95.54	96.89
SUPPORT VECTOR MACHINES	91.68	93.99	95.16
GRADIENT BOOSTING	93.54	95.43	96.77
LOGISTIC REGRESSION	89.81	91.92	93.29
MULTI-LAYER PERCEPTRON	93.79	95.27	96.02
K-NEAREST NEIGHBORS	91.06	92.74	94.29

Tabella 5.19: Periodo del Black Friday - Tabella riepilogativa dell'Accuratezza per la seconda configurazione (senza Amazon e senza nuovi venditori)

5.3.3 Periodo delle Feste di Natale (15/12/2024 - 22/12/2024)

Il periodo delle festività natalizie rappresenta un periodo particolarmente redditizio per il settore dell'e-commerce, determinando un significativo incremento del fatturato complessivo. Proprio la ricerca, da parte dei consumatori, di regali di Natale per i propri amici e familiari, spinge i venditori ad una concorrenza spietata per vendere i loro prodotti.

Per l'analisi nel periodo delle Feste di Natale si è preso di riferimento il periodo che va dal 15 al 22 Dicembre 2024, corrispondente alla settimana precedente a quella di Natale utile agli ultimi acquisti, con la possibilità, o meglio la speranza, da parte del consumatore di ottenere una consegna entro Natale dei prodotti.

La seguente figura (fig. 5.18) mostra come appare la sezione di input nell'applicazione Web sviluppata, in riferimento alla prima configurazione di input discussa in precedenza, ossia includendo Amazon e i nuovi venditori:

Input Data to Machine Learning Analysis

Observation Period: 15-12-2024 → 22-12-2024

Features to consider:

- ☒ price_diff_prod
- ☒ price_diff
- ☒ price_diff_ship
- ☒ delivery_days
- ☒ ratings_num
- ☒ ratings_avg
- ☒ ratings_perc_positive
- ☒ fba
- ☒ amazon
- ☒ new

Filter Amazon as BuyBox winner: ☐ Yes ☒ No

Filter Amazon as non-BuyBox winner: ☐ Yes ☒ No

Filter New Seller as BuyBox winner: ☐ Yes ☒ No

Filter New Seller as non-BuyBox winner: ☐ Yes ☒ No

Cross Validation Option:

- ☐ Hold-out (select test size)
- ☐ k-Fold (10 splits)
- ☐ Stratified k-Fold (10 splits)
- ☒ Repeated k-Fold (10 splits, 3 repeats)

Machine Learning Algorithm to use: ALL ALGORITHMS

Figura 5.18: Periodo delle Feste di Natale - Sezione di input con prima configurazione
(con Amazon e nuovi venditori)

Dall'insieme delle statistiche e dei grafici prodotti nella sezione di output a seguito dell'analisi in Machine Learning per l'input selezionato, mostrata nella figura (fig. 5.19) e nelle tabelle (tab. 5.20, 5.21, 5.22) a pagina seguente, è possibile constatare che le caratteristiche in media più influenti nell'assegnazione della Buy Box sono state `price_diff`, `price_diff_pro` e `fba`, anche se il distacco di quest'ultima rispetto alle altre caratteristiche in esame non è stato così netto. Infatti, troviamo subito sotto nella classifica media anche caratteristiche come `amazon` e `ratings_num`. Con la presenza di Amazon, la cui percentuale di vittoria della Buy Box si attesta al 70.2%, i risultati delle analisi suggeriscono che per vincere la Buy Box nel periodo suddetto è stato necessario offrire i prodotti ad un prezzo minimo di mercato rispetto ai concorrenti.

Output Data & Graphs


Normalized Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	15052	0.48	0.33	0	0.2	0.5	0.75	1
price_diff	15052	0.48	0.33	0	0.2	0.5	0.75	1
price_diff_ship	15052	0.13	0.31	0	0	0	0	1
delivery_days	15052	0.43	0.34	0	0	0.4	0.75	1
ratings_num	15052	0.49	0.33	0	0.25	0.5	0.75	1
ratings_avg	15052	0.72	0.28	0	0.71	0.86	0.86	1
ratings_perc_positive	15052	0.58	0.33	0	0.32	0.61	0.86	1
fba	15052	0.24	0.42	0	0	0	0	1
amazon	15052	0.09	0.29	0	0	0	0	1
new	15052	0.01	0.12	0	0	0	0	1

Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	15052	6.22	9.89	-4.95	0	3.1	8.09	72.03
price_diff	15052	7.24	10.42	-4.95	0.2	4.08	9.06	77.53
price_diff_ship	15052	1.03	2.53	0	0	0	0	23.5
delivery_days	15052	11.87	8.3	0	4	11	17	63
ratings_num	15052	4220.16	10844.9	0	113	707	2683	84313
ratings_avg	15052	3.85	1.42	0	4	4.5	4.5	5
ratings_perc_positive	15052	75.06	28.9	0	70	83	94	100

Buy Box Winners



Accuracy Score



Features Importance Table

feature	CLASSIFICATION AND REGRESSION TREE	GRADIENT BOOSTING	K-NEAREST NEIGHBORS	LOGISTIC REGRESSION	MULTI-LAYER PERCEPTRON	RANDOM FOREST	SUPPORT VECTOR MACHINES
amazon	27.04	32.29	0.05	1.36	9.57	1.24	0.79
delivery_days	4.98	5.83	11.88	4.9	10.37	8.13	9.29
fba	11.03	5.95	22.45	9.06	11.97	6.04	22.1
new	0	0.02	0.05	0.04	0.07	0.07	0.25
price_diff	24.62	31.47	17.05	6	17.33	52.25	24.9
price_diff_prod	13.89	7.83	22.34	26.44	19.12	11.87	19.04
price_diff_ship	0.46	0.02	0.34	5.1	3.76	0.08	1.59
ratings_avg	3.31	0.1	0.05	36.12	11.62	0.36	10.17
ratings_num	8.08	8.98	22.44	4.87	12.35	10.22	5.22
ratings_perc_positive	6.6	7.52	3.37	6.1	3.84	9.74	6.64

Features Importance Graph




Figura 5.19: Periodo delle Feste di Natale - Sezione di output per la prima configurazione (con Amazon e nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	15052	0.48	0.33	0	0.2	0.5	0.75	1
price_diff	15052	0.48	0.33	0	0.2	0.5	0.75	1
price_diff_ship	15052	0.13	0.31	0	0	0	0	1
delivery_days	15052	0.43	0.34	0	0	0.4	0.75	1
ratings_num	15052	0.49	0.33	0	0.25	0.5	0.75	1
ratings_avg	15052	0.72	0.28	0	0.71	0.86	0.86	1
ratings_perc_positive	15052	0.58	0.33	0	0.32	0.61	0.86	1
fba	15052	0.24	0.42	0	0	0	0	1
amazon	15052	0.09	0.29	0	0	0	0	1
new	15052	0.01	0.12	0	0	0	0	1

Tabella 5.20: Periodo delle Feste di Natale - Tabella Describe dei dati normalizzati per la prima configurazione (con Amazon e nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	15052	6.22	9.89	-4.95	0	3.1	8.09	72.03
price_diff	15052	7.24	10.42	-4.95	0.2	4.08	9.06	77.53
price_diff_ship	15052	1.03	2.53	0	0	0	0	23.5
delivery_days	15052	11.87	8.3	0	4	11	17	63
ratings_num	15052	4220.16	10844.9	0	113	707	2683	84313
ratings_avg	15052	3.85	1.42	0	4	4.5	4.5	5
ratings_perc_positive	15052	75.06	28.9	0	70	83	94	100

Tabella 5.21: Periodo delle Feste di Natale - Tabella Describe dei dati non-normalizzati per la prima configurazione (con Amazon e nuovi venditori)

Features	Classification And Regression Tree	Gradient Boosting	K-Nearest Neighbors	Logistic Regression	Multi-Layer Perceptron	Random Forest	Support Vector Machines
amazon	27.04	32.29	0.05	1.36	9.57	1.24	0.79
delivery_days	4.98	5.83	11.88	4.9	10.37	8.13	9.29
fba	11.03	5.95	22.45	9.06	11.97	6.04	22.1
new	0	0.02	0.05	0.04	0.07	0.07	0.25
price_diff	24.62	31.47	17.05	6	17.33	52.25	24.9
price_diff_prod	13.89	7.83	22.34	26.44	19.12	11.87	19.04
price_diff_ship	0.46	0.02	0.34	5.1	3.76	0.08	1.59
ratings_avg	3.31	0.1	0.05	36.12	11.62	0.36	10.17
ratings_num	8.08	8.98	22.44	4.87	12.35	10.22	5.22
ratings_perc_positive	6.6	7.52	3.37	6.1	3.84	9.74	6.64

Tabella 5.22: Periodo delle Feste di Natale - Tabella Descrive dei dati non-normalizzati per la prima configurazione (con Amazon e nuovi venditori)


Di seguito è riportata la tabella (tab. 5.23) che riporta le percentuali dell'accuratezza minima, media e massima relative all'addestramento dei diversi modelli di classificazione con l'applicazione del metodo Repeated K-Fold di Cross-Validation, estratte dai log applicativi registrati nella fase di analisi in Machine Learning:

Modello di classificazione	Accuratezza		
	min	mean	max
CLASSIFICATION AND REGRESSION TREE	98.14	99.13	99.60
RANDOM FOREST	98.74	99.27	99.73
SUPPORT VECTOR MACHINES	97.21	97.92	98.74
GRADIENT BOOSTING	98.87	99.28	99.93
LOGISTIC REGRESSION	96.15	96.92	97.94
MULTI-LAYER PERCEPTRON	98.21	98.87	99.34
K-NEAREST NEIGHBORS	98.54	99.15	99.53

Tabella 5.23: Periodo delle Feste di Natale - Tabella riepilogativa dell'Accuratezza per la prima configurazione (con Amazon e nuovi venditori)

Rimuovendo Amazon e i nuovi venditori con la seconda configurazione di input si ha la seguente sezione di input (fig. 5.20):

Input Data to Machine Learning Analysis



Observation Period: 15-12-2024 → 22-12-2024

Features to consider:

- price_diff_prod
- price_diff
- price_diff_ship
- delivery_days
- ratings_num
- ratings_avg
- ratings_perc_positive
- fba

Filter Amazon as BuyBox winner: ☒ Yes ☐ No

Filter Amazon as non-BuyBox winner: ☒ Yes ☐ No

Filter New Seller as BuyBox winner: ☒ Yes ☐ No

Filter New Seller as non-BuyBox winner: ☒ Yes ☐ No

Minimum Number of sellers: 4

Number of non-buybox winner sellers to consider: 10

Cross Validation Option:

- ☐ Hold-out (select test size)
- ☐ k-Fold (10 splits)
- ☐ Stratified k-Fold (10 splits)
- ☒ Repeated k-Fold (10 splits, 3 repeats)

Machine Learning Algorithm to use: ALL ALGORITHMS

Figura 5.20: Periodo delle Feste di Natale - Sezione di input con seconda configurazione (senza Amazon e senza nuovi venditori)

In questo caso la sezione di output (fig. 5.21) (tab. 5.24, 5.25, 5.26) mostra delle statistiche che mettono in risalto delle caratteristiche molto differenti rispetto a quelle risultanti dall'analisi con la presenza di Amazon. Infatti, le caratteristiche più influenti sono state `ratings_num`, `fba` e `ratings_perc_positive`, le quali hanno superato in media `price_diff` e affini.

E' opportuno notare che non è presente tra le prime posizioni la caratteristica `delivery_days`, che ipoteticamente poteva essere considerata una delle più importanti al fine di soddisfare il consumatore per un eventuale acquisto dell'ultimo minuto con consegna in tempi rapidi.

Dunque, è possibile fornire l'interpretazione alle analisi per la quale i venditori di terze parti che hanno offerto i loro prodotti durante per la settimana prima di quella di Natale, hanno avuto più possibilità di vincere l'assegnazione della Buy Box se affiliati al programma FBA o se avevano delle ottime recensioni sia in termini di numeri che di qualità. Inoltre, solo per questo caso che considera solo i venditori di terze parti, è importante sottolineare che il prezzo del prodotto non ha la medesima rilevanza rispetto alle precedenti caratteristiche più influenti.

Output Data & Graphs


Normalized Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	4584	0.44	0.34	0	0.14	0.4	0.75	1
price_diff	4584	0.44	0.34	0	0.14	0.4	0.75	1
price_diff_ship	4584	0.02	0.14	0	0	0	0	1
delivery_days	4584	0.34	0.36	0	0	0.25	0.67	1
ratings_num	4584	0.5	0.32	0	0.2	0.5	0.8	1
ratings_avg	4584	0.67	0.31	0	0.67	0.67	1	1
ratings_perc_positive	4584	0.67	0.28	0	0.53	0.67	0.9	1
fba	4584	0.33	0.47	0	0	0	1	1


Features Dataset Describe Table

feature	count	mean	std	min	25%	50%	75%	max
price_diff_prod	4584	3.59	6.2	-1	0	0.54	4	28.07
price_diff	4584	3.75	6.62	-1	0	0.54	4	30.6
price_diff_ship	4584	0.16	1.07	0	0	0	0	7.5
delivery_days	4584	9.13	7.14	2	3	6	13	35
ratings_num	4584	7373.01	16343.63	8	199	995	8590	84313
ratings_avg	4584	4.5	0.46	3.5	4.5	4.5	5	5
ratings_perc_positive	4584	88.13	11.22	59	84	90	97	100

Buy Box Winners



Accuracy Score



Features Importance Table

feature	CLASSIFICATION AND REGRESSION TREE	GRADIENT BOOSTING	K-NEAREST NEIGHBORS	LOGISTIC REGRESSION	MULTI-LAYER PERCEPTRON	RANDOM FOREST	SUPPORT VECTOR MACHINES
delivery_days	7.15	12.4	13.96	1.64	7.57	18.81	3.3
fba	18.48	13.48	39.2	16.66	15.59	16.64	16.59
price_diff	18.82	10.18	0.45	9.21	14.59	8.46	12.16
price_diff_prod	14.56	10.22	0.45	9.25	15.42	8.42	12.16
price_diff_ship	0.01	0.01	0.35	0	0.3	0.18	0.02
ratings_avg	7.45	1.41	4.22	29.07	8.58	0.4	17.67
ratings_num	15.24	25.67	31.51	16.62	21.66	20.93	16.68
ratings_perc_positive	18.3	26.62	9.86	17.55	16.3	26.18	21.41

Features Importance Graph




Figura 5.21: Periodo delle Feste di Natale - Sezione di output per la seconda configurazione (senza Amazon e senza nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	4584	0.44	0.34	0	0.14	0.4	0.75	1
price_diff	4584	0.44	0.34	0	0.14	0.4	0.75	1
price_diff_ship	4584	0.02	0.14	0	0	0	0	1
delivery_days	4584	0.34	0.36	0	0	0.25	0.67	1
ratings_num	4584	0.5	0.32	0	0.2	0.5	0.8	1
ratings_avg	4584	0.67	0.31	0	0.67	0.67	1	1
ratings_perc_positive	4584	0.67	0.28	0	0.53	0.67	0.9	1
fba	4584	0.33	0.47	0	0	0	1	1

Tabella 5.24: Periodo delle Feste di Natale - Tabella Describe dei dati normalizzati per la seconda configurazione (senza Amazon e senza nuovi venditori)

Features	count	mean	std	min	25%	50%	75%	max
price_diff_prod	4584	3.59	6.2	-1	0	0.54	4	28.07
price_diff	4584	3.75	6.62	-1	0	0.54	4	30.6
price_diff_ship	4584	0.16	1.07	0	0	0	0	7.5
delivery_days	4584	9.13	7.14	2	3	6	13	35
ratings_num	4584	7373.01	16343.63	8	199	995	8590	84313
ratings_avg	4584	4.5	0.46	3.5	4.5	4.5	5	5
ratings_perc_positive	4584	88.13	11.22	59	84	90	97	100

Tabella 5.25: Periodo delle Feste di Natale - Tabella Describe dei dati non-normalizzati per la seconda configurazione (senza Amazon e senza nuovi venditori)

Features	Classification And Regression Tree	Gradient Boosting	K-Nearest Neighbors	Logistic Regression	Multi-Layer Perceptron	Random Forest	Support Vector Machines
delivery_days	7.15	12.4	13.96	1.64	7.57	18.81	3.3
fba	18.48	13.48	39.2	16.66	15.59	16.64	16.59
price_diff	18.82	10.18	0.45	9.21	14.59	8.46	12.16
price_diff_prod	14.56	10.22	0.45	9.25	15.42	8.42	12.16
price_diff_ship	0.01	0.01	0.35	0	0.3	0.18	0.02
ratings_avg	7.45	1.41	4.22	29.07	8.58	0.4	17.67
ratings_num	15.24	25.67	31.51	16.62	21.66	20.93	16.68
ratings_perc_positive	18.3	26.62	9.86	17.55	16.3	26.18	21.41

Tabella 5.26: Periodo delle Feste di Natale - Tabella Descrive dei dati non-normalizzati per la seconda configurazione
(senza Amazon e senza nuovi venditori)

Di seguito è riportata la tabella (tab. 5.27) che riporta le percentuali dell'accuratezza minima, media e massima relative all'addestramento dei diversi modelli di classificazione con l'applicazione del metodo Repeated K-Fold di Cross-Validation, estratte dai log applicativi registrati nella fase di analisi in Machine Learning:

Modello di classificazione	Accuratezza		
	min	mean	max
CLASSIFICATION AND REGRESSION TREE	95.41	97.24	98.91
RANDOM FOREST	95.20	97.48	98.47
SUPPORT VECTOR MACHINES	95.21	96.63	98.03
GRADIENT BOOSTING	96.29	97.51	99.13
LOGISTIC REGRESSION	91.94	94.13	97.38
MULTI-LAYER PERCEPTRON	95.85	96.88	98.47
K-NEAREST NEIGHBORS	94.99	96.94	98.91

Tabella 5.27: Periodo delle Feste di Natale - Tabella riepilogativa dell'Accuratezza per la seconda configurazione
(senza Amazon e senza nuovi venditori)

6 Conclusioni

Il presente lavoro di ricerca si è posto l'obiettivo di sviluppare uno strumento in grado di analizzare le dinamiche che influenzano l'assegnazione della Buy Box da parte di Amazon, aprendo nuove prospettive di ricerca per gli studiosi dell'argomento e contribuendo a stimolare ulteriori approfondimenti in questo campo.

Attraverso l'implementazione di un sistema containerizzato di Web Scraping, applicazione di algoritmi di Machine Learning e di esplorazione dei dati, si è riusciti a estrarre e analizzare un ampio insieme di informazioni relativo a venditori e prodotti su Amazon. L'obiettivo di identificare le caratteristiche dei venditori che influenzano maggiormente l'assegnazione della Buy Box è stato raggiunto, mentre l'approccio containerizzato ha permesso la realizzazione di un sistema modulare e portatile, che possa fornire agli studiosi dell'argomento un punto di partenza solido per lo sviluppo di nuove funzionalità o l'esplorazione di nuovi dati.

La ricerca è iniziata con un capitolo introduttivo in cui è stato illustrato il contesto attorno al quale ruota il presente elaborato, ossia la piattaforma di e-commerce Amazon. E' stata effettuata una panoramica sul contesto commerciale che ruota attorno ad Amazon e ai venditori che decidono di vendere i loro prodotti tramite la vetrina di questo colosso dell'e-commerce, con evidenza degli elementi fondamentali che caratterizzano la piattaforma, quali la Buy Box e il pricing dinamico.

Il capitolo successivo ha illustrato il lavoro progettuale ad alto livello, con evidenza degli obiettivi, delle tecnologie utilizzate e della relazione e comunicazione tra le parti che lo compongono. Ogni elemento dell'architettura containerizzata realizzata è stato approfondito nei capitoli a seguire, con l'analisi delle scelte effettuate e degli opportuni dettagli implementativi.

In particolare, il capitolo successivo si è focalizzato sul campionamento dei dati da Amazon tramite tecniche di Web Scraping, realizzate mediante script in Python atti a estrarre le informazioni più rilevanti dei venditori per alcuni prodotti di diverse categorie. Tra i dati raccolti vi sono informazioni quali il prezzo di vendita del prodotto, il numero di recensioni e il rating del venditore, i giorni di consegna e altre caratteristiche rilevanti. Tali dati sono raccolti in un formato strutturato in JSON e memorizzati in un Database non-relazionale MongoDB.

E' seguito il capitolo in cui si sono analizzati i dati raccolti tramite gli algoritmi di Machine Learning, con un approfondimento sulle caratteristiche scelte per l'analisi, sui singoli algoritmi e sui dettagli implementativi che consentiranno di ottenere i risultati con delle prestazioni ottimali.

Successivamente, si è illustrata la piattaforma Web sviluppata per consentire la scelta dei parametri di filtro dei dati da analizzare e di input all'analisi in Machine Learning secondo gli algoritmi trattati nel capitolo appena precedente e la visualizzazione dei risultati dell'analisi stessa, in modo da consentire l'esplorazione di diverse configurazioni che possono portare a risultati diversi e di particolare interesse.

Infatti, tramite tale piattaforma sono state esplorate alcune specifiche configurazioni che hanno mostrato, oltre a un'elevata accuratezza nell'analisi, convalidata dai meccanismi di Cross-Validation, dei risultati notevoli che hanno evidenziato quali sono le caratteristiche dei venditori che Amazon predilige per l'assegnazione della Buy Box.

In particolare, sono stati presi in considerazione tre periodi di osservazione di particolare interesse, quali un periodo non promozionale, il periodo del Black Friday e il periodo delle Feste di Natale, e due particolari composizioni di input alle analisi nelle quali Amazon e i nuovi venditori sono inclusi nei dati, sia come vincitori che non della Buy Box, oppure sono filtrati ed esclusi.

I risultati delle analisi condotte hanno evidenziato che il prezzo totale di vendita del prodotto rappresenta il fattore più determinante per l'assegnazione della Buy Box. Tuttavia, anche altri elementi come l'adesione al programma FBA di Amazon e la percentuale di recensioni positive hanno dimostrato di avere un impatto significativo. Inoltre, l'analisi comparativa dei diversi periodi osservati (non promozionale, Black Friday, Natale) e delle diverse configurazioni dei dati ha permesso di individuare variazioni nelle dinamiche di assegnazione della Buy Box, sottolineando la complessità dell'algoritmo di Amazon.

I risultati ottenuti confermano l'importanza della competitività sui prezzi per conquistare la Buy Box. Tuttavia, emergono anche altri fattori che i venditori dovrebbero considerare, come la qualità del servizio offerto, misurata dalle recensioni, e la partecipazione al programma FBA, che garantisce una gestione logistica efficiente.

Lo studio presenta alcuni limiti, legati principalmente alla natura dinamica dell'algoritmo di Amazon e alla difficoltà di accedere a tutti i dati rilevanti. Future ricerche potrebbero approfondire l'analisi considerando ulteriori variabili, come la condizione del prodotto, la stagionalità della domanda e l'impatto delle campagne pubblicitarie. Inoltre, sarebbe interessante estendere lo studio ad altre piattaforme di e-commerce per verificare se le dinamiche osservate su Amazon sono generalizzabili.

Un'ulteriore direzione di ricerca potrebbe consistere nell'arricchire l'insieme di dati da esaminare con nuovi prodotti di diverse categorie e con informazioni più dettagliate, includendo proprio la categoria di appartenenza. Ciò consentirebbe di condurre analisi più granulari, identificando eventuali differenze nelle dinamiche di assegnazione della Buy Box tra le diverse categorie. Ad esempio, si potrebbe indagare se prodotti di elettronica, abbigliamento o alimentari sono soggetti a criteri di selezione differenti.

Inoltre, l'introduzione di una classificazione dei prodotti per categoria potrebbe facilitare l'identificazione di nuovi pattern e tendenze. Potrebbe emergere, ad esempio, che all'interno di una stessa categoria, prodotti di fascia alta sono soggetti a criteri di selezione più rigorosi rispetto a quelli di fascia bassa.

In riferimento all'applicazione Web, eventuali evoluzioni potrebbero includere nuovi filtri e selezioni per esplorare nuove configurazioni di input alle analisi in Machine Learning, con quest'ultime che potrebbero essere condotte con l'introduzione di un sistema di valutazione più complesso, come ad esempio con voto a maggioranza o pesato sulla base dell'accuratezza raggiunta o dell'adeguatezza computazionale dei singoli algoritmi alla grandezza dell'insieme di dati in input.

Si potrebbe, inoltre, estendere il parco dei grafici e delle statistiche visualizzate nella piattaforma, fornendo all'utente un quadro più esteso e con nuovi particolari, che possa mettere in evidenza, ad esempio, i risultati parziali dell'analisi in Machine Learning per ogni modello di classificazione.

In conclusione, Il sistema sviluppato in questo lavoro rappresenta un valido strumento che offre una base solida per l'estrazione, l'analisi e la visualizzazione dei dati, garantendo un buon punto di partenza per eventuali evoluzioni future. La sua natura open source e la sua documentazione dettagliata, attraverso questo elaborato, permettono alla comunità scientifica di beneficiare di uno strumento potente e flessibile, incentivando la collaborazione e l'ulteriore sviluppo nel campo dell'analisi della Buy Box.

Bibliografia

- [B1] Anderson C., *Makers: The New Industrial Revolution*, Crown Business, 2014.
- [B2] Agrawal A., Gans J. S., Goldfarb A., *Prediction machines: The simple economics of artificial intelligence*, Harvard Business Review Press, 2018.
- [B3] Chen L., Mislove A., Wilson C., *An Empirical Analysis of Algorithmic Pricing on Amazon Marketplace*, 2016.
- [B4] Mitchell R., *Web Scraping with Python: Collecting More Data from the Modern Web*, O'Reilly Media, 2018.
- [B5] Raschka S., *Machine learning con Python. Costruire algoritmi per generare conoscenza*, Apogeo, 2016.
- [B5.1] opera citata in [B5], capitolo 1, pagine 29-33.
- [B5.2] opera citata in [B5], capitolo 3, pagine 70-74.
- [B5.3] opera citata in [B5], capitolo 4, pagine 116-118.
- [B5.4] opera citata in [B5], capitolo 7, pagine 173-179.
- [B5.5] opera citata in [B5], capitolo 7, pagine 185-189.
- [B5.6] opera citata in [B5], capitolo 7, pagine 190-196.
- [B5.7] opera citata in [B5], capitolo 12, pagine 318-319.
- [B6] Sensini S., *Docker: Sviluppare e rilasciare software tramite container*, Apogeo, 2020.
- [B7] Peng J., Jury E., Dönnies P., Ciurtin C., *Machine Learning Techniques for Personalised Medicine Approaches in Immune-Mediated Chronic Inflammatory Diseases: Applications and Challenges. Frontiers in Pharmacology*, 2021.
- [B8] Matanga Y., *Master Thesis: Analysis of Control Attainment in Endogenous Electroencephalogram-Based Brain Computer Interfaces*, 2017.
- [B9] James G., Witten D., Hastie T., Tibshirani R., Taylor J., *An Introduction to Statistical Learning: With Applications in Python*, Springer International Publishing, 2023.
- [B9.1] opera citata in [B9], capitolo 8, pagine 337-341.
- [B9.2] opera citata in [B9], capitolo 8, pagine 346-347.
- [B9.3] opera citata in [B9], capitolo 8, pagine 377-382.

[B9.4] opera citata in [B9], capitolo 8, pagine 347-350.

[B9.5] opera citata in [B9], capitolo 4, pagine 138-146.

[B9.6] opera citata in [B9], capitolo 4, pagine 183-188.

[B10] Goodfellow I., Bengio Y., Courville A., *Deep Learning*, MIT Press, 2016, capitolo 6.

Sitografia

- [S1] <https://www.aboutamazon.it/chi-siamo>, consultato in data 02/01/2025.
- [S2] <https://it.tradingview.com/symbols/NASDAQ-AMZN/financials-income-statement/total-revenue/>, consultato in data 17/11/2024.
- [S3] <https://it.tradingview.com/symbols/NASDAQ-AMZN/financials-revenue/>, consultato in data 17/11/2024.
- [S4] <https://www.junglescout.com/resources/articles/amazon-statistics-2024/>, consultato in data 17/11/2024.
- [S5] <https://sell.amazon.com/fulfillment-by-amazon>, consultato in data 17/11/2024.
- [S6] <https://www.contimod.com/amazon-seller-statistics/#amazon-fba-seller-statistics>, consultato in data 17/11/2024.
- [S7] <https://business.amazon.it/>, consultato in data 04/01/2025.
- [S8] <https://sell.amazon.com/programs/fulfilled-by-merchant>, consultato in data 03/01/2025.
- [S9] <https://www.python.org/>, consultato in data 17/11/2024.
- [S10] <https://www.crummy.com/software/BeautifulSoup/>, consultato in data 17/11/2024.
- [S11] <https://www.selenium.dev/>, consultato in data 17/11/2024.
- [S12] <https://www.mongodb.com/it-it>, consultato in data 17/11/2024.
- [S13] <https://pymongo.readthedocs.io/en/stable/>, consultato in data 17/11/2024.
- [S14] <https://github.com/mongo-express/mongo-express>, consultato in data 17/11/2024.
- [S15] <https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.html>, consultato in data 04/11/2025.
- [S16] <https://Scikit-Learn.org/stable>, consultato in data 17/11/2024.
- [S17] <https://dash.plotly.com/>, consultato in data 17/11/2024.
- [S18] <https://www.docker.com/>, consultato in data 17/11/2024.
- [S19] <https://docs.docker.com/compose/>, consultato in data 17/11/2024.

- [S20] <https://yaml.org/>, consultato in data 17/11/2024.
- [S21] <https://docs.docker.com/get-started/docker-concepts/the-basics/what-is-an-image/>, consultato in data 17/11/2024.
- [S22] <https://docs.docker.com/reference/dockerfile/>, consultato in data 17/11/2024.
- [S23] <https://docs.docker.com/engine/storage/volumes/>, consultato in data 17/11/2024.
- [S24] https://registry.hub.docker.com/_/mongo, consultato in data 17/11/2024.
- [S25] https://registry.hub.docker.com/_/mongo-express, consultato in data 17/11/2024.
- [S26] https://registry.hub.docker.com/_/python, consultato in data 17/11/2024.
- [S27] <https://support.mozilla.org/en-US/kb/install-firefox-linux>, consultato in data 20/11/2024.
- [S28] <https://tg24.sky.it/tecnologia/2024/11/19/amazon-black-friday-2024-quando-inizia>, consultato in data 03/11/2025.
- [S29] <https://wiki.ubuntu-it.org/AmministrazioneSistema/Cron>, consultato in data 20/11/2024.
- [S30] <https://www.amazon.it/dp/B07YGZO4H8/ref=olp-opf-redir?od=1&ie=UTF8&condition=NEW>, consultato in data 21/11/2024.
- [S31] <https://Scikit-Learn.org/stable/modules/tree.html#classification>, consultato in data 17/11/2024.
- [S32] <https://williamkoehrsen.medium.com/random-forest-simple-explanation-377895a60d2d>, consultato in data 05/01/2025.
- [S33] <https://Scikit-Learn.org/stable/modules/ensemble.html#random-forests-and-other-randomized-tree-ensembles>, consultato in data 17/11/2024.
- [S34] <https://medium.com/@jainvidip/understanding-support-vector-machines-svms-1f7c78bad934>, consultato in data 05/01/2025.
- [S35] <https://Scikit-Learn.org/stable/modules/svm.html#support-vector-machines>, consultato in data 17/11/2024.
- [S36] <https://medium.com/@hemashreekilari9/understanding-gradient-boosting-632939b98764>, consultato in data 05/01/2025.

- [S37] <https://Scikit-Learn.org/stable/modules/ensemble.html#gradient-boosted-trees>, consultato in data 17/11/2024.
- [S38] <https://medium.com/@jainvidip/understanding-logistic-regression-e6b8f379a420>, consultato in data 05/01/2025.
- [S39] https://Scikit-Learn.org/stable/modules/linear_model.html#logistic-regression, consultato in data 17/11/2024.
- [S40] <https://www.sciencedirect.com/topics/computer-science/multilayer-perceptron>, consultato in data 05/01/2025.
- [S41] https://Scikit-Learn.org/stable/modules/neural_networks_supervised.html#multi-layer-perceptron, consultato in data 17/11/2024.
- [S42] <https://intuitivetutorial.com/2023/04/07/k-nearest-neighbors-algorithm/>, consultato in data 05/01/2025.
- [S43] <https://Scikit-Learn.org/stable/modules/neighbors.html#nearest-neighbors>, consultato in data 17/11/2024
- [S44] https://Scikit-Learn.org/dev/modules/generated/sklearn.model_selection.GridSearchCV.html#gridsearchcv, consultato in data 17/11/2024
- [S45] <https://matplotlib.org/>, consultato in data 08/01/2025.
- [S46] <https://dash.plotly.com/dash-html-components>, consultato in data 22/12/2024.
- [S47] <https://dash-bootstrap-components.opensource.faculty.ai/>, consultato in data 22/12/2024.
- [S48] <https://dash.plotly.com/basic-callbacks>, consultato in data 22/12/2024.
- [S49] <https://dash.plotly.com/dash-core-components/datepickerrange>, consultato in data 22/12/2024.
- [S50] <https://dash.plotly.com/dash-core-components/dropdown>, consultato in data 22/12/2024.
- [S51] <https://dash.plotly.com/dash-core-components/radioitems>, consultato in data 22/12/2024.
- [S52] <https://dash.plotly.com/dash-core-components/slider>, consultato in data 22/12/2024.
- [S53] <https://dash.plotly.com/dash-html-components/button>, consultato in data 22/12/2024.

- [S54] <https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.describe.html>, consultato in data 26/12/2024.
- [S55] <https://dash.plotly.com/datatable>, consultato in data 26/12/2024.
- [S56] <https://plotly.com/python/pie-charts/>, consultato in data 29/12/2024.
- [S57] <https://dash.plotly.com/dash-daq/gauge>, consultato in data 26/12/2024.
- [S58] <https://plotly.com/python/histograms/>, consultato in data 27/12/2024.
- [S59] <https://neptune.ai/blog/cross-validation-in-machine-learning-how-to-do-it-right>, consultato in data 28/01/2025.
- [S60] https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.KFold.html, consultato in data 28/01/2025.
- [S61] https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedKFold.html, consultato in data 28/01/2025.
- [S62] https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.RepeatedKFold.html, consultato in data 28/01/2025.
- [S63] https://scikit-learn.org/stable/modules/permutation_importance.html, consultato in data 28/01/2025.
- [S64] https://scikit-learn.org/stable/modules/generated/sklearn.metrics.accuracy_score.html, consultato in data 06/02/2025.

Appendice A - Codice sorgente del progetto

Il codice sorgente afferente il lavoro progettuale è pubblicato e accessibile sul repository Github <https://github.com/giubag10/amazon-buy-box> ed è strutturato secondo la seguente alberatura:




Figura A.1: Alberatura codice sorgente del progetto

Appendice B - Esempi di file di campionamento

In questa sezione sono raccolti esempi di file di campionamento afferenti il lavoro progettuale.

result_example.json

```
[
  {
    "name": "PORTA CELLULARE AUTO",
    "url": "https://www.amazon.it/dp/B0C273FR2T/ref=olp-opf-redir?aod=1&ie=UTF8&condition=NEW",
    "datetime_extraction": "2024-09-14 11:00:02",
    "data": {
      "product": {
        "name": "Miracase Porta Cellulare Auto, [Livello Militare Aspirazione Affidabile] Supproto Telefono Auto Universale, Per il Cruscotto & Bocchette di Aerazione E Parabrezza Adatto a Tutti Smartphone",
        "ratings": {
          "num": 5394
        }
      },
      "buybox_seller": {
        "name": "Miracase-EU",
        "index": 0,
        "sale": {
          "priceNoShipping": 11.949999999999999,
          "condition": 5,
          "totalPrice": 11.949999999999999,
          "diffPriceNoShipping": 0,
          "diffTotalPrice": 0
        }
      },
      "shipping": {
        "price": 0,
        "days": 4,
        "diffPrice": 0
      },
      "ratings": {
        "isNew": false,
        "avg": 5.0,
        "num": 733,
        "perc_positive": 98
      },
      "fba": true
    },
    "other_sellers": [
      {
        "name": "BODE",
        "index": 1,
        "sale": {
          "priceNoShipping": 11.949999999999999,
          "condition": 5,
          "totalPrice": 11.949999999999999,
          "diffPriceNoShipping": 0.0,
          "diffTotalPrice": 0.0
        },
        "shipping": {
```

```

        "price": 0,
        "days": 4,
        "diffPrice": 0
    },
    "ratings": {
        "isNew": false,
        "avg": 5.0,
        "num": 2,
        "perc_positive": 100
    },
    "fba": true
},
{
    "name": "EMRSPTA",
    "index": 2,
    "sale": {
        "priceNoShipping": 17.379999999999999,
        "condition": 5,
        "totalPrice": 17.379999999999999,
        "diffPriceNoShipping": 5.4299999999999997,
        "diffTotalPrice": 5.4299999999999997
    },
    "shipping": {
        "price": 0,
        "days": 5,
        "diffPrice": 0
    },
    "ratings": {
        "isNew": false,
        "avg": 5.0,
        "num": 234,
        "perc_positive": 99
    },
    "fba": true
},
{
    "name": "Amazon",
    "index": 3,
    "sale": {
        "priceNoShipping": 17.98,
        "condition": 5,
        "totalPrice": 17.98,
        "diffPriceNoShipping": 6.0300000000000011,
        "diffTotalPrice": 6.0300000000000011
    },
    "shipping": {
        "price": 0,
        "days": 4,
        "diffPrice": 0
    },
    "ratings": {
        "isNew": false,
        "avg": null,
        "num": null,
        "perc_positive": null
    },
    "fba": true
},
{
    "name": "Gambistore",

```

```

        "index": 4,
        "sale": {
            "priceNoShipping": 22.989999999999998,
            "condition": 5,
            "totalPrice": 22.989999999999998,
            "diffPriceNoShipping": 11.039999999999999,
            "diffTotalPrice": 11.039999999999999
        },
        "shipping": {
            "price": 0,
            "days": 5,
            "diffPrice": 0
        },
        "ratings": {
            "isNew": false,
            "avg": 1.0,
            "num": 3,
            "perc_positive": 0
        },
        "fba": false
    },
    {
        "name": "Amazon UK",
        "index": 5,
        "sale": {
            "priceNoShipping": 27.719999999999999,
            "condition": 5,
            "totalPrice": 27.719999999999999,
            "diffPriceNoShipping": 15.77,
            "diffTotalPrice": 15.77
        },
        "shipping": {
            "price": 0,
            "days": 6,
            "diffPrice": 0
        },
        "ratings": {
            "isNew": false,
            "avg": null,
            "num": null,
            "perc_positive": null
        },
        "fba": true
    }
]
}
]

```

result_err_example.json

```
[
  {
    "name": "PORTA CELLULARE AUTO",
    "url":
    "https://www.amazon.it/dp/B0C273FR2T/ref=olp-opf-redir?aod=1&ie=UTF8&condi
    tion=NEW",
    "datetime_extraction": "2024-09-14 11:00:02",
    "data": null
  }
]
```